Федеральное государственное автономное образовательное учреждение высшего образования «Московский физико-технический институт (национальный исследовательский университет)»

Физтех-школа прикладной математики и информатики
Научно-образовательный центр когнитивного моделирования

Доклад об основных результатах диссертации
специальность 1.2.1 — Искусственный интеллект и машинное обучение

Методы и алгоритмы безопасного обучения с подкреплением в робототехнических задачах

Аспирант: Горбов Григорий Владиславович
Научный руководитель: д-р физ.-мат. наук, проф. РАН Александр Игоревич Панов

Долгопрудный, 2026

Основные способы обучения роботов

- датасеты экспертных траекторий;
- симуляторы с заданным подкрепляющим сигналом.

Проблемы переноса

- **Out-of-distribution:** реальные ситуации отсутствуют в обучающем датасете;
- **Sim-to-real:** симулятор не учитывает все особенности реальной системы.

Решение проблемы — дообучение робота в реальном мире

Обучение с подкреплением (RL)

Агент обучается методом проб и ошибок непосредственно при взаимодействии со средой.

Исследование среды $\rightarrow$ обнаружение эффективной последовательности действий $\rightarrow$ достижение цели.

Риски исследования

Случайное исследование в реальной среде может приводить к:

- столкновениям;
- поломке оборудования;
- причинению вреда человеку.

Безопасное обучение с подкреплением (SafeRL)

Проблемой безопасного исследования занимается область Безопасного обучения с подкреплением (SafeRL).

Цель работы

Исследование и разработка методов безопасного обучения с подкреплением, которые используют модели мира и иерархическую структуру поведения для повышения эффективности исследования среды при соблюдении ограничений безопасности в робототехнических задачах.

Задачи исследования:

1. Провести анализ существующих методов безопасного обучения с подкреплением и сред, используемых для их экспериментальной оценки.
2. Разработать подход для учёта долгосрочного риска в методах безопасного обучения с подкреплением на основе модели мира.
3. Разработать подход на основе иерархического обучения с подкреплением для решения задачи безопасного исследования.
4. Разработать метод генерации безопасных подцелей с использованием модели мира для задач с большим горизонтом.
5. Разработать бенчмарк для обучения и оценки методов безопасного обучения с подкреплением в задачах с целями и ограничениями на естественном языке.

Положения, выносимые на защиту

1. Способ построения и агрегации функций оценки будущих накопленных штрафов в модели мира для безопасного исследования в рамках модели SPOWL.
2. Метод SG-Safe, использующий генерацию промежуточных подцелей для улучшения исследовательских способностей безопасной стратегии.
3. Метод ITES, контролирующий безопасность на уровне генерации подцелей и на уровне исполнения действий с помощью модели мира.
4. Бенчмарк Caged CrafText для обучения и оценки методов обучения с подкреплением с естественно-языковыми целями и ограничениями.

Научная новизна

1. В рамках метода **SPOWL** предложена функция оценки будущих накопленных штрафов в рамках модели мира для улучшения скрытых представлений, а также для более точной оценки безопасности траекторий при планировании. Эксперименты на средах Safety Gym показали лучшую производительность и безопасность по сравнению с предыдущими методами безопасного обучения с подкреплением.
2. Разработан метод **SG-Safe**, использующий промежуточные подцели для улучшения исследовательских способностей безопасной стратегии. Метод показывает лучшее качество в среде POLAMP в сравнении с методами безопасного обучения с подкреплением и методами на основе классического планирования.
3. Разработан метод **ITES**, обеспечивающий безопасную генерацию и достижение подцелей с помощью модели мира. Метод достигает лучшего качества в задачах навигации и манипуляции с большим горизонтом в сравнении с методами на основе моделей мира в безопасном обучении с подкреплением.
4. Разработанный бенчмарк **Caged CrafText** позволяет оценивать способности методов обучения с подкреплением: понимание языка (language understanding), связывание языка с объектами из среды (grounding), память, безопасное исследование.

Соответствие паспорту специальности 1.2.1

- постановка задач управления и принятия решений на основе методов ИИ, в том числе управления роботами;
- разработка алгоритмического и программного обеспечения систем ИИ, а также методов их взаимодействия с человеком;
- исследования доверенных систем ИИ: надёжность, устойчивость и формирование тестовых наборов задач;
- методы и технологии поиска, приобретения и использования знаний и закономерностей, в том числе эмпирических, в системах искусственного интеллекта; исследования в области совместного применения методов машинного обучения и классического математического моделирования; методы и средства использования экспертных знаний.

Математическая постановка: CMDP

Задача безопасного исследования формализуется при помощи марковского процесса принятия решений с ограничениями:

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, P, r, c, \gamma, d \rangle,$$

где $\mathcal{S}$ — пространство состояний, $\mathcal{A}$ — пространство действий, P — функция переходов, $\pi : \mathcal{S} \to \mathcal{A}$ — стратегия (распределение над действиями), r — вознаграждение, c — штраф за нарушение ограничения, d — допустимый бюджет нарушений.

$$\max_{\pi} J_R(\pi) = \mathbb{E}_{\pi}\left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t)\right],$$

$$\text{при условии} \quad J_C(\pi) = \mathbb{E}_{\pi}\left[\sum_{t=0}^{\infty} \gamma^t c(s_t, a_t)\right] \leq d.$$

Интерпретация

r — численно оценивает желаемое поведение агента.
c — численно оценивает ограничения.

Пример

Мобильный робот должен достигнуть цели, не сталкиваясь с препятствиями и не превышая допустимый уровень нарушений.

[1] Источник постановки и сред: Altman, 1999; Ray et al., “Benchmarking Safe Exploration in Deep Reinforcement Learning”, 2019.

Основные подходы к безопасному обучению с подкреплением

Методы оптимизации стратегии с ограничениями

Методы применимы для произвольной CMDP-задачи, но не гарантируют безопасность каждого действия.

Метод на основе функции Лагранжа

$$\max_{\pi} J_R(\pi) = \mathbb{E}_{\pi}\left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t)\right]$$

$$J_C(\pi) = \mathbb{E}_{\pi}\left[\sum_{t=0}^{\infty} \gamma^t c(s_t, a_t)\right] \leq d.$$

$$\mathcal{L}(\pi, \lambda) = J_R(\pi) - \lambda\big(J_C(\pi) - d\big), \qquad \lambda \geq 0.$$

$$\max_{\pi} \min_{\lambda \geq 0} \mathcal{L}(\pi, \lambda).$$

Если $J_C(\pi) > d$, множитель λ увеличивается и стратегия сильнее штрафуется за нарушения.

Методы на основе фильтрации действий

Метод на основе барьерной функции

h — барьерная функция; $h(s) \geq 0$ — безопасное множество состояний.

$a_\pi \sim \pi(\cdot \mid s)$, где π — стратегия, не учитывающая ограничения безопасности.

$$a_{\text{safe}} = \arg\min_{a} \|a - a_\pi\|^2.$$

$$\dot{h}(s) = \nabla h(s)^\top \big(f(s) + g(s)a\big) \geq 0.$$

Требуется модель объекта управления $\dot{s} = f(s) + g(s)a$.

[1] Источники: Ray et al., 2019; Stooke et al., 2020; Ames et al., 2017; Dalal et al., 2018.

Методы, использующие синтетический опыт и планирование

SafeDreamer
Модель мира: g_θ — декодер, f_θ — динамика, r_θ — награда, c_θ — штраф (f,r,c на входе берут z_t):

$$\hat{s}_t = g_\theta(z_t),\ \hat{z}_{t+1} = f_\theta(z_t,a_t),\ \hat{r}_t = r_\theta(z_t,a_t),\ \hat{c}_t = c_\theta(z_t,a_t).$$

Планирование (CEM):

1. $a_t \sim \mathcal{N}^t(\mu_a^t, \sigma_a^t)$, $t = 0,\dots,H-1$;
   $\tau = (z_t,a_t,\dots,z_{t+H},a_{t+H})$, $z_{t+1} = f(z_t,a_t)$.
2. $J_{\text{local}}(\tau^{(i)}) = \sum_{t=0}^{H-1} \gamma^t \hat{c}_t^{(i)}$, $\mathcal{T}_{\text{safe}} = \{i : J_{\text{local}}(\tau^{(i)}) \le d\}$;
3. $J^R_{\text{local}}(\tau^{(i)}) = \sum_{t=0}^{H-1} \gamma^t \hat{r}_t^{(i)}$, $\mathcal{T}_{\text{elite}} = \text{Top}_k\big(\mathcal{T}_{\text{safe}}, J^R_{\text{local}}\big)$.

Стратегия (обучение в модели мира):

$$\mathcal{L}(\pi,\lambda) = J_R(\pi) - \lambda\big(J_C(\pi) - d\big).$$

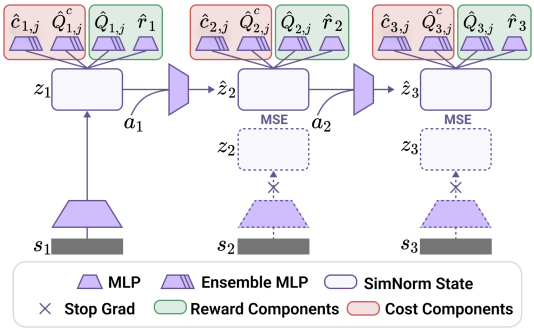
[1] Источники: Huang et al., 2024; As et al., 2022; Jayant et al., 2022.

Преимущества

- позволяют генерировать дополнительный синтетический опыт;
- позволяют планировать в рамках модели мира.

Текущие проблемы SafeDreamer

- Смещённая цель (*miss objective*): декодер предсказывает лишнюю информацию.
- Безопасность траекторий оценивается только при помощи c_θ, то есть на коротком горизонте.



$$z_t = h(s_t), \qquad \hat{z}_{t+1} = f(z_t, a_t)$$

$$\hat{r}_t = \hat{R}(z_t, a_t), \qquad \hat{Q}_{t,j} = \hat{Q}_j(z_t, a_t)$$

$$\hat{c}_{t,j} = \hat{C}_j(z_t, a_t), \qquad \boxed{\hat{Q}^c_{t,j} = \hat{Q}^c_j(z_t, a_t)}$$

Дает информацию о будущих штрафах

Неявная модель мира

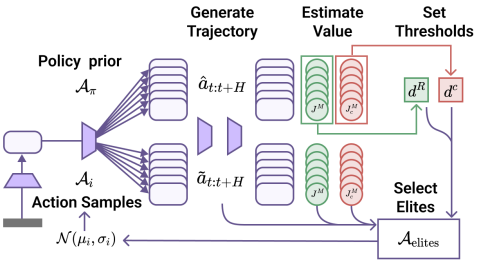
Неявная модель мира в SPOWL обучается полезным представлениям с точки зрения CMDP-задачи и помогает решать проблему смещённой цели (*miss objective*).

Оценка будущих накопленных штрафов

$$\hat{Q}^c_{t,j} = \hat{Q}^c_j(z_t, a_t)$$

$\hat{Q}^c_j$ задаёт оценку ожидаемого будущего накопленного штрафа.

SPOWL: оценка риска с помощью модели мира



Планирование (CEM)

1. $a_t \sim \mathcal{N}^t(\mu_a^t, \sigma_a^t),\ t = 0, \ldots, H-1;$
   $\tau = (z_t, a_t, \ldots, z_{t+H}, a_{t+H}),\ z_{t+1} = f(z_t, a_t).$
2. $\mathcal{T}_{\text{safe}} = \{i : J_M^c(\tau^{(i)}) \le d\};$
3. $\mathcal{T}_{\text{elite}} = \text{Top}_k(\mathcal{T}_{\text{safe}}, J_M^R).$

$$J_M^R = \sum_{i=0}^{H-1} \gamma^i \hat{r}_{t+i} + \gamma^H \hat{Q}_{\text{avg}}(z_{t+H}, a_{t+H})$$

$$J_M^c = \sum_{i=0}^{H-1} \gamma^i \hat{c}_{t+i} + \boxed{\gamma^H \hat{Q}_{c,\text{avg}}(z_{t+H}, a_{t+H})}$$

Улучшает оценку безопасности траекторий

Это позволяет учитывать нарушения **за пределами короткого горизонта** модели мира.

SPOWL: сравнение с базовыми методами

Task	Metric	SPOWL	TD-MPC2	SafeDreamer	PPOLag(25)
PG1	$R\uparrow$	26.9 ± 0.4	27.5 ± 0.2	12.0 ± 4.0	14.5 ± 0.6
	$C\downarrow$	1.5 ± 1.1	52.3 ± 8.6	10.3 ± 9.5	19.7 ± 3.0
	$\rho\downarrow$	133 ± 2	515 ± 9	160 ± 16	361 ± 20
PG2	$R\uparrow$	13.7 ± 3.2	27.4 ± 0.5	5.2 ± 3.9	2.0 ± 0.9
	$C\downarrow$	4.8 ± 1.2	179.0 ± 12.2	0 ± 0	33.7 ± 16.3
	$\rho\downarrow$	280 ± 5	1641 ± 18	221 ± 32	570 ± 73
PP1	$R\uparrow$	18.7 ± 1.4	20.8 ± 0.6	12.5 ± 7.2	4.4 ± 2.7
	$C\downarrow$	1.8 ± 2.5	34.2 ± 11.6	7.3 ± 10.4	24.2 ± 12.4
	$\rho\downarrow$	103 ± 5	353 ± 6	71 ± 3	276 ± 16
PB1	$R\uparrow$	10.0 ± 1.5	33.4 ± 0.4	0.1 ± 1.4	3.7 ± 2.5
	$C\downarrow$	5.4 ± 2.7	103.3 ± 3.1	0.3 ± 0.5	33.6 ± 7.7
	$\rho\downarrow$	269 ± 3	1219 ± 10	159 ± 3	392 ± 27
CG1	$R\uparrow$	31.3 ± 0.8	34.8 ± 0.3	6.6 ± 1.2	18.4 ± 3.9
	$C\downarrow$	1.0 ± 1.0	51.2 ± 7.9	0 ± 0	30.5 ± 5.0
	$\rho\downarrow$	113 ± 2	563 ± 11	127 ± 15	345 ± 9
DG1	$R\uparrow$	19.0 ± 1.9	27.9 ± 1.5	1.1 ± 0.9	0 ± 0
	$C\downarrow$	0.3 ± 0.4	72.6 ± 20.6	0 ± 0	21.8 ± 30.8
	$\rho\downarrow$	286 ± 15	659 ± 33	260 ± 70	376 ± 70
AG1	$R\uparrow$	38.9 ± 1.4	61.0 ± 2.6	0.2 ± 0.2	5.1 ± 3.9
	$C\downarrow$	2.0 ± 0.2	70.9 ± 6.0	0 ± 0	23.6 ± 18.2
	$\rho\downarrow$	275 ± 6	682 ± 6	218 ± 58	638 ± 115

Метрики

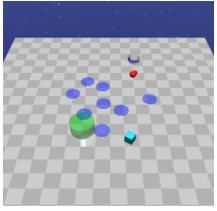
$R\uparrow$ — среднее вознаграждение.

$C\downarrow$ — средний штраф.

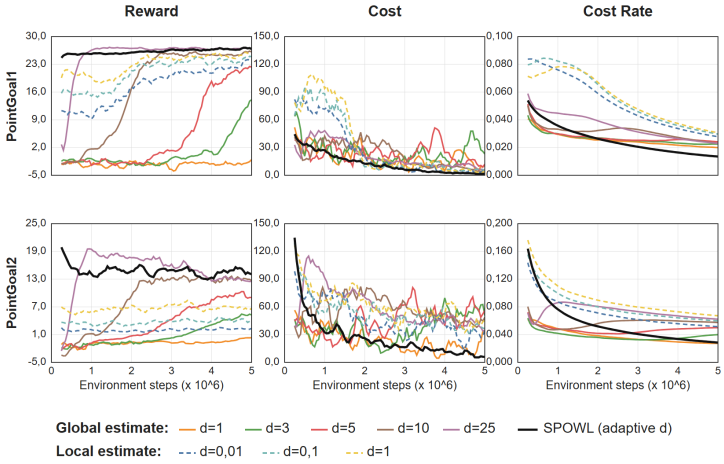
$\rho\downarrow$ — средний штраф за шаг $(\times 10^4)$.

ET↓ — время генерации одного действия при инференсе: $4.0 \cdot 10^{-2}$ с.

Safety Gym



SPOWL: локальная и глобальная оценки штрафов



Проблема безопасного исследования в задачах с большим горизонтом

Добавление безопасности к RL-стратегии → исследование ухудшается → переход на задачи с большим горизонтом → робот стоит на месте.

Признаки большого горизонта

- большая последовательность шагов до цели;
- разреженное вознаграждение;
- большое пространство состояний и действий.

Базовые методы в задачах с большим горизонтом

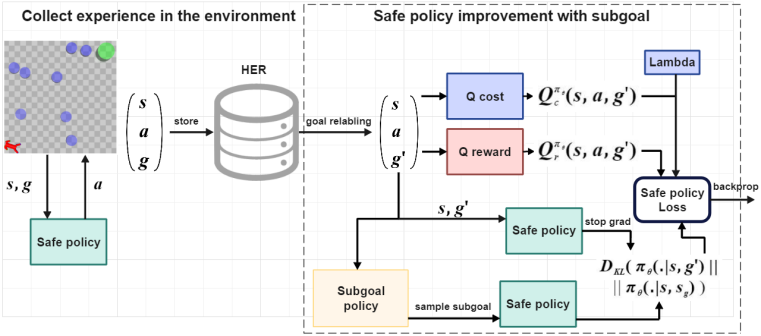
SafeAntMaze-C

Method	Final SR↑	Final Cost↓
SafeDreamer	0	13 ± 18.11
CUP	0	6.8 ± 22.4
FOCOPS	0	19.4 ± 50.9
PPOLAG	0.2 ± 0.2	41.2 ± 1.1
TD3LAG	0.13 ± 0.33	133.45 ± 184.4

SafePusher

Method	Final SR↑	Final Cost↓
SafeDreamer	0	6.7 ± 2.7
TD3LAG	0.05 ± 0.03	54.72 ± 3.16
CUP	0.01	46.14 ± 0.42
FOCOPS	0	55.83 ± 1.67
PPOLAG	0	51.25 ± 1.25

SG-Safe: Решение проблемы безопасного исследования в задачах с большим горизонтом через подцели



Промежуточные подцели декомпозируют задачу, направляют исследование и упрощают достижение цели; при обучении — дополнительный сигнал, при исполнении — только безопасная стратегия.

SG-Safe: функции оптимизации стратегий

Стратегия генерации подцелей (SAC) базируется на подходе RIS[1].

$V^{\pi_\theta}(s,g)$ — ожидаемое дисконтированное вознаграждение при достижении цели g из состояния s:

$$V^{\pi_\theta}(s,g) = \mathbb{E}_{\pi_\theta}\left[\sum_{t=0}^{\infty}\gamma^t r(s_t,a_t,g)\,\middle|\, s_0 = s\right].$$

При $r = -1$ величина $V^{\pi_\theta}(s,g)$ равна количеству шагов от s до g.

$$\psi_{\pi_\theta}(s_g \mid s,g) = \max\left(|V^{\pi_\theta}(s,s_g)|, |V^{\pi_\theta}(s_g,g)|\right).$$

Минимизация ψ_{π_θ} заставляет подцель быть по середине пути от s до g.

$$\pi^H = \arg\max_{\pi} \mathbb{E}\left[-\psi_{\pi_\theta}(s_g \mid s,g)\right],$$

$$D_{\mathrm{KL}}\left(\pi^H(\cdot \mid s,g) \,\|\, p_s(\cdot)\right) \le \varepsilon.$$

$p_s(\cdot)$ — распределение состояний в среде.

Безопасная стратегия (SAC-LAG + HER)

$$J(\pi_\theta) = \mathbb{E}\big[Q_r^{\pi_\theta}(s,a,g) - \lambda Q_c^{\pi_\theta}(s,a,g) - \alpha D_{\mathrm{KL}}(\pi_\theta(\cdot \mid s,g) \,\|\, \pi_\theta(\cdot \mid s,s_g))\big].$$

Компонента для усиления исследования

$\pi_\theta(\cdot \mid s,g)$ — действие, направленное на конечную цель g;
$\pi_\theta(\cdot \mid s,s_g)$ — действие, направленное на подцель s_g.

- Q_r оценивает будущую награду, Q_c — будущие накопленные штрафы.

$$Q_r^{\pi_\theta}(s,a,g) = \mathbb{E}_{\pi_\theta}\left[\sum_{t=0}^{\infty}\gamma^t r_t\,\middle|\, s_0 = s, a_0 = a, g\right],$$

$$Q_c^{\pi_\theta}(s,a,g) = \mathbb{E}_{\pi_\theta}\left[\sum_{t=0}^{\infty}\gamma^t c_t\,\middle|\, s_0 = s, a_0 = a, g\right].$$

[1] RIS: Chane-Sane, Schmid, Laptev. Goal-conditioned reinforcement learning with imagined subgoals. ICML, 2021.

SG-Safe: эксперименты на POLAMP

SR — доля успешных эпизодов, CR — частота столкновений, Cost — средний накопленный штраф за эпизод. Красным выделены методы с привилегированной информацией и/или явными моделями. Среднее ± стандартное отклонение.

Level 1

Method	SR↑	CR↓	Cost↓
SG-Safe	**0.919 ± 0.009**	**0.025 ± 0.012**	1.567 ± 0.331
SAC-LAG	0.727 ± 0.011	0.029 ± 0.009	6.765 ± 2.954
SAC	0.610 ± 0.040	0.023 ± 0.014	11.252 ± 3.718
SAC-NCMP	0.427 ± 0.000	0.573 ± 0.000	**0.869 ± 0.015**
SAC-RCBF	0.344 ± 0.032	0.240 ± 0.025	4.456 ± 3.076
ADVICE	0.000 ± 0.000	0.031 ± 0.000	0.031 ± 0.000
L-RRT	0.551 ± 0.152	0.350 ± 0.028	8.335 ± 1.898

Level 2

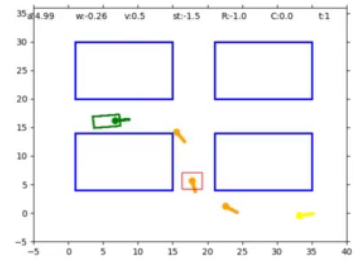
Method	SR↑	CR↓	Cost↓
SG-Safe	**0.875 ± 0.052**	**0.031 ± 0.017**	5.103 ± 2.632
SAC-LAG	0.000 ± 0.000	**0.004 ± 0.006**	1.319 ± 0.802
SAC	0.000 ± 0.000	0.010 ± 0.015	5.054 ± 2.325
SAC-NCMP	0.000 ± 0.000	1.000 ± 0.000	1.369 ± 0.020
SAC-RCBF	0.008 ± 0.010	0.050 ± 0.025	8.625 ± 1.823
ADVICE	0.000 ± 0.000	0.010 ± 0.000	**0.010 ± 0.000**
L-RRT	0.125 ± 0.050	0.664 ± 0.165	12.154 ± 4.167

Avg.

Method	SR↑	CR↓	Cost↓
SG-Safe	**0.897 ± 0.026**	0.028 ± 0.010	3.335 ± 1.327
SAC-LAG	0.364 ± 0.006	**0.017 ± 0.005**	4.042 ± 1.530
SAC	0.305 ± 0.020	**0.017 ± 0.010**	8.153 ± 2.192
SAC-NCMP	0.214 ± 0.000	0.787 ± 0.000	1.119 ± 0.012
SAC-RCBF	0.176 ± 0.017	0.145 ± 0.017	6.541 ± 1.788
ADVICE	0.000 ± 0.000	0.021 ± 0.000	**0.021 ± 0.000**
L-RRT	0.338 ± 0.080	0.507 ± 0.084	10.245 ± 2.289

Среда POLAMP

навигационная задача с большим горизонтом



ITES: иерархическая структура и функции потерь

Развитие иерархического безопасного обучения

В SG-Safe подцели направляют исследование, однако их безопасность явно не гарантируется. ITES решает более сильную задачу и контролирует безопасность всей иерархии: как при выборе промежуточных подцелей, так и при их достижении.

Иерархия

- $\pi^h_{\theta_h}(s_g \mid s,g)$ генерирует подцель;
- $\pi^l_{\theta_l}(a \mid s,s_g)$ достигает подцель.

Верхнеуровневый критик вознаграждения

$$Q^h_{\theta_{qh}}(s,s_g,g) = \mathbb{E}\left[\sum_{t=0}^{T}\gamma^t r_t \,\middle|\, s_0 = s,\, s_{g,0} = s_g,\, g\right].$$

Обучает эмбеддинги целей

$$\begin{aligned} L_{adj} = \mathbb{E}\big[& l\max(\|\psi(s_i) - \psi(s_j)\| - \epsilon, 0) \\ & + (1-l)\max(\epsilon + \delta \\ & - \|\psi(s_i) - \psi(s_j)\|, 0)\big]. \end{aligned}$$

Функция потерь HRAC

$$L^h = -Q^h_{\theta_{qh}}(s,s_g,g) + \beta^h_{adj} L_{adj}(s,s_g).$$

Q^h способствует максимизации вознаграждения от подцели для решения задачи.
Член L_{adj} способствует генерации подцелей ровно на k шагов вперед.

Безопасность на верхнем уровне: генерация безопасных подцелей

Задача

обеспечить безопасность $s_g \sim \pi^h_{\theta_h}(s_g \mid s, g)$.

Два сигнала безопасности

Модель штрафов возвращает вероятность того, что подцель находится в безопасном множестве:

$$C_M(s_g, s) = \Pr(s_g \in \mathcal{S}_{safe} \mid s) \in [0,1].$$

Верхнеуровневый критик штрафов оценивает ожидаемый дисконтированный накопленный штраф после выбора подцели:

$$Q^h_c(s, s_g, g) = \mathbb{E}\left[\sum_{t=0}^{T} \gamma_c^t c_t \,\middle|\, s_0 = s,\, s_{g,0} = s_g,\, g\right].$$

Функция потерь ITES на верхнем уровне

$$L^h = -Q^h_{\theta_{qh}}(s, s_g, g) + \beta^h_{adj} L_{adj}(s, s_g) + \boxed{-\beta^h_{safe} C_M(s_g, s) + \lambda Q^h_c(s, s_g, g)}.$$

Компоненты, отвечающие за безопасность

- C_M направляет подцель в безопасную область;
- Q^h_c учитывает безопасность достижения подцелей.

Безопасность на нижнем уровне: безопасное достижение подцелей

Проблема

Безопасная подцель не гарантирует безопасное достижение подцели.

Задача

обеспечить безопасность $a_i \sim \pi^l_{\theta_l}(a_i \mid s_i, s_g)$ для всех i до подцели.

M_{θ_m} — модель мира (имеет маленький размер).

Проверка в модели мира

1. стратегия выбирает действие $a_i \sim \pi^l_{\theta_l}(a_i \mid s_i, s_g)$;
2. модель мира предсказывает $s'_{i+1} = M_{\theta_m}(s_i, a_i)$;
3. $L_{\text{imagined}} = \sum_{i=1}^{n} C_M(\phi(s_i), s)$.

Функция потерь ITES на нижнем уровне

$$L^l = -Q^l_{\theta_{ql}}(s, a, s_g) + \boxed{-\beta^l_{safe} L_{\text{imagined}}}.$$

Компонент, отвечающий за безопасность

Задачи навигации и манипуляции с большим горизонтом

Итоговые результаты на SafeAntMaze и SafePusher. SAM-C — SafeAntMaze C-shape, SAM-W — SafeAntMaze W-shape, SR — доля успешных эпизодов. Методы с Cost $\leqslant d$ выделены зелёным, нарушающие — красным. Усреднение по 5 запускам.

SAM-C

Method	SR↑	Cost↓
ITES	**0.88 ± 0.01**	15.2 ± 17.3
SafeDreamer	0	13 ± 18.11
CUP	0	**6.8 ± 22.4**
FOCOPS	0	19.4 ± 50.9
TD3L/R	0.38 ± 0.04	83.6 ± 37.2
PPOLAG	0.2 ± 0.2	41.2 ± 1.1
TD3LAG	0.13 ± 0.33	133.45 ± 184.4

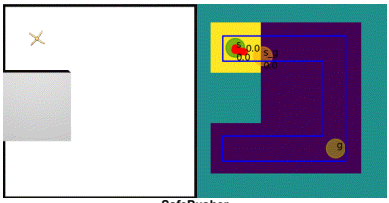
SAM-W

Method	SR↑	Cost↓
ITES	**0.35 ± 0.05**	183 ± 16.5
TD3L/R	0.05 ± 0.02	154 ± 13.5
CUP	0	**103.5 ± 21.5**
FOCOPS	0	141.0 ± 26.0
TD3LAG	0	128.68 ± 210
PPOLAG	0	105 ± 20.1
SafeDreamer	0	216.3 ± 199

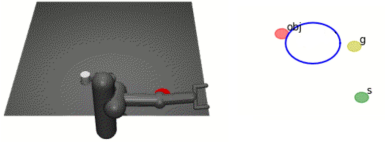
Pusher

Method	SR↑	Cost↓
ITES	**0.42 ± 0.02**	**12.8 ± 0.87**
SafeDreamer	0	6.7 ± 2.7
TD3LAG	0.05 ± 0.03	54.72 ± 3.16
CUP	0.01	46.14 ± 0.42
FOCOPS	0	55.83 ± 1.67
PPOLAG	0	51.25 ± 1.25

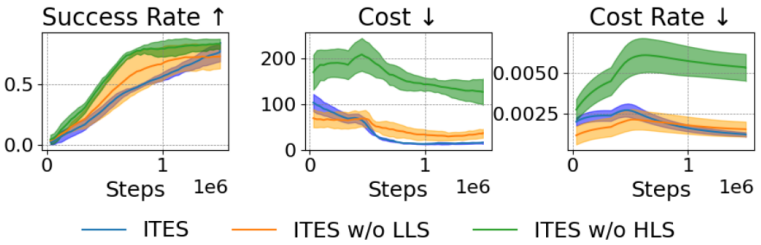
SafeAntMaze



SafePusher



ITES: абляция компонентов безопасности



Влияние безопасных подцелей на обучение

Отсутствие безопасности в подцелях приводит к такому же Success Rate, но гораздо большим нарушениям Cost (зелёный график).

Caged CrafText: цели и ограничения на естественном языке

Таблица 12. Таксономия задач Caged CrafText

Сценарий	Ограничение	M	DE	SE	R	LU
Budgetary	Maintain ≥ 5	✓	✓	✓		
	Maintain ≥ 5	✓	✓	✓		
	Maintain ≥ 5			✓		
	Maintain ≥ 5	✓	✓	✓	✓	
Sequential	Don't attack w/o		✓	✓	✓	
	Don't sleep nearby			✓	✓	
	When ≤ 4, avoid			✓	✓	
Mathematical	20 budget, -10 for killing	✓		✓	✓	
	50 budget, -10 for chopping	✓		✓	✓	
Relational	Avoid within 3 cells	✓		✓	✓	
	Find source of	✓	✓	✓		
	Find source of	✓	✓	✓		
Budgetary All		✓	✓	✓	✓	
Sequential All			✓	✓	✓	
Mathematical All		✓		✓	✓	
Relational All		✓	✓	✓	✓	
Caged		✓	✓	✓	✓	✓

M — память, DE — глубокое исследование, SE — безопасное исследование, R — рассуждение, LU — понимание языка.



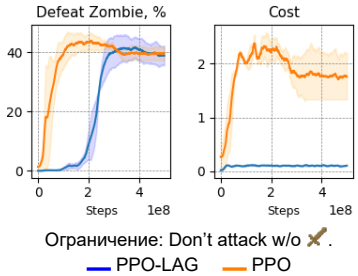
Четыре типа ограничений

- бюджетные;
- последовательные;
- математические;
- отношенческие.

Caged CrafText: сравнение базовых методов

$R \uparrow$ — эпизодическое вознаграждение, $C \downarrow$ — эпизодический штраф.

Набор задач	**PPO**		**PPO-LAG**		**PPO-Cost**		**LLM**	
	$R \uparrow$	$C \downarrow$	$R \uparrow$	$C \downarrow$	$R \uparrow$	$C \downarrow$	$R \uparrow$	$C \downarrow$
Budgetary All $(d = 0.1)$	0.23	11.38	0.05	0.36	0.11	**0.12**	0.19	40.1
Sequential All $(d = 0.1)$	**0.24**	7.65	0.05	1.02	0.08	**0.82**	0.19	22.7
Mathematical All $(d = 0.1)$	0.23	110.42	**0.24**	0.10	0.18	**0.05**	0.19	16.9
Relational All $(d = 10)$	**0.22**	31.36	0.11	11.69	0.04	**8.18**	0.18	15.2
Caged $(d = 0.1)$	**0.22**	103.66	0.03	0.17	0.14	**0.13**	0.20	43.4



Практическая значимость

- Метод SPEIS можно применять в робототехнических задачах с коротким горизонтом, например в задачах навигации в офисных помещениях.
- Методы SG-Safe и ITES могут быть применимы в задачах с большим горизонтом, в узких пространствах, например навигации в шахтах; ITES может быть применим для задач манипуляции роборукой, например на конвейерных лентах.
- Репозитории с открытым кодом: SPOWL[1], SG-Safe[2], ITES[3], CrafText[4], Caged CrafText[5].

[1] https://github.com/AIRI-Institute/SPOWL
[2] https://github.com/Gricha1/SPEIS
[3] https://github.com/Gricha1/ITES_alg
[4] https://github.com/AIRI-Institute/CrafText
[5] https://github.com/Gricha1/CAGED-CrafText

Публикации и апробация по теме диссертационной работы

Публикации по теме работы:

Основные результаты по теме диссертации изложены в 5 публикациях: 2 — в журналах категории К1 собственного перечня журналов МФТИ, 2 — в сборниках трудов конференций уровня A и A*, 1 — в виде препринта на arXiv.

- **SG-Safe** — журнал Technologies издательства MDPI, 2026, категория К1 перечня МФТИ, Q1;
- **Caged CrafText** — журнал Optical Memory and Neural Networks, 2026, категория К1;
- **SPOWL** — материалы ECAI 2025, конференция уровня A;
- **CrafText benchmark** — ACL 2025, конференция уровня A*;
- **ITES** — препринт arXiv:2606.22509, 2026.

Апробация результатов:

Основные результаты диссертационной работы докладывались и обсуждались на:

- международной конференции European Conference on Artificial Intelligence, ECAI 2025 (метод SPOWL);
- конференции Fall into ML 2025;
- междисциплинарной конференции по искусственному интеллекту «ИИ-АЗАМАН 2025»;
- семинарах Центра когнитивного моделирования МФТИ (2023–2025).

Основные выводы

1. Для безопасного исследования в методах безопасного обучения с подкреплением необходимо учитывать будущие накопленные штрафы.
2. Генерация подцелей позволяет улучшать исследование методов безопасного обучения с подкреплением.
3. При помощи модели мира и моделей штрафов можно обеспечить безопасность как подцелей, так и их достижения в решении задач с большим горизонтом.
4. Caged CrafText выявляет ограничения современных методов при одновременном выполнении языковой инструкции и соблюдении текстового ограничения.

Спасибо за внимание!

Вопросы

Горбов Григорий Владиславович
МФТИ, 2026

SG-Safe: время генерации действий при инференсе

POLAMP (Level 1). PT — время планирования, ET — время генерации действия при инференсе (action generation time).

Method	PT↓, s	ET↓, s
SG-Safe	0	$9 \cdot 10^{-3}$
ITES	–	$1.8 \cdot 10^{-2}$
L-RRT	10.4	$9 \cdot 10^{-3}$
SPOWL	–	$4.0 \cdot 10^{-2}$