Федеральное государственное автономное образовательное учреждение
высшего образования «Московский физико-технический институт
(национальный исследовательский университет)»

На правах рукописи

Горбов Григорий Владиславович

Методы и алгоритмы безопасного обучения с подкреплением в робототехнических задачах

Специальность 1.2.1 —
«Искусственный интеллект и машинное обучение»

Диссертация на соискание учёной степени
кандидата технических наук

Научный руководитель:
доктор физико-математических наук, профессор РАН
Панов Александр Игоревич

Долгопрудный — 2026

Оглавление

Стр.

Введение 5

Глава 1. Безопасное обучение с подкреплением: методы, ограничения и среды оценки 14

1.1 Теоретические основы безопасного обучения с подкреплением . . . 15

1.2 Методы оптимизации стратегии с ограничениями 18

1.3 Ограничение небезопасных действий при управлении агентом . . . 20

1.4 Методы безопасного обучения на основе моделей мира 22

1.5 Иерархическое обучение с подкреплением и задачи с большим горизонтом 25

1.6 Безопасное иерархическое обучение с подкреплением 26

1.7 Мультимодальные агенты и естественно-языковые инструкции . . . 28

1.7.1 Бенчмарки безопасного обучения с подкреплением 29

1.7.2 Бенчмарки с естественно-языковыми ограничениями 31

1.8 Бенчмарки, используемые в диссертационной работе 34

1.9 Метрики оценки безопасного исследования, используемые в диссертационной работе 38

1.10 Выводы по главе 39

Глава 2. Использование моделей мира для оценки будущих накопленных штрафов в безопасном обучении с подкреплением 41

2.1 Оценка будущих накопленных штрафов в модели мира SPOWL . . 41

2.1.1 Неявная модель мира 42

2.1.2 Обучение функции оценки будущих накопленных штрафов 44

2.1.3 Оценка безопасности кандидатных траекторий 45

2.1.4 Агрегация ансамбля функций оценки будущих накопленных штрафов 47

2.2 Экспериментальная проверка метода SPOWL и исследование оценки накопленных штрафов 48

2.2.1 Сравнение с базовыми методами 49

Стр.

2.2.2 Сравнение локальных и глобальных оценок штрафов 51
2.2.3 Сравнение способов агрегации ансамбля функций оценки будущих накопленных штрафов 53
2.2.4 Влияние размера ансамбля и размера подвыборки 54
2.3 Выводы по главе 56

Глава 3. Решение проблемы безопасного исследования с помощью иерархической структуры 57
3.1 Метод SG-Safe 58
3.1.1 Безопасная стратегия метода SG-Safe 59
3.1.2 Стратегия, генерирующая подцели 60
3.1.3 Обновление безопасной стратегии с применением подцелей 61
3.2 Экспериментальная проверка метода SG-Safe 63
3.2.1 Улучшение безопасного исследования 65
3.2.2 Сравнение с методами, использующими априорную информацию 66
3.2.3 Сравнение с базовыми методами 68
3.2.4 Анализ компонент метода 73
3.3 Выводы по главе 76

Глава 4. Развитие иерархического безопасного обучения с подкреплением с использованием модели мира 78
4.1 Метод ITES 78
4.1.1 Безопасность на верхнем уровне: генерация безопасных подцелей 80
4.1.2 Безопасность на нижнем уровне: безопасное достижение подцелей 82
4.1.3 Практическая реализация 84
4.2 Экспериментальная проверка метода ITES 86
4.2.1 Сравнение ITES с базовыми методами на задачах с большим горизонтом 88
4.2.2 Сравнение ITES с базовыми методами на задачах с коротким горизонтом 89

Стр.

4.2.3 Абляционное исследование: влияние компонент ITES на безопасность . . . 92
4.3 Выводы по главе . . . 93

Глава 5. Переход к мультимодальной безопасности в задачах с естественно-языковыми целями и ограничениями . . . 95
5.1 Бенчмарк Caged CrafText . . . 95
5.1.1 Сценарии . . . 96
5.1.2 Настройка среды . . . 98
5.1.3 Уровни датасета . . . 99
5.2 Сравнение методов в среде Caged CrafText . . . 100
5.2.1 Базовые методы . . . 100
5.2.2 Сравнение базовых методов . . . 101
5.2.3 Проблема безопасного исследования . . . 103
5.2.4 Абляционный анализ безопасного поведения . . . 106
5.2.5 Подходы на основе больших языковых моделей . . . 107
5.3 Выводы по главе . . . 108

Заключение . . . 110

Словарь терминов . . . 113

Список литературы . . . 115

Список рисунков . . . 125

Список таблиц . . . 130

Введение

Искусственный интеллект (ИИ) всё шире применяется в робототехнических задачах, где роботу необходимо принимать решения в процессе взаимодействия со средой. Обычно обучение таких систем проводится на заранее собранных данных или в симуляторах. Однако при переносе обученной стратегии (policy) в реальные условия робот может столкнуться с ситуациями, которые не были учтены заранее, либо с проблемой переноса из симуляции в реальность (sim-to-real). Решением обеих проблем является дообучение робота непосредственно в реальных условиях [1].

Методы обучения с подкреплением (Reinforcement Learning, RL) являются одним из перспективных подходов к такому дообучению [2; 3]. В этих методах агент (робот) обучается методом проб и ошибок: он получает вознаграждение за действия, которые приближают его к желаемому поведению. Важной частью обучения является исследование среды, в ходе которого агенту необходимо обнаружить оптимальную последовательность действий, а затем использовать её для решения поставленной задачи. Однако в реальных условиях исследование не может быть произвольным: действия робота могут нанести вред людям, окружающей среде или самой робототехнической системе. Поэтому агент должен не только исследовать среду в поиске полезных действий, но и делать это безопасно. Эту задачу рассматривает область безопасного обучения с подкреплением (Safe Reinforcement Learning, Safe RL) [4; 5].

В безопасном обучении с подкреплением, помимо вознаграждения, вводится штраф, который численно описывает нарушения ограничений безопасности [4]. В результате агент должен решать двойственную задачу: достигать цели и одновременно соблюдать ограничения. Например, робот должен не только прийти в заданную точку, но и не сталкиваться с препятствиями, не превышать скорость или снижать её рядом с людьми.

Существующие подходы решают эту проблему по-разному. Методы на основе функции лагранжиана применимы к широкому классу сред, но обычно не обеспечивают строгих гарантий безопасности [6—8]. Методы на основе барьерных функций и других механизмов фильтрации действий могут давать более строгий контроль поведения, однако часто требуют знания модели объекта управления, явного вида функции штрафов и её дифференцируемости [9—13]. Эти

требования ограничивают их применение в сложных робототехнических задачах, где полная информация о среде и точная модель динамики часто недоступны.

Одним из способов уменьшить число небезопасных взаимодействий является использование моделей мира [2; 3]. В таких подходах, помимо стратегии агента, обучается модель, предсказывающая будущие состояния среды при выполнении заданных действий, что позволяет генерировать дополнительный синтетический опыт, а также осуществлять планирование в рамках модели мира. Однако безопасное исследование в таких методах зависит от того, насколько корректно модель мира оценивает безопасность состояний [14—18].

Дополнительные трудности возникают в задачах с большим горизонтом, которые характеризуются разреженным вознаграждением, высокой размерностью пространства состояний и действий, а также большим количеством шагов. Соответственно, агенту необходимо выполнять длинную последовательность действий, чтобы получить полезный сигнал для обучения. Одним из способов справиться с этой проблемой является иерархическое обучение с подкреплением [19—21]. В таких методах верхнеуровневая стратегия выбирает промежуточные подцели или навыки, а низкоуровневая стратегия отвечает за их достижение [22—24]. Это позволяет разбить исходную задачу на более короткие подзадачи и направить исследование агента к достижению конечной цели [25—27].

Объединение моделей мира и иерархического обучения с подкреплением позволяет использовать оба преимущества одновременно: декомпозицию поведения на промежуточные подцели и предварительную оценку риска их достижения [28]. Такой подход особенно важен в навигационных и робототехнических задачах, где одноуровневые безопасные стратегии часто становятся чрезмерно консервативными или не достигают цели.

При переходе от симуляционных задач к взаимодействию с человеком возникает ещё одна проблема: цели и правила поведения часто задаются не в виде явной функции штрафа, а на естественном языке [29—35]. В этом случае агенту необходимо связать текстовое ограничение с объектами, состояниями среды и допустимыми последовательностями действий. Поэтому методы, ориентированные только на заранее заданные численные штрафы, не покрывают весь класс задач, возникающих при использовании автономных агентов в человеко-ориентированных средах. Для проверки таких методов требуются среды, где

языковая инструкция влияет не только на цель, но и на допустимость поведения агента [36; 37].

Таким образом, актуальность данной работы определяется тремя связанными проблемами. Во-первых, в задачах безопасного обучения важно заранее оценивать долгосрочные последствия действий: короткий горизонт планирования может не выявлять будущие нарушения безопасности, а ошибки в оценке нарушений приводят либо к небезопасным траекториям, либо к чрезмерно осторожному поведению. Во-вторых, безопасная стратегия должна сохранять способность к исследованию среды в постановках с большим горизонтом, а не сводить поведение к избеганию любых потенциально рискованных действий. В-третьих, для более реалистичных постановок необходимо учитывать ограничения, заданные не только численно, но и на естественном языке.

Целью данной работы является исследование и разработка методов безопасного обучения с подкреплением, которые используют модели мира и иерархическую структуру поведения для повышения эффективности исследования среды при соблюдении ограничений безопасности в робототехнических задачах.

Для достижения поставленной цели необходимо было решить следующие **задачи**:

1. Провести анализ существующих методов безопасного обучения с подкреплением и сред, используемых для их экспериментальной оценки.
2. Разработать подход для учёта долгосрочного риска в методах безопасного обучения с подкреплением на основе модели мира.
3. Разработать метод иерархического обучения с подкреплением, направленный на уменьшение консервативности безопасной стратегии и повышение её способности к исследованию среды.
4. Разработать метод генерации безопасных подцелей с использованием модели мира для обеспечения безопасности как у верхнеуровневой стратегии, так и у низкоуровневой для решения робототехнических задач с большим горизонтом.
5. Разработать бенчмарк для обучения методов безопасного обучения с подкреплением и для оценки их способностей к пониманию задачи и ограничений, заданных при помощи естественного языка.

Научная новизна:

1. В рамках метода SPOWL (Safe Planning and Policy Optimization via World Model Learning, безопасное планирование и оптимизация стратегии с

использованием модели мира) предложена функция оценки будущих накопленных штрафов в рамках модели мира для улучшения скрытых представлений, а также для более точной оценки безопасности траекторий при планировании. Эксперименты на средах Safety Gym показали лучшую производительность и безопасность по сравнению с предыдущими методами безопасного обучения с подкреплением.

2. Разработан метод SG-Safe (Enhancing Safe Exploration Through Subgoal Guidance) для улучшения исследовательских способностей безопасных стратегий за счёт направления исследования через промежуточные подцели. На этапе исполнения используется только безопасная стратегия. Метод показывает лучшее качество в среде POLAMP в сравнении с методами безопасного обучения с подкреплением и методами на основе классического планирования.
3. Разработан метод ITES (Imagine to Ensure Safety in Hierarchical Reinforcement Learning) для генерации безопасных подцелей в задачах с большим горизонтом, использующий модель мира для обеспечения безопасного достижения этих подцелей. Метод достигает лучшего качества в задачах навигации и манипуляции с большим горизонтом в сравнении с методами на основе моделей мира в безопасном обучении с подкреплением.
4. Разработан бенчмарк Caged CrafText (Caged CrafText: Language-Grounded Safety Constraints for Multimodal Reinforcement Learning in CrafText) для оценки способностей к пониманию языка, связывания языка с объектами из среды, памяти, безопасного исследования. Предложенный бенчмарк позволяет как обучать, так и оценивать методы безопасного обучения с подкреплением в сложной динамической среде.

Теоретическая значимость. В работе показано, что в задачах с большим горизонтом у нынешних методов безопасного обучения с подкреплением ухудшается способность к исследованию, и что такая проблема решается с помощью иерархического обучения с подкреплением в методах SG-Safe и ITES.

Показано, что безопасное исследование в методах обучения с подкреплением на основе модели мира зависит от корректной оценки моделью мира нарушений на сгенерированных траекториях. Недооценка будущих штрафов приводит к небезопасному исследованию, а переоценка — к чрезмерно консервативному поведению агента.

Caged CrafText позволяет обучать и оценивать методы безопасного обучения с подкреплением в задачах, где цель и ограничения заданы на естественном языке. Разделение задач на бюджетные, последовательные, математические и отношенческие ограничения позволяет оценивать разные аспекты поведения агента: понимание инструкции, связывание текста с объектами и состояниями среды, память, долгосрочное планирование и безопасное исследование.

Практическая значимость заключается в возможности применения разработанных методов для робототехнических платформ, где требуется заданный уровень безопасности и производительности, особенно для задач, требующих большого количества действий от робота, в том числе для адаптивного обучения робота в реальных условиях.

Компоненты метода SPOWL, отвечающие за оценку будущих накопленных штрафов действий, могут быть применены в робототехнических задачах безопасного исследования, где агент должен заранее оценивать риск кандидатных действий до их выполнения в реальной среде. Это позволяет уменьшить число небезопасных действий при обучении и одновременно избежать чрезмерно консервативного поведения агента.

Разработанные методы SG-Safe и ITES, направленные на улучшение исследовательских способностей безопасной стратегии при помощи иерархического обучения, могут быть применены для адаптации мобильных роботов к новым условиям эксплуатации, например в задачах автономной инспекции промышленных объектов, патрулирования охраняемых территорий, обследования аварийных зон, навигации в шахтах и других труднодоступных пространствах, где требуется исследовать среду при ограничении числа небезопасных действий.

Методология и методы исследования. Для оптимизации стратегий использовались методы актор-критик, включая метод оптимизации ближайшей стратегии (Proximal Policy Optimization, PPO) и метод мягкого актор-критика (Soft Actor-Critic, SAC), а также методы на основе функции лагранжиана для учёта ограничений безопасности. Для формализации задач применялись марковские процессы принятия решений с ограничениями (CMDP). В качестве одного из базовых методов сравнения рассматривался SafeDreamer, основанный на архитектуре DreamerV3 и использующий модель мира для планирования с учётом ограничений безопасности. Для оценки предложенных методов проводились численные эксперименты в симуляционных средах безопасного обучения с подкреплением. Основными метриками выступали эпизодическое вознагра-

дение (Reward), эпизодические штрафы (Cost), успешность выполнения задачи (Success Rate). Программная реализация выполнялась на языке Python 3 с использованием JAX и PyTorch. В качестве основного программного интерфейса для симуляционных сред использовались Gymnasium и Safety Gymnasium, а также собственные реализации сред для отдельных экспериментов. Эксперименты проводились на графических ускорителях NVIDIA RTX-серии и NVIDIA H100. Логирование результатов экспериментов выполнялось с использованием Comet ML, а визуализация и анализ результатов — с использованием Matplotlib и стандартных инструментов обработки численных данных. Репозитории с открытым кодом: SPOWL[1], SG-Safe[2], ITES[3], CrafText[4], Caged CrafText[5].

Основные положения, выносимые на защиту:

1. Способ построения и агрегации функций оценки будущих накопленных штрафов в модели мира для безопасного исследования в рамках модели SPOWL. Показано, что устойчивое безопасное исследование в обучении с подкреплением на основе модели мира требует оценки не только мгновенных штрафов, но и оценки будущих накопленных штрафов.
2. Метод SG-Safe для безопасного иерархического обучения с подкреплением, использующий генерацию промежуточных подцелей для улучшения исследовательских способностей безопасной стратегии. Метод позволяет повысить успешность решения навигационных задач с большим горизонтом при сохранении контролируемого уровня нарушений безопасности.
3. Метод ITES для безопасного исследования с использованием иерархической структуры и модели мира, в котором высокоуровневая стратегия генерирует безопасные подцели, а низкоуровневая стратегия использует модель мира и модель штрафов для безопасного достижения этих подцелей. Метод позволяет контролировать безопасность как на уровне выбора подцелей, так и на уровне исполнения действий.
4. Бенчмарк Caged CrafText для оценки и обучения методов безопасного обучения с подкреплением с естественно-языковыми целями и ограничениями, позволяющий анализировать способность агентов понимать

[1] https://github.com/AIRI-Institute/SPOWL
[2] https://github.com/Gricha1/SPEIS
[3] https://github.com/Gricha1/ITES_alg
[4] https://github.com/AIRI-Institute/CrafText
[5] https://github.com/Gricha1/CAGED-CrafText

задачи и ограничения, заданные на естественном языке, и соблюдать их в сложной динамической среде.

Достоверность результатов обеспечивается многократным проведением экспериментов, использованием общепринятых симуляционных сред и сравнением с современными базовыми методами. Достоверность подтверждается также абляционными исследованиями, апробацией результатов на научных семинарах и конференциях, а также публикациями в рецензируемых научных изданиях.

Апробация работы. Основные результаты диссертационной работы докладывались и обсуждались на:

- семинарах Центра когнитивного моделирования МФТИ (2023, 2024, 2025);
- международной конференции European Conference on Artificial Intelligence, ECAI 2025;
- конференции Fall into ML 2025;
- междисциплинарной конференции по искусственному интеллекту «ИИ-АЗАМАН 2025».

Полученные результаты и знания использовались в преподавании курсов по искусственному интеллекту:

- курс «Продвинутые методы машинного обучения с подкреплением» (МФТИ, 2026): разработка и проведение практических занятий;
- курс «Обучение с подкреплением» (Центр «ПУСК», 2025): разработка и проведение практических и лекционных занятий;
- курс «Обучение с подкреплением (углубленный курс)» (ФКН ВШЭ, 2026): проведение лекции и семинара по безопасному обучению с подкреплением.

Публикации. Основные результаты по теме диссертации изложены в 5 публикациях: 2 — в журналах категории К1 собственного перечня журналов МФТИ [38; 39], 2 — в сборниках трудов конференций уровня A и A* [40; 41], 1 — в виде препринта на arXiv [28].

Личный вклад. В работе по SPOWL [40] автор предложил функцию оценки будущих накопленных штрафов в рамках модели мира для улучшения скрытых представлений и более точной оценки безопасности траекторий при планировании, а также способ агрегации её в ансамбле. В частности, автор провёл экспериментальный анализ способов агрегации ансамбля функций оценки будущих накопленных штрафов и влияния размера ансамбля на баланс между

эффективностью и безопасностью агента. Показано, что корректная ансамблевая оценка будущих накопленных штрафов является необходимым условием безопасного исследования: недооценка риска приводит к нарушениям ограничений, а переоценка риска — к консервативному поведению и снижению целевой эффективности.

В работе по SG-Safe [38] автор разработал метод безопасного иерархического обучения с подкреплением, направленный на улучшение исследовательских способностей безопасной стратегии за счёт генерации промежуточных подцелей, а также провёл экспериментальную проверку метода на навигационных задачах с большим горизонтом.

В работе по ITES [28] автор разработал метод, использующий модель мира и модель штрафов для генерации безопасных подцелей и безопасного достижения этих подцелей низкоуровневой стратегией.

В работе по CrafText Benchmark [41] автор участвовал в разработке задач для оценки способности агента следовать естественно-языковым инструкциям в сложной динамической среде. В частности, были сформированы навигационные и пространственные задачи, связанные с локализацией объектов, выбором направления движения и размещением объектов относительно элементов карты.

В работе [39] разработан и протестирован бенчмарк Caged CrafText для оценки агентов безопасного обучения с подкреплением в задачах с естественно-языковыми целями и ограничениями. Сформированы типы ограничений, наборы задач для обучения и тестирования, а также протокол оценки агентов. Проведено экспериментальное сравнение базовых алгоритмов и проанализированы их ограничения при одновременном выполнении языковой инструкции и соблюдении текстового ограничения безопасности в динамической среде.

Во всех указанных работах автор участвовал в обсуждении экспериментальных результатов, их интерпретации и формулировке выводов.

Содержание диссертации соответствует специальности 1.2.1. Искусственный интеллект и машинное обучение:

– формализация и постановка задач управления и (поддержки) принятия решений на основе систем искусственного интеллекта и машинного обучения; разработка систем управления с использованием систем искусственного интеллекта и методов машинного обучения, в том числе управления роботами, автомобилями, БПЛА и т.п.;

- разработка специализированного математического, алгоритмического и программного обеспечения систем искусственного интеллекта и машинного обучения; методы и средства взаимодействия систем искусственного интеллекта с другими системами и человеком-оператором;
- исследования в области «доверенных» систем класса ИИ, включая проблемы формирования тестовых выборок прецедентов, надёжности, устойчивости, переобучения и т.д.;
- методы и технологии поиска, приобретения и использования знаний и закономерностей, в том числе эмпирических, в системах искусственного интеллекта; исследования в области совместного применения методов машинного обучения и классического математического моделирования; методы и средства использования экспертных знаний.

Объем и структура работы. Диссертация состоит из введения, 5 глав и заключения. Полный объём диссертации составляет 132 страницы, включая 30 рисунков и 14 таблиц. Список литературы содержит 96 наименований.

Глава 1. Безопасное обучение с подкреплением: методы, ограничения и среды оценки

В данной главе рассматриваются основные подходы к безопасному обучению с подкреплением и их применимость к задачам автономных интеллектуальных агентов. В таких задачах агент должен не только достигать цели и получать высокую награду, но и соблюдать ограничения безопасности. Нарушениями могут считаться столкновения с препятствиями, попадание в опасные области, превышение допустимого риска, повреждение объектов среды или несоблюдение правил, заданных пользователем.

Основная сложность безопасного обучения связана с исследованием среды. Чтобы найти оптимальную стратегию, агенту необходимо пробовать разные действия и посещать новые состояния. При этом именно исследование чаще всего приводит к нарушениям безопасности, особенно в начале обучения, когда агент ещё неточно оценивает последствия своих действий. Эта проблема становится более выраженной в задачах с редкой наградой (sparse reward), большим горизонтом планирования (long horizon), частичной наблюдаемостью (partial observability) и сложной динамикой среды.

Существующие методы решают эту проблему по-разному. Методы оптимизации стратегии с ограничениями включают штрафы за нарушение безопасности (cost) непосредственно в задачу обучения. Их преимущество состоит в том, что они не требуют известной модели объекта управления, явного вида функции штрафов или её дифференцируемости. Такие методы могут быть применены к произвольным задачам. Однако такие методы не предоставляют строгих теоретических гарантий безопасности, а только эмпирические гарантии.

Другой класс подходов связан с безопасным управлением и фильтрацией действий. В этих методах поведение агента дополнительно контролируется на этапе исполнения: небезопасные действия могут блокироваться или заменяться на безопасные. Такой подход удобен, когда ограничения заданы явно и доступна достаточно точная информация о состоянии системы. Однако в более сложных средах он часто требует полной наблюдаемости, дифференцируемой функции штрафов, явного вида функции штрафов или дополнительной оптимизации на каждом шаге.

Отдельное направление образуют методы на основе моделей мира. В них агент использует модель среды для предварительной оценки последствий своих действий, построения воображаемых траекторий и снижения числа небезопасных взаимодействий с реальной средой. При этом качество безопасного поведения зависит от того, насколько точно модель оценивает будущие состояния и связанные с ними штрафы. Недооценка безопасности будущих состояний может приводить к нарушению ограничений во время исследования.

Для решения задач с большим горизонтом обычно применяются методы иерархического обучения с подкреплением. Такие методы позволяют разбить исходную задачу на более короткие подзадачи при помощи подцелей или навыков. Тем не менее такие методы не учитывают ограничения по безопасности: как подцели, так и траектории, ведущие к ним, могут нарушать эти ограничения.

В реальных сценариях не всегда можно представить ограничение в виде явной математической функции. Ограничение может зависеть от объектов сцены, порядка действий, контекста или отношений между объектами. Поэтому для оценки безопасных агентов требуются среды, в которых проверяется не только способность достигать цели, но и способность понимать ограничения, заданные на естественном языке.

Далее в главе рассматриваются теоретические основы безопасного обучения с подкреплением, методы оптимизации стратегии с ограничениями, подходы к фильтрации действий, методы на основе моделей мира, иерархическое безопасное обучение, а также бенчмарки для оценки агентов с численными и естественно-языковыми ограничениями.

1.1 Теоретические основы безопасного обучения с подкреплением

Классическое обучение с подкреплением рассматривает взаимодействие агента со средой как марковский процесс принятия решений:

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, P, R, \rho_0, \gamma \rangle, \tag{1.1}$$

где $\mathcal{S}$ обозначает пространство состояний, $\mathcal{A}$ — пространство действий, $P(s' \mid s,a)$ — функцию переходов, $R(s,a)$ — функцию награды, ρ_0 — распределение начальных состояний, а $\gamma \in [0,1)$ — коэффициент дисконтирования. Агент задаётся

стратегией $\pi(a \mid s)$ и стремится максимизировать ожидаемую дисконтированную награду:

$$J_R(\pi) = \mathbb{E}_{\tau\sim\pi}\left[\sum_{t=0}^{T}\gamma^t r(s_t,a_t)\right]. \tag{1.2}$$

В задачах безопасного обучения с подкреплением, в том числе в Safety Gym [7], рассматривается проблема безопасного исследования, которая формулируется математически через марковский процесс принятия решений с ограничениями:

$$\mathcal{M}_c = \langle \mathcal{S}, \mathcal{A}, P, R, C, \rho_0, \gamma, \gamma_c, d\rangle, \tag{1.3}$$

где C — функция штрафа, γ_c — коэффициент дисконтирования для штрафов, а d — допустимый бюджет нарушений. Целью агента является решение задачи:

$$\pi^* = \arg\max_{\pi} J_R(\pi), \quad \text{при условии } J_C(\pi) \leqslant d, \tag{1.4}$$

где

$$J_C(\pi) = \mathbb{E}_{\tau\sim\pi}\left[\sum_{t=0}^{T}\gamma_c^t c(s_t,a_t)\right]. \tag{1.5}$$

Постановка CMDP является удобной, поскольку позволяет описывать компромисс между достижением цели и соблюдением ограничений в единой математической форме [4].

В современных методах глубокого обучения с подкреплением стратегия и функции полезности обычно аппроксимируются нейронными сетями. Наиболее распространённой является архитектура актор-критик. В такой архитектуре актор $\pi_\theta(a \mid s)$ задаёт стратегию агента, то есть распределение действий в каждом состоянии, а критик оценивает ожидаемую полезность состояния или пары состояние–действие.

В классическом обучении с подкреплением критик вознаграждений оценивает ожидаемое дисконтированное вознаграждение:

$$V_r^{\pi_\theta}(s) = \mathbb{E}_{\pi_\theta}\left[\sum_{t=0}^{T}\gamma^t r_t \mid s_0 = s\right], \tag{1.6}$$

или, в варианте для пар состояние–действие,

$$Q_r^{\pi_\theta}(s,a) = \mathbb{E}_{\pi_\theta}\left[\sum_{t=0}^{T}\gamma^t r_t \mid s_0 = s, a_0 = a\right]. \tag{1.7}$$

Такая функция используется для оценки того, насколько выбранное действие полезно с точки зрения достижения цели.

В безопасном обучении с подкреплением аналогично вводится критик штрафов, оценивающий ожидаемые накопленные штрафы:

$$V_c^{\pi_\theta}(s) = \mathbb{E}_{\pi_\theta}\left[\sum_{t=0}^{T} \gamma_c^t c_t \mid s_0 = s\right], \tag{1.8}$$

или

$$Q_c^{\pi_\theta}(s,a) = \mathbb{E}_{\pi_\theta}\left[\sum_{t=0}^{T} \gamma_c^t c_t \mid s_0 = s, a_0 = a\right]. \tag{1.9}$$

Таким образом, критик вознаграждений оценивает будущее вознаграждение, а критик штрафов — будущие нарушения ограничений безопасности. Это разделение важно, поскольку действие может быть полезным с точки зрения достижения цели, но одновременно рискованным с точки зрения будущих штрафов.

Критики обычно обучаются по принципу временных разностей (Temporal-Difference, TD). Для критика вознаграждений TD-ошибка имеет вид:

$$\delta_t^R = r_t + \gamma V_r^{\pi_\theta}(s_{t+1}) - V_r^{\pi_\theta}(s_t), \tag{1.10}$$

а для критика штрафов:

$$\delta_t^C = c_t + \gamma_c V_c^{\pi_\theta}(s_{t+1}) - V_c^{\pi_\theta}(s_t). \tag{1.11}$$

Соответственно, параметры критиков обновляются так, чтобы уменьшать квадратичную ошибку этих оценок:

$$\mathcal{L}_R = \mathbb{E}\left[(\delta_t^R)^2\right], \qquad \mathcal{L}_C = \mathbb{E}\left[(\delta_t^C)^2\right]. \tag{1.12}$$

Для Q-критиков целевые значения строятся аналогично, но вместо $V(s_{t+1})$ используется оценка полезности следующей пары состояние–действие.

Оценки критиков затем используются для обновления актора. В обычном обучении актор усиливает действия, которые имеют высокое ожидаемое вознаграждение. В безопасном обучении обновление стратегии должно учитывать оба сигнала: увеличить ожидаемое вознаграждение и одновременно не превысить допустимый бюджет нарушений. В лагранжевой форме это часто записывается как оптимизация выражения вида

$$Q_r^{\pi_\theta}(s,a) - \lambda Q_c^{\pi_\theta}(s,a), \tag{1.13}$$

где λ — множитель, задающий относительную важность ограничения безопасности. При большом значении λ стратегия сильнее штрафуется за действия, ведущие к нарушениям, а при малом значении λ больше ориентируется на достижение вознаграждения.

Такая схема лежит в основе многих современных методов безопасного обучения с подкреплением. Актор отвечает за выбор действий, критик вознаграждений оценивает их полезность для достижения цели, а критик штрафов оценивает риск будущих нарушений. Поэтому качество обучения безопасной стратегии во многом зависит не только от самой функции штрафов, но и от того, насколько точно критик штрафов предсказывает долгосрочные накопленные штрафы поведения агента.

Таким образом, центральная проблема безопасного обучения с подкреплением заключается в необходимости совместить два противоречивых требования: достаточно активное исследование среды и ограничение числа небезопасных действий. Эта проблема далее называется проблемой безопасного исследования.

1.2 Методы оптимизации стратегии с ограничениями

Один из основных классов методов безопасного обучения с подкреплением связан с прямой оптимизацией стратегии при наличии ограничений. В такой постановке агент должен максимизировать ожидаемую награду, но при этом удерживать ожидаемые штрафы ниже заданного порога [4; 5].

К числу первых методов этого типа относится метод оптимизации стратегии с ограничениями (Constrained Policy Optimization, CPO) [42]. Его можно рассматривать как расширение метода оптимизации стратегии в доверительной области (Trust Region Policy Optimization, TRPO) на задачи с ограничениями безопасности. Как и TRPO, CPO ограничивает изменение стратегии с помощью доверительной области, но дополнительно вводит ограничение на ожидаемый накопленный штраф. Поэтому новая стратегия должна не только улучшать ожидаемую награду, но и оставаться в пределах заданного допустимого бюджета нарушений. Вычислительно CPO наследует сложность TRPO: обновление требует работы с матрицей Фишера, или гессианом KL-дивергенции, обычно через метод сопряжённых градиентов. Из-за этого обновление стратегии оказывается

более дорогим, что затрудняет масштабирование метода на большие непрерывные пространства состояний и действий.

Дальнейшее развитие этого направления связано с попытками сохранить идею ограниченного обновления стратегии, но избежать вычислительной сложности CPO. К этому относятся метод проекции обновления с ограничениями (Constrained Update Projection, CUP) [43] и метод оптимизации первого порядка с ограничениями в пространстве стратегий (First Order Constrained Optimization in Policy Space, FOCOPS) [44], которые можно рассматривать как более практичные варианты безопасной оптимизации стратегии, в которых обновление выполняется с использованием методов первого порядка, без явной работы с гессианом KL-дивергенции или матрицей Фишера. В CUP обновление стратегии разделяется на два этапа. На первом этапе выполняется промежуточное градиентное обновление, направленное на увеличение ожидаемой награды. На втором этапе полученная стратегия проецируется на множество стратегий, удовлетворяющих ограничению безопасности. В FOCOPS эти два шага объединяются в одну процедуру: метод сначала выводит безопасное обновление в пространстве политик, учитывающее как преимущество по награде, так и преимущество по штрафам, а затем приближает это обновление параметризованной стратегией с помощью обычной градиентной оптимизации.

Более простым и часто используемым подходом являются методы на основе функции лагранжиана. В них ограничение на штраф включается в целевую функцию с помощью множителя Лагранжа. В результате задача с ограничениями заменяется оптимизацией лагранжиана:

$$\mathcal{L}(\pi,\lambda) = J_R(\pi) - \lambda(J_C(\pi) - d), \tag{1.14}$$

где $\lambda \geqslant 0$ — множитель Лагранжа. Если стратегия превышает заданный бюджет, значение λ увеличивается, и штраф за нарушение становится сильнее. Если ограничение выполняется с запасом, λ уменьшается, позволяя стратегии больше ориентироваться на увеличение награды.

Главное преимущество методов на основе функции лагранжиана состоит в том, что они легко встраиваются в уже существующие алгоритмы обучения с подкреплением. К этому направлению относятся PPO-Lagrangian, TRPO-Lagrangian, TD3-Lagrangian и SAC-Lagrangian [6—8]. Такие методы не требуют известной априорной информации.

В SAUTE RL [45] оставшийся бюджет штрафов добавляется в состояние агента, после чего исходная задача с ограничениями сводится к обычному обучению с подкреплением в расширенном пространстве состояний. Метод автоматической функции штрафов (AutoCost) [46] рассматривает отдельную проблему — автоматическое построение функции штрафов, поскольку во многих задачах тяжело или невозможно задать математически функцию штрафов.

Общее ограничение этих методов состоит в том, что безопасность в них задаётся через ожидаемые накопленные штрафы. Такая постановка позволяет регулировать средний уровень нарушений, но не гарантирует безопасность каждого отдельного действия. Агент может нарушать ограничения на ранних этапах обучения или в состояниях, которые редко встречались во время обучения. Для методов на основе функции лагранжиана дополнительно возникает проблема устойчивости двойственной оптимизации: значение множителя Лагранжа чувствительно к шуму в оценке штрафов, текущей стратегии и относительному масштабу награды и штрафа.

1.3 Ограничение небезопасных действий при управлении агентом

В этой группе методов безопасность обеспечивается не только за счёт обучения стратегии, но и за счёт дополнительной проверки действия перед его выполнением. Если выбранное действие нарушает ограничение, оно может быть отклонено, изменено или заменено на ближайшее допустимое действие.

К этому направлению относятся слои безопасности (Safe Layer), методы экранирования (Shielding), методы на основе барьерных функций (CBF-based) и методы на основе функций Ляпунова [5; 9—11]. Слой безопасности обычно решает вспомогательную задачу оптимизации: найти действие, наиболее близкое к действию стратегии, но удовлетворяющее локальному ограничению безопасности. Методы на основе барьерных функций и функций Ляпунова формулируют безопасность через специальные функции состояния, которые ограничивают допустимые переходы системы и позволяют получать более строгий контроль поведения.

Достоинство таких методов состоит в том, что они могут делать каждое действие безопасным. Если известна модель объекта управления, фильтр

может предотвращать опасные действия независимо от ошибок обучаемой стратегии. Поэтому такие методы особенно естественны для робототехники, где часто доступны модели объекта управления, ограничения на управление или геометрическое описание опасных областей.

Однако эта же особенность ограничивает применимость методов фильтрации. Во многих задачах безопасного обучения агент не имеет точной модели объекта управления, полной информации о состоянии среды или аналитически заданной функции штрафов. Кроме того, методы на основе барьерных функций и слоёв безопасности часто требуют дифференцируемой функции штрафов и решения задачи оптимизации на каждом шаге управления. Это увеличивает вычислительные требования для генерации каждого действия и затрудняет применение таких методов в сложных, частично наблюдаемых и стохастических средах.

При использовании экранов безопасность задаётся явно: действие стратегии проверяется перед выполнением и при необходимости заменяется допустимым. В дискретных задачах такой экран часто строится по формальному описанию поведения, например с помощью темпоральной логики, автоматов или заранее заданных спецификаций безопасности [12; 13].

Часть более поздних работ пытается уменьшить зависимость от ручного задания правил. Например, в методе на основе советов (ADVICE) [47] экран строится не на основе аналитической модели динамики, а по данным о переходах между состояниями. В этом методе обучается модель эмбеддингов для переходов (состояние, действие). Обучение проводится с использованием контрастивной функции потерь (contrastive learning), при которой представления переходов (состояние, действие), которые не нарушают ограничения, сближаются в латентном пространстве, а представления переходов, нарушающих ограничения, отделяются от них. Далее для оценки каждого действия, предложенного стратегией, используются K ближайших представлений в латентном пространстве; в случае, если действие нарушает ограничение, используется ближайшее дискретизированное действие. Такой подход не требует априорной информации о среде, но перестаёт давать более строгие теоретические гарантии безопасности действий.

Таким образом, методы оптимизации стратегии с ограничениями могут быть применимы на произвольных средах, но не дают строгих гарантий того, что каждое действие будет безопасным. Методы фильтрации и безопасного управ-

ления дают более строгие гарантии безопасности каждого действия, но часто требуют сильных предположений о среде.

1.4 Методы безопасного обучения на основе моделей мира

Несмотря на развитие методов обучения с подкреплением без модели мира, их применение в задачах с жёсткими ограничениями остаётся затруднённым. Основная причина состоит в том, что такие методы требуют большого числа непосредственных взаимодействий со средой. В безопасном обучении это особенно критично: на ранних этапах агент действует методом проб и ошибок, поэтому увеличение числа обучающих эпизодов обычно сопровождается ростом числа нарушений ограничений безопасности. В результате даже алгоритмы, учитывающие ограничения в процессе оптимизации стратегии, могут накапливать значительные штрафы во время обучения.

Одним из способов уменьшить число небезопасных взаимодействий является использование моделей мира. Методы обучения с подкреплением на основе модели мира строят приближённую модель динамики среды, которая предсказывает последствия действий агента. Такая модель может использоваться для генерации синтетического опыта, обновления стратегии по воображаемым траекториям или предварительной оценки действий перед их выполнением в реальной среде [2; 3]. В задачах безопасного обучения модель мира особенно важна, поскольку позволяет заранее оценивать не только ожидаемую награду, но и будущий накопленный штраф кандидатных действий.

С точки зрения использования модели мира можно выделить два основных направления. В первом случае модель применяется непосредственно при выборе действия: агент рассматривает несколько кандидатных последовательностей действий, оценивает их в модели мира и выполняет первое действие из выбранной последовательности. К этому направлению относятся методы на основе управления с прогнозирующей моделью и планирования с ограничениями [11; 14; 48—50]. Во втором случае модель используется для генерации синтетических траекторий и обновления стратегии без обязательного планирования на каждом шаге [15; 51; 52].

В работах по безопасному планированию на основе модели мира естественным образом используется идея выбора траектории не только по награде, но и по штрафам. Например, метод перекрёстной энтропии с ограничениями (cross-entropy method, CCEM) [50] модифицирует метод кросс-энтропии для постановки с ограничениями: на каждой итерации генерируются кандидатные последовательности действий, после чего траектории с недопустимым накопленным штрафом исключаются из элитного множества.

Аналогичная идея используется в методе обучения с подкреплением на основе модели мира с методом кросс-энтропии (Model-Based Reinforcement Learning with Cross-Entropy Method, MBRCE) [49]. В этом методе поиск действий также строится на основе CEM, но дополнительно применяется ансамбль моделей мира. Это позволяет учитывать неопределённость предсказаний и делать выбор действий менее зависимым от ошибки одной модели. При этом ограничение остаётся общим для этого класса подходов: если модель неточно предсказывает будущий накопленный штраф или если опасные последствия выходят за выбранный горизонт планирования, метод может неверно оценить безопасность кандидатной траектории.

Другая группа работ использует модель мира для обновления стратегии. Метод оптимизации ближайшей стратегии с лагранжевой релаксацией ограничений на основе модели мира (Model-Based Proximal Policy Optimization Lagrangian, MBPPO-Lag) [15] расширяет PPO-Lagrangian синтетическими траекториями, полученными из ансамбля моделей мира. Метод на основе функции лагранжиана и байесовской модели мира (Lagrangian Model-Based Reinforcement Learning with Bayesian World Models, LAMBDA) [16] использует байесовскую модель мира для оценки неопределённости предсказаний модели мира, стратегия оптимизируется так, чтобы использовать оптимистичные оценки вознаграждения и одновременно пессимистичные оценки нарушений ограничения по безопасности. Метод безопасного обучения с латентной стохастической моделью актор-критик (Safe Stochastic Latent Actor-Critic, Safe SLAC) [17] переносит безопасное обучение с подкреплением на случай пиксельных наблюдений: SLAC обучает компактное стохастическое скрытое состояние из изображений, а Safe SLAC дополнительно предсказывает нарушения безопасности и использует критик штрафов для обучения безопасной стратегии. Эти методы показывают, что модели мира могут повышать эффективность безопасного обучения, однако часто не используют модель мира для непосредственного безопасного планирования действий.

Существенное влияние на развитие обучения с подкреплением на основе модели оказали метод на основе скрытой модели динамики и воображаемых траекторий (Dreamer) и метод управления на основе модели мира с применением временных разностей (Temporal Difference Model Predictive Control, TD-MPC). Dreamer обучает скрытую модель динамики и использует воображаемые траектории для оптимизации поведения [51; 53]. TD-MPC и TD-MPC2 используют неявные модели мира и совмещают планирование в скрытом пространстве с функциями оценки полезности [54; 55]. Эти подходы показали высокую эффективность в задачах непрерывного управления, но в исходном виде не предназначены для соблюдения ограничений безопасности.

К этому классу методов относится SafeDreamer [18], который развивает идеи DreamerV3 и объединяет лагранжевую оптимизацию, планирование при выборе действия и обучение по воображаемым траекториям. В отличие от ряда предыдущих методов, SafeDreamer поддерживает как низкоразмерные, так и визуальные наблюдения, использует модель мира для безопасного планирования и обучает стратегию с учётом ограничений. Такой подход показывает сильные результаты в задачах Safety Gymnasium [56]. Однако архитектуры семейства Dreamer могут быть вычислительно тяжёлыми, а планирование в модели мира остаётся ограниченным коротким горизонтом.

Тем не менее в нынешних методах обучения с подкреплением остаётся проблема с оценкой будущих потенциальных нарушений при выборе действий. Если модель недооценивает риск, агент может выбирать небезопасные траектории, поскольку опасные последствия не всегда проявляются в пределах короткого горизонта планирования. Если модель переоценивает риск, агент становится чрезмерно осторожным и прекращает активное исследование среды [3; 57].

Отдельную роль играет неопределённость модели. Модель мира обучается по конечному набору данных и может ошибаться в областях состояния, которые агент редко посещал. Поэтому в безопасном обучении с подкреплением на основе модели мира часто используются ансамбли моделей или функций штрафов [15; 16; 49]. Ансамблевые оценки позволяют уменьшить влияние ошибок отдельной модели, однако выбор способа агрегации становится самостоятельной проблемой. Оптимистичная агрегация может приводить к недооценке риска, а чрезмерно пессимистичная — к избыточно осторожному поведению.

1.5 Иерархическое обучение с подкреплением и задачи с большим горизонтом

Иерархическое обучение с подкреплением рассматривает задачу принятия решений на нескольких уровнях абстракции. В общем виде иерархический агент включает верхнеуровневую стратегию и одну или несколько низкоуровневых стратегий. Верхнеуровневая стратегия (high-level policy) выбирает абстрактное действие: навык или подцель. Низкоуровневая стратегия (low-level policy) исполняет это решение в течение нескольких шагов и выдаёт примитивные действия в среду. За счёт этого возникает временная абстракция: одно решение верхнего уровня соответствует нескольким действиям нижнего уровня. Такая структура особенно полезна в задачах с редкой наградой, где одной стратегии трудно случайно обнаружить оптимальную последовательность действий [19].

В литературе можно выделить два распространённых способа задания высокоуровневых действий. Первый способ основан на навыках или опциях. Опция задаётся стратегией выполнения, условием начала и условием завершения. В этом случае верхнеуровневая стратегия выбирает, какой навык следует активировать, а выбранный навык некоторое время управляет агентом. К этому направлению относятся классические работы по опциям [20], а также методы, обучающие опции совместно с основной стратегией, например критик навыков (Option-Critic) [21]. Преимущество такого подхода состоит в том, что навыки могут представлять переиспользуемые фрагменты поведения. Однако в задачах с редкой наградой обучение полезных навыков без заранее заданной структуры может быть затруднено, если отсутствует дополнительный сигнал о том, какие навыки должны быть сформированы.

Второй способ основан на подцелях. В этом случае верхнеуровневая стратегия выбирает подцель, заданную в виде координат, картинки, текстового описания или эмбеддинга, а низкоуровневая стратегия обучается достигать выбранную подцель. Метод иерархического актора-критика (Hierarchical Actor-Critic, HAC) [22], метод эффективного иерархического обучения с подкреплением (Data-Efficient Hierarchical Reinforcement Learning, HiRO) [23] и метод иерархического обучения с k-шаговым ограничением смежности (Hierarchical Reinforcement Learning with k-step Adjacency Constraint, HRAC) [24] используют такую структуру для разбиения исходной задачи на более короткие подзадачи. Верхний уровень работает на

более грубой временной шкале и выбирает подцели, а нижний уровень действует чаще и решает локальную задачу достижения заданной подцели.

Одной из ключевых проблем иерархического обучения является нестационарность. Пока низкоуровневая стратегия обучается, её способность достигать подцелей меняется. Поэтому один и тот же выбор верхнего уровня может приводить к разным фактическим переходам в разные моменты обучения. Метод HiRO решает эту проблему с помощью коррекции (off-policy correction) [23]. Метод HAC также использует переобозначение подцелей и позволяет строить многоуровневую иерархию [22].

Другой важной проблемой является достижимость подцелей. Если верхнеуровневая стратегия выбирает подцели, которые нижний уровень не может достичь, обучение становится нестабильным, а собранный опыт плохо соответствует задаче верхнего уровня. В HRAC для ограничения пространства подцелей используется информация о смежности состояний: подцели выбираются так, чтобы они были достижимы низкоуровневой стратегией за ограниченное число шагов [24]. Тем самым уменьшается вероятность выбора недостижимых подцелей и повышается устойчивость обучения.

Несмотря на эффективность иерархической декомпозиции в задачах с большим горизонтом, классические методы иерархического обучения обычно не учитывают требования безопасности. Они предполагают, что достижимая подцель является допустимой, либо полагаются на тщательно заданную функцию награды. В безопасном обучении такого предположения уже недостаточно. Подцель может быть достижима с точки зрения динамики среды, но путь к ней может проходить через опасную область или приводить к накоплению большого штрафа. Поэтому в безопасной постановке важно различать два свойства подцели: может ли агент её достичь и может ли он сделать это без нарушения ограничений безопасности.

1.6 Безопасное иерархическое обучение с подкреплением

Нынешние методы, которые рассматривают связь безопасного и иерархического обучения с подкреплением, рассматривают задачи только с коротким горизонтом. Тем не менее в таких задачах показано, что такие методы могут улуч-

шать итоговую долю решения задач за счёт разбиения задачи на подцели или навыки.

Подцель может быть достижима для низкоуровневой стратегии, но путь к ней может проходить через опасную область или давать слишком большой накопленный штраф. Поэтому в безопасной иерархической постановке нужно оценивать не только достижимость подцели, но и безопасность траектории, по которой агент будет её достигать.

Область безопасного иерархического обучения с подкреплением остаётся крайне малоизученной. В литературе можно выделить три основных метода: SafetyLayer + HiRO [25], метод планирования при помощи случайных деревьев с контроллером на основе функции Ляпунова (Lyapunov Rapidly-exploring Random Tree, LyapunovRRT) [26] и метод интегрированного адаптивного иерархического обучения с подкреплением (Integrated Adaptive Hierarchical Reinforcement Learning, IAHRL) [27]. Эти методы используют иерархическую структуру для решения задач с большим горизонтом, но различаются способом обеспечения безопасности и требованиями к информации о среде.

Метод SafetyLayer + HiRO [25] объединяет иерархическую стратегию HiRO с дополнительным слоем безопасности. Верхнеуровневая стратегия задаёт подцели, а низкоуровневая стратегия выбирает действия для их достижения. Каждое действие заменяется с помощью слоя безопасности на допустимое. Такой подход может уменьшать число нарушений безопасности, однако требует явного вида функции штрафов, её дифференцируемости, а также дополнительного решения задачи квадратичного программирования при генерации действий. Кроме того, метод не предлагает механизма для обеспечения безопасности подцелей: верхний уровень может требовать от нижнего уровня вход в небезопасную область, что приводит к локальному минимуму.

Метод планирования при помощи случайных деревьев с контроллером на основе функции Ляпунова (Lyapunov Rapidly-exploring Random Tree, LyapunovRRT) [26] использует планирование RRT* вместе с контроллером на основе функций Ляпунова. В такой схеме планировщик строит путь между состояниями, а механизм экранирования на основе функции Ляпунова выбирает промежуточные подцели так, чтобы агент двигался к цели и при этом не сталкивался с препятствиями. Иными словами, безопасность обеспечивается не только выбором конечной цели, но и контролем промежуточных переходов вдоль траектории. Этот подход может быть применим в ситуациях, когда известны

расположения всех препятствий в среде, их размеры (bounding box), а также размеры самого агента.

Метод интегрированного адаптивного иерархического обучения с подкреплением (Integrated Adaptive Hierarchical Reinforcement Learning, IAHRL) [27] рассматривает задачу безопасного беспилотного вождения и использует иерархическую структуру с заранее заданными опциями. В такой постановке опции соответствуют типовым элементам поведения автомобиля: обгону, перестроению или движению по выбранной полосе. Поэтому верхнеуровневой стратегии проще выбирать между уже подготовленными вариантами действий, чем обучать всю структуру поведения без заранее заданных опций. Это ускоряет обучение и делает исследование более направленным в рассматриваемом домене. Однако такое преимущество связано с ручным проектированием структуры поведения: набор опций подбирается заранее именно для задачи вождения. Поэтому при переходе к другой среде или другому типу робота метод может потребовать повторной разработки набора навыков.

В таблице 1 приведено сравнение основных подходов области безопасного обучения с подкреплением с подходом SG-Safe, разработанным автором и описанным в третьей главе. Сравнение проводится по критериям, которые важны для рассматриваемой постановки: требуется ли явный вид функции штрафов, требуется ли дифференцируемость функции штрафов, требуется ли фильтрация действий на базе безопасности, требуются ли заранее заданные навыки, способность решать задачи с большим горизонтом.

1.7 Мультимодальные агенты и естественно-языковые инструкции

Современные автономные агенты всё чаще рассматриваются не только как системы управления, но и как системы, взаимодействующие с человеком через естественный язык. В таких задачах агент должен понимать текстовую инструкцию, сопоставлять её с объектами и состояниями среды, а затем выбирать действия, приводящие к выполнению инструкции. Это направление связано с языковым связыванием (language grounding), воплощённым ИИ (embodied AI) и мультимодальным обучением с подкреплением.

Таблица 1 — Сравнение методов безопасного обучения с подкреплением. EC — не требуется явный вид функции штрафов; DC — не требуется дифференцируемость функции штрафов; RC — не требуется фильтрация действий на базе безопасности; NS — не требуются заранее заданные навыки; LH — способность решать задачи с большим горизонтом.

Method	EC	DC	RC	NS	LH
Lagrangian-based methods [6—8]	✓	✓	✓	✓	×
CPO [42]	✓	✓	✓	✓	×
CUP [43]	✓	✓	✓	✓	×
FOCOPS [44]	✓	✓	✓	✓	×
SafeDreamer [18]	✓	✓	✓	✓	×
Safety Layer [9]	×	×	×	✓	×
CBF-based [10]	×	×	×	✓	×
Shielding [12; 13]	×	✓	×	✓	×
ADVICE [47]	✓	✓	×	✓	×
SafetyLayer + HiRO [25]	×	×	×	✓	✓
LyapunovRRT [26]	×	×	×	✓	✓
IAHRL [27]	✓	✓	✓	×	✓
SG-Safe [38]	✓	✓	✓	✓	✓

1.7.1 Бенчмарки безопасного обучения с подкреплением

Развитие безопасного обучения с подкреплением во многом определяется наличием бенчмарков, позволяющих сравнивать методы в воспроизводимых условиях. В прикладных задачах обучение с подкреплением используется в управлении транспортом, робототехнике, энергетике, автономных системах и других областях, где ошибки агента могут приводить к существенным негативным последствиям [58—61]. Поэтому для безопасного обучения с подкреплением важны среды, в которых можно одновременно оценивать достижение цели и соблюдение ограничений безопасности.

Ранние среды для исследования безопасности часто строились на простых дискретных задачах. Примером являются AI Safety Gridworlds [62], где рассматривается задача, связанная с внешним отключением агента. В этой задаче агент должен пройти к цели через область, где с некоторой вероятностью его движение может быть остановлено внешним оператором до конца эпизода.

Также рассматриваются устойчивость к сдвигу распределения и предотвращение нежелательного поведения. Такие среды удобны для анализа отдельных свойств алгоритмов, однако они имеют упрощённую динамику, дискретное пространство состояний и действий, а также слабо отражают сложности реальных задач управления.

Другой класс бенчмарков возник как развитие уже существующих сред навигации. Например, в MiniGrid [63] и его безопасных модификациях ограничения обычно задаются через опасные клетки, области или объекты, попадание в которые приводит к штрафу [64; 65]. Такая постановка удобна для отладки алгоритмов: в ней легко контролировать структуру среды, сложность маршрута и расположение опасных зон. Однако по сравнению с задачами непрерывного управления она остаётся существенно упрощённой. Действия агента дискретны, пространство наблюдений имеет простую структуру, а сама задача чаще всего сводится к безопасному прохождению двумерной карты.

Для непрерывного управления одним из наиболее часто используемых бенчмарков стал Safety Gym [7]. В нём задачи формулируются для агентов с различной морфологией, включая Point, Car, Ant и Doggo. Агенту требуется достигать целевых объектов, одновременно избегая опасных зон, ваз, кнопок и других элементов среды, связанных со штрафами.

Позднее этот набор задач был расширен в Safety Gymnasium [56]. В нём сохранена общая идея Safety Gym, но добавлены новые агенты, сценарии и варианты постановки задачи, в том числе для многоагентного безопасного обучения. Это сделало бенчмарк более разнообразным. Большая часть задач по-прежнему связана с навигацией к цели при избегании заранее заданных опасных объектов. Кроме того, безопасность задаётся фиксированной численной функцией штрафов, тогда как в реальных задачах требования к поведению агента могут меняться от сценария к сценарию и задаваться в менее формализованной форме.

Отдельное направление связано с безопасным управлением в робототехнических и физических симуляторах. Safe-Control-Gym [66] включает задачи управления cartpole и quadrotor с возмущениями динамики и ориентирован на проверку методов безопасного управления и sim-to-real переноса. RWRL [67] добавляет ограничения и возмущения в действия, наблюдения и физические параметры для робототехнических задач. Safe MAMuJoCo, Safe MARobosuite и Safe MAIG [68] предназначены для безопасного многоагентного обучения и робототехнического управления.

Для автономного вождения и навигации применяются симуляторы CARLA [69], TORCS [70] и MetaDrive [71]. В таких средах безопасность обычно учитывается через штрафы за столкновения, выезд за пределы полосы или другие нежелательные события [72—74]. Эти бенчмарки позволяют моделировать более реалистичные сценарии движения, однако они ориентированы на конкретные прикладные домены и не всегда удобны для систематического анализа общих алгоритмов безопасного обучения с подкреплением.

Более современным примером является HASARD [75], построенный на основе ViZDoom [76] с использованием Sample-Factory [77]. В отличие от многих предыдущих бенчмарков, HASARD ориентирован на безопасное обучение с эгоцентричным визуальным наблюдением в трёхмерной стохастической среде. Он включает несколько уровней сложности, частичную наблюдаемость и задачи, требующие навигации, распознавания целей и предсказания движения объектов. Однако HASARD, как и большинство бенчмарков безопасного обучения с подкреплением, не проверяет способность агента понимать естественно-языковые инструкции и ограничения.

Таким образом, существующие бенчмарки безопасного обучения с подкреплением можно условно разделить на несколько групп: простые двумерные среды для анализа отдельных аспектов безопасности, среды непрерывного управления типа Safety Gym, робототехнические и физические симуляторы, а также визуальные 3D-среды. Несмотря на различия, большинство из них задаёт безопасность через фиксированную функцию штрафов. Такая постановка удобна для классического безопасного обучения с подкреплением, но ограничивает переход к задачам, где человек задаёт цель и ограничения в форме естественного языка.

1.7.2 Бенчмарки с естественно-языковыми ограничениями

Переход от фиксированных численных ограничений к естественно-языковым инструкциям существенно усложняет задачу безопасного обучения с подкреплением. В мультимодальной постановке цель задаётся текстовой инструкцией I_g. Для безопасного обучения с естественно-языковыми ограничениями вводится дополнительная инструкция I_c, задающая правило безопасности. Тогда полная инструкция имеет вид $I = (I_g, I_c)$, где I_g задаёт целевую задачу, а I_c

задаёт ограничение. В этом случае агент должен сопоставить текст с объектами, действиями и состояниями среды. Стратегия должна учитывать оба компонента:

$$a_t \sim \pi(a_t \mid o_t, I_g, I_c), \tag{1.15}$$

где o_t — наблюдение агента.

Такая постановка отличается как от классического безопасного обучения с подкреплением, так и от стандартного следования инструкциям (instruction following). В обычном безопасном обучении с подкреплением ограничения, как правило, задаются в математической или логической форме, например через функцию штрафов или логическое правило [78; 79]. Это требует экспертного задания ограничений и затрудняет использование таких систем конечными пользователями. Естественный язык, напротив, является более доступным способом задания ограничений: человек может сформулировать правило вида “не заходи в опасную область до выполнения другого действия” без явного задания соответствующей формулы штрафов. В задачах следования инструкциям (instruction following) инструкция обычно задаёт, что агент должен сделать, и тем самым непосредственно определяет целевое поведение [29; 80—84]. В безопасном обучении с языковыми ограничениями агенту необходимо решать задачу с ограничениями: текстовое правило задаёт, чего агент не должен делать, оставаясь ортогональным функции вознаграждения, поэтому агент должен самостоятельно искать поведение, максимизирующее награду, но при этом соблюдать заданное текстовое ограничение.

Смежное направление связано с навигацией по визуальному входу и языковым командам и воплощённым ИИ (embodied AI), где агент должен выполнять навигационные инструкции в визуальной или трёхмерной среде [30—35]. Эти работы важны для связывания естественного языка и наблюдений среды, однако в большинстве таких постановок язык используется для задания цели, а не для задания ограничений по безопасности.

Одной из первых работ, рассматривающих безопасное обучение с естественно-языковыми ограничениями, является HAZARDWORLD [36]. Этот бенчмарк включает две группы сред: HAZARD WORLD grid на основе MiniGrid [85] и HAZARD WORLD robot на основе Safety Gym [7].

В HAZARDWORLD ограничения различаются не только по текстовой формулировке, но и по тому, какая информация требуется агенту для их соблюдения.

В простейшем случае правило задаёт допустимый бюджет нарушений: например, агент может ограниченное число раз заходить в опасную область. В более сложном варианте опасность определяется не самой клеткой или объектом, а отношением между объектами среды, например расстоянием до заданного препятствия. Наконец, в последовательных ограничениях безопасность зависит от предыдущих действий агента: одно и то же состояние может быть допустимым или запрещённым в зависимости от того, какие объекты агент уже посетил. Поэтому такие задачи проверяют не только распознавание текущего наблюдения, но и способность учитывать историю взаимодействия со средой.

При этом HAZARDWORLD во многом наследует ограничения сред, на которых он построен. Версия на основе MiniGrid остаётся дискретной и сравнительно простой по динамике. Версия на основе Safety Gym ближе к задачам непрерывного управления, но основная структура задачи по-прежнему сводится к навигации с избеганием опасных объектов. Кроме того, в HAZARDWORLD естественный язык в первую очередь используется для задания ограничения, тогда как цель часто задаётся через структуру среды, координаты или функцию вознаграждения. Поэтому такая постановка не полностью отражает сценарий, в котором пользователь формулирует на естественном языке и целевую задачу, и правило безопасности.

Бенчмарк Caged CrafText, рассматриваемый далее в диссертации, направлен на преодоление этих ограничений. В отличие от HAZARDWORLD и подходов с отдельной проверкой траектории [37], он использует более сложную, стохастическую и недетерминированную среду Crafter, в которой агент должен добывать ресурсы, создавать предметы и планировать длинные последовательности действий. При этом как цель, так и ограничение задаются на естественном языке. Это требует от агента не только безопасного поведения, но и понимания инструкции, долгосрочного планирования и рассуждения о правилах, зависящих от контекста и истории взаимодействия со средой.

Таким образом, развитие бенчмарков показывает переход от классического безопасного обучения с подкреплением с фиксированными численными функциями штрафов к постановкам, где ограничения задаются естественным языком. Такой переход важен для автономных агентов, взаимодействующих с человеком: в реальных сценариях пользователь чаще задаёт правила в текстовой форме, а не в виде математической функции штрафов. Поэтому бенчмарки с естественно-языковыми целями и ограничениями необходимы для оценки агентов, которые

должны одновременно понимать инструкции, планировать действия и соблюдать явно заданные правила безопасности.

1.8 Бенчмарки, используемые в диссертационной работе

В диссертационной работе используются несколько групп экспериментальных сред, позволяющих проверить три аспекта безопасного обучения с подкреплением: способность решать задачи с большим горизонтом, способность решать задачи с коротким горизонтом, способность к безопасному исследованию.

Среды с большим горизонтом. Для оценки способности методов решать задачи с большим горизонтом используются SafeAntMaze, SafePusher и POLAMP.

SafeAntMaze является вариантом MuJoCo AntMaze с добавленными ограничениями безопасности. В этой среде многозвенный робот Ant должен перемещаться по C-образному или W-образному лабиринту при частичной наблюдаемости. Наблюдения включают координаты, углы сочленений и скорости агента, $\mathcal{S} \subset \mathbb{R}^{30}$. Агент управляется непрерывными действиями, соответствующими моментам в сочленениях, $\mathcal{A} \subset \mathbb{R}^{8}$. Вознаграждение связано с продвижением агента к целевой области. Штраф $+1$ начисляется, если агент находится на расстоянии меньше заданного порога от стен. Для C-образного лабиринта используется ограничение на накопленные штрафы $d = 25$, для W-образного лабиринта — $d = 200$. Эпизоды завершаются после 500 шагов. Пример среды SafeAntMaze и схемы C-образного и W-образного лабиринтов приведены на рис. 1.1.

SafePusher является безопасной модификацией задачи MuJoCo Pusher. В этой среде роботизированная рука должна переместить объект в целевую область, используя непрерывное управление моментами, $\mathcal{A} \subset \mathbb{R}^{7}$. Наблюдения $\mathcal{S} \subset \mathbb{R}^{24}$ включают состояния сочленений, координаты конечной точки роботизированной руки, координаты объекта для манипуляции и координаты цели. Вознаграждение определяется качеством перемещения объекта к целевой области. Среда относится к задачам с большим горизонтом из-за высокой размерности управления, контактной динамики и необходимости согласовывать движение робота с перемещением объекта. Для SafePusher используется ограничение на накопленные штрафы $d = 25$, а длина эпизода составляет 100 шагов. Пример среды SafePusher приведён на рис. 1.2.

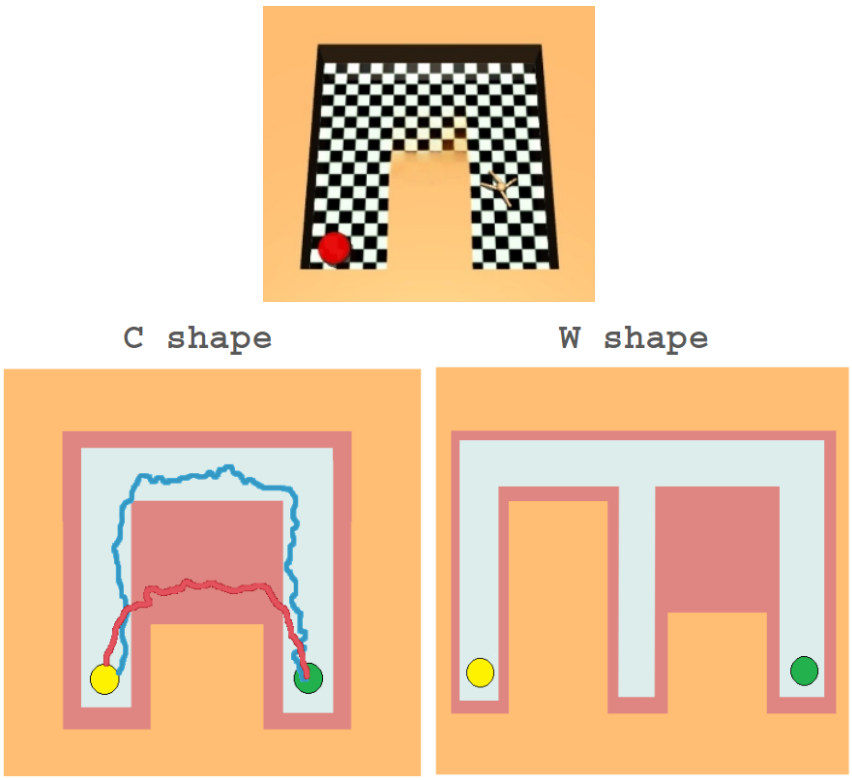


Рисунок 1.1 — Среда SafeAntMaze. Сверху показана визуализация SafeAntMazeCshape, где робот Ant должен решить задачу с большим горизонтом и достичь заданной цели. Снизу приведены схемы C-образного лабиринта слева и W-образного лабиринта справа. Зелёная точка обозначает начальное положение Ant, жёлтая точка — целевое положение, светлая область — безопасную зону, розовая область — опасную зону, в которой агент получает штраф $+1$ за каждый шаг, а оранжевая область — статическое препятствие. Красная траектория соответствует алгоритму HRAC, не учитывающему безопасность, а синяя траектория соответствует алгоритму ITES.

POLAMP [86] является навигационным бенчмарком для проверки безопасного исследования в средах с препятствиями и узкими коридорами. В нём агент с кинематической моделью велосипеда должен перемещаться между статическими препятствиями, находя путь к цели и избегая опасного сближения со стенами. Управление осуществляется непрерывными действиями: линейным ускорением и угловой скоростью (a_t, ω_t). Наблюдение агента включает 39-лучевой лидар с обзором 360° и максимальной дальностью 10 м, а также внутреннее состояние робота $(x, y, \theta, v, \gamma)$. Вознаграждение формируется на основе евклидова расстояния до цели. Штраф начисляется, если агент приближается к стене ближе чем на 0.3 м. В работе используются два набора задач различной сложности: Level 1 и

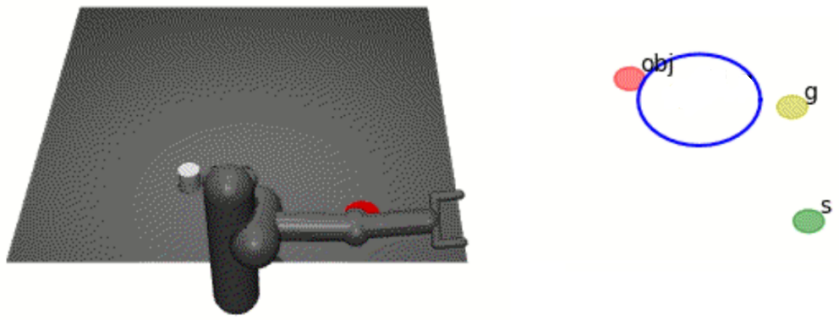


Рисунок 1.2 — Среда SafePusher. Слева показана визуализация MuJoCo: роботизированный манипулятор обозначен чёрным цветом, белый объект является перемещаемым объектом, а красный маркер указывает его целевое положение. Справа приведена схема среды сверху: красный круг обозначает объект для манипуляции, зелёный круг — положение конечной точки манипулятора, жёлтый круг — целевое положение объекта, а синяя зона — опасную область. Агент получает штраф $+1$ за каждый шаг, в течение которого объект находится внутри опасной зоны.

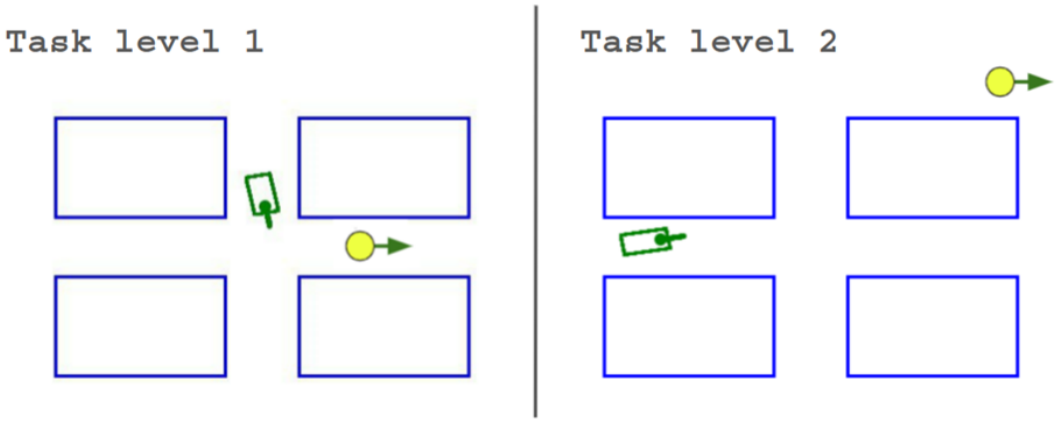


Рисунок 1.3 — Примеры навигационных задач в бенчмарке POLAMP. Начальное положение и ориентация агента показаны зелёным прямоугольником, целевое положение — жёлтым кругом. Слева показан пример задачи Level 1, где требуется не более одного изменения направления движения. Справа показан пример задачи Level 2, где агенту необходимо выполнить два точных поворота в узких коридорах.

Level 2. Каждый уровень включает 96 уникальных задач. Примеры навигационных шаблонов POLAMP приведены на рис. 1.3.

Среды с коротким горизонтом. Для оценки безопасного планирования и контроля штрафов используются задачи из семейств Safety Gym [7] и Safety Gymnasium [56]. Эти бенчмарки предназначены для задач навигации, где агент



Рисунок 1.4 — Примеры тел роботов в бенчмарке Safety Gym: Sweeps, Point, Car и Doggo.

должен достигать целевой области или взаимодействовать с объектами среды, одновременно избегая опасных зон и других источников штрафов. Пространство действий в этих средах является непрерывным, а наблюдения включают собственное состояние робота и дополнительные признаки задачи, например информацию о цели, опасных зонах и объектах среды.

В работе рассматриваются задачи Goal, Push и Button. В задаче Goal агент должен достичь целевой области, избегая опасных зон. В задаче Push агент должен переместить объект в заданную область. В задаче Button агент должен активировать целевую кнопку, не нарушая ограничения безопасности. Также используются разные типы тел агента: Point, Car, Doggo и Ant. Кроме того, в Safety Gym также используется тело Sweeps, которое представляет собой более простой роботизированный агент для навигационных задач. Point имеет 12-мерное собственное наблюдение и 2-мерное действие; Car — 24-мерное собственное наблюдение и 2-мерное действие; Doggo — 12-мерное собственное наблюдение и 12-мерное действие; Ant — 40-мерное собственное наблюдение и 8-мерное действие. Полная размерность наблюдения зависит от конкретной задачи, поскольку к собственным наблюдениям робота добавляются признаки целей, опасных зон и других объектов среды.

Примеры тел роботов, используемых в Safety Gym, показаны на рис. 1.4.

В задачах Safety Gym оптимальная стратегия обычно достигает цели за 100–200 шагов, а также используется плотная функция вознаграждения (dense). Поэтому эти среды рассматриваются как задачи с более коротким горизонтом по сравнению с SafeAntMaze, SafePusher и POLAMP. В задачах Safety Gym агент решает простую задачу навигации без необходимости выполнять сложные манёвры или перемещаться по лабиринтам, вознаграждение определяется как евклидово расстояние до цели, а функция штрафов принимает значение $+1$, когда агент находится внутри опасной зоны. Дополнительно рассматривается вариант PointGoal1 с разреженным вознаграждением, где агент получает награду $+1$ только за достижение цели; такая постановка усложняет исследование среды.

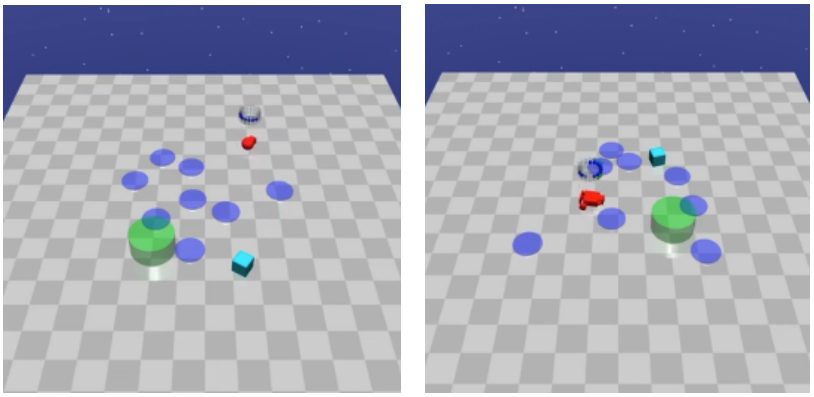


Рисунок 1.5 — Примеры задач PointGoal1 слева и CarGoal1 справа из бенчмарка Safety Gym. Синие круги обозначают опасные зоны, в которых агент получает штраф $+1$ при нахождении внутри них. Зелёный круг показывает целевую область, а синий прямоугольник обозначает перемещаемый объект среды, с которым агент может взаимодействовать без штрафа.

Задачи PointGoal1 и CarGoal1 приведены на рис. 1.5. Для задачи PointGoal sparse используется допустимый бюджет нарушений $d = 40$.

1.9 Метрики оценки безопасного исследования, используемые в диссертационной работе

Для оценки методов безопасного обучения с подкреплением используются метрики эффективности достижения цели в конце обучения, соблюдения ограничений по безопасности в конце обучения, а также среднее число нарушений ограничений во время обучения.

Метрикой эффективности является эпизодическое вознаграждение (Reward, Return):

$$R_{\text{ep}} = \sum_{t=0}^{T_{\text{ep}}} r_t. \tag{1.16}$$

Эта метрика показывает, насколько успешно агент решает исходную задачу.

Для оценки безопасности используется эпизодический штраф (Costs, Mean Total Safety Cost, MTSC):

$$C_{\text{ep}} = \sum_{t=0}^{T_{\text{ep}}} c_t. \tag{1.17}$$

Эта метрика отражает суммарное число или величину нарушений безопасности за эпизод. Чем ниже значение эпизодического штрафа, тем безопаснее поведение агента.

Для анализа безопасности во время обучения используется частота штрафов (Cost Rate):

$$\rho = \frac{1}{T} \sum_{t=0}^{T} c_t, \tag{1.18}$$

где T — общее число шагов взаимодействия со средой. В отличие от итогового эпизодического штрафа, эта метрика характеризует безопасность самого процесса исследования, то есть показывает, насколько часто агент нарушает ограничения во время обучения.

В навигационных задачах дополнительно используются метрики успешности и столкновений. Доля успешных эпизодов (Success Rate, SR) показывает, в какой части эпизодов агент достиг цели. Частота столкновений (Collision Rate, CR) показывает долю эпизодов, в которых агент столкнулся с опасной зоной или препятствием.

1.10 Выводы по главе

В данной главе приведена постановка безопасного обучения с подкреплением; в качестве математической модели используется марковский процесс принятия решений с ограничениями.

Методы оптимизации стратегии с ограничениями решают эту задачу на уровне целевой функции. Такие методы применимы к произвольным задачам, однако не гарантируют безопасность каждого действия. Подходы на основе фильтрации действий контролируют безопасность на этапе выбора действий и гарантируют безопасность каждого действия. Однако такая точность обычно требует дополнительных предположений о среде. Часто необходимы модель объекта управления, дифференцируемая функция штрафов, формальные правила безопасности или решение вспомогательной задачи оптимизации на каждом шаге.

Методы на основе моделей мира позволяют снизить число опасных взаимодействий при помощи генерации синтетического опыта, а также планирования в

рамках модели мира. Однако качество такого подхода зависит от точности модели мира; дополнительно возникает проблема с вычислительной стоимостью.

Для решения задач с большим горизонтом помогают методы иерархического обучения с подкреплением. Подцели и навыки позволяют разбить сложную задачу на более короткие подзадачи и тем самым упростить исследование. Но такие методы не учитывают ограничения по безопасности: подцель может быть достижимой, но путь к ней может проходить через опасные состояния. Существующие методы безопасного иерархического обучения частично решают эту проблему, но часто опираются на сильные предположения о полной наблюдаемости, дифференцируемости функции штрафов и заранее заданных навыках.

Отдельно в главе рассмотрен переход от фиксированных численных ограничений к ограничениям, заданным на естественном языке. Такая постановка ближе к реальным сценариям взаимодействия человека с автономным агентом. Современные бенчмарки для таких задач рассматривают только простые задачи навигации, которые не могут оценить важные способности агентов: память, понимание языка, связывание языка и наблюдения.

Рассмотренные проблемы определяют логику следующих глав диссертации: далее рассматривается метод оценки долгосрочного риска с помощью модели мира, иерархическое безопасное исследование, контроль безопасности подцелей, а также обучение агентов с естественно-языковыми целями и ограничениями.

Глава 2. Использование моделей мира для оценки будущих накопленных штрафов в безопасном обучении с подкреплением

Одним из основных ограничений безопасного обучения с подкреплением является необходимость принимать решения в условиях неполного знания о будущих последствиях действий агента. Эта проблема особенно существенна в задачах с разреженными штрафами, где опасное действие может не приводить к немедленному нарушению, но переводить агента в область состояний, из которой дальнейшее безопасное поведение становится затруднительным.

Методы обучения с подкреплением на основе модели мира позволяют частично решить эту проблему за счёт предсказания последствий действий до их выполнения в реальной среде. В таких подходах обучаемая модель мира используется для оценки будущих состояний, вознаграждений и штрафов на коротком горизонте планирования. Однако оценка безопасности только на конечном горизонте планирования имеет принципиальное ограничение: она не учитывает штрафы, которые могут возникнуть после окончания планируемой траектории.

В данной главе рассматривается метод SPOWL [40] как базовая архитектура безопасного обучения с подкреплением на основе модели мира. Исследуется способ построения функции оценки будущих накопленных штрафов, её использование при оценке кандидатных траекторий, а также способы агрегации ансамбля таких функций.

2.1 Оценка будущих накопленных штрафов в модели мира SPOWL

Метод SPOWL объединяет обучаемую модель мира, безопасную стратегию, планировщик и механизм выбора между действием стратегии и действием, предложенным планировщиком. В каждый момент времени агент может рассматривать две альтернативы: действие, сгенерированное безопасной стратегией, и действие, полученное с помощью планирования в модели мира. Итоговое действие выбирается на основе оценок накопленного вознаграждения и штрафов.

В рамках данной главы общая архитектура SPOWL используется как вычислительный контекст для анализа оценки будущих накопленных штрафов.

Основным объектом рассмотрения является модель мира, которая предсказывает не только мгновенные вознаграждения и штрафы, но и функции оценки будущего накопленного вознаграждения и штрафа. Наличие такой функции оценки позволяет оценивать риск не только внутри горизонта планирования, но и за его пределами.

2.1.1 Неявная модель мира

SPOWL использует модель мира в латентном пространстве. В отличие от подходов, где модель дополнительно восстанавливает исходное наблюдение, в SPOWL предсказываются прежде всего те величины, которые затем используются при планировании: вознаграждение, штраф и оценки будущих накопленных вознаграждений и штрафов. Таким образом решается проблема смещённой цели (*miss objective*), которая встречается в предыдущих работах, где модель мира обучается восстанавливать всё наблюдение, в том числе, например, освещённость изображения, что усложняет латентное представление. Поэтому модель не обязана точно декодировать всё состояние среды; достаточно, чтобы латентное представление сохраняло информацию, важную для выбора безопасных действий. Схема неявной модели мира SPOWL показана на рис. 2.1.

Пусть z_t — латентное представление состояния. Сначала состояние кодируется в латентное пространство:

$$z_t = h(s_t), \tag{2.1}$$

где h — кодировщик состояния. Затем модель латентной динамики предсказывает следующее латентное состояние:

$$\hat{z}_{t+1} = f(z_t, a_t), \tag{2.2}$$

где f — модель перехода в латентном пространстве.

Для оценки качества действий SPOWL использует несколько предсказательных голов. Модель мгновенного вознаграждения имеет вид

$$\hat{r}_t = \hat{R}(z_t, a_t), \tag{2.3}$$

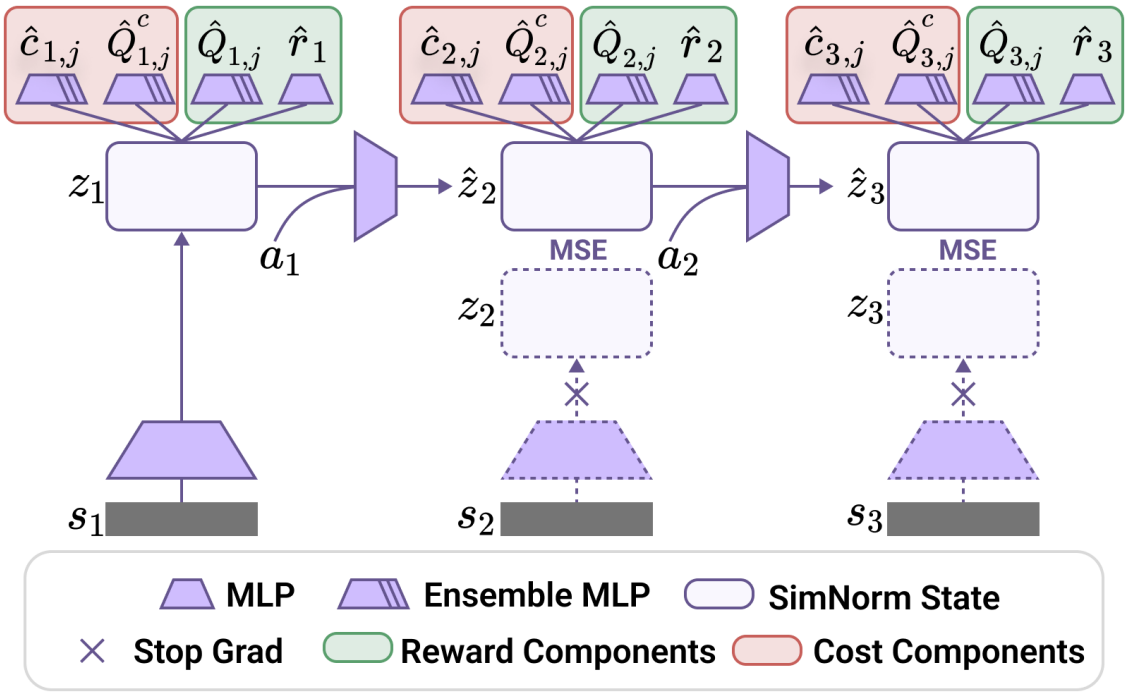


Рисунок 2.1 — Схема неявной модели мира SPOWL. Состояние кодируется в латентное пространство (h), модель динамики (f) предсказывает следующее латентное состояние; предсказательные головы оценивают вознаграждение ($\hat{R}$), накопленное вознаграждение ($\hat{Q}_j$), мгновенный штраф ($\hat{C}_j$) и будущие накопленные штрафы ($\hat{Q}^c_j$).

где $\hat{R}$ предсказывает вознаграждение. Функция оценки накопленного вознаграждения задаётся ансамблем функций

$$\hat{Q}_{t,j} = \hat{Q}_j(z_t, a_t), \tag{2.4}$$

где $\hat{Q}_j$ — одна из функций оценки накопленного вознаграждения.

Отдельно в SPOWL моделируется безопасность. Для этого используются два типа оценок. Первый тип отвечает за мгновенный штраф:

$$\hat{c}_{t,j} = \hat{C}_j(z_t, a_t), \tag{2.5}$$

где $\hat{C}_j$ — элемент ансамбля моделей текущего штрафа.

В предыдущих работах по безопасному обучению с подкреплением на основе модели мира, в частности в SafeDreamer [18], для оценки безопасности действий использовалась только модель мгновенных штрафов $\hat{C}$. При этом латентное представление z_t в процессе обучения не содержало информации о возможных будущих штрафах. Поэтому в SPOWL модель мира дополнительно

обучается предсказывать будущий накопленный штраф Q^c:

$$Q^c(s,a) = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma_c^k c_{t+k} \mid s_t = s,\, a_t = a \right], \tag{2.6}$$

где γ_c — коэффициент дисконтирования штрафов. В модели мира SPOWL эта величина задаётся ансамблем функций

$$\hat{Q}^c_{t,j} = \hat{Q}^c_j(z_t, a_t), \tag{2.7}$$

где $\hat{Q}^c_j$ — элемент ансамбля функций будущих накопленных штрафов.

Разделение между $\hat{C}_j$ и $\hat{Q}^c_j$ важно для безопасного планирования. Модель $\hat{C}_j$ показывает, возникает ли штраф непосредственно при текущем переходе. Функция $\hat{Q}^c_j$, напротив, оценивает последствия выбранного действия за пределами одного шага и учитывает риск будущих нарушений.

2.1.2 Обучение функции оценки будущих накопленных штрафов

Функция будущих накопленных штрафов обучается по принципу временных разностей. Для вознаграждения и штрафов используются отдельные целевые значения. Целевое значение для функции оценки накопленного вознаграждения имеет вид:

$$Q_t = r_t + \gamma \overline{Q}(\hat{z}'_t, \hat{a}'_t), \tag{2.8}$$

где γ — коэффициент дисконтирования вознаграждения, а $\overline{Q}$ — целевая функция оценки накопленного вознаграждения.

Аналогично, целевое значение для функции оценки будущих накопленных штрафов задаётся как

$$Q^c_t = c_t + \gamma_c \overline{Q}^c(\hat{z}'_t, \hat{a}'_t), \tag{2.9}$$

где γ_c — коэффициент дисконтирования штрафов, а $\overline{Q}^c$ — целевая функция оценки будущих накопленных штрафов.

Эта формула показывает, что оценка штрафов действия состоит из двух частей: текущего штрафа и ожидаемого будущего накопленного штрафа. Следовательно, модель мира обучается не только обнаруживать непосредственные

нарушения безопасности, но и предсказывать долгосрочный риск, связанный с текущим действием.

Полная функция потерь модели мира включает несколько компонент:

$$\begin{aligned} L_t = \|\hat{z}'_t - \mathrm{sg}(z'_t)\|_2^2 + \mathrm{CE}(\hat{r}_t, r_t) \\ + \frac{1}{N}\sum_{j=1}^{N} \mathrm{CE}(\hat{Q}_{t,j}, Q_t) + \frac{1}{N}\sum_{j=1}^{N} \mathrm{CE}(\hat{c}_{t,j}, c_t) \\ + \frac{1}{N}\sum_{j=1}^{N} \mathrm{CE}(\hat{Q}^c_{t,j}, Q^c_t). \end{aligned} \tag{2.10}$$

Здесь первая компонента отвечает за согласованность латентной динамики, вторая — за предсказание вознаграждения, третья — за обучение функций оценки накопленного вознаграждения, четвёртая — за предсказание мгновенных штрафов, а последняя — за обучение функций будущих накопленных штрафов. Именно последняя компонента является центральной для оценки долгосрочного риска.

2.1.3 Оценка безопасности кандидатных траекторий

При планировании агент рассматривает кандидатную последовательность действий

$$a_{t:t+H} = (a_t, a_{t+1}, \ldots, a_{t+H}), \tag{2.11}$$

где H — горизонт планирования. Модель мира последовательно предсказывает латентные состояния и оценивает для каждой траектории ожидаемое вознаграждение и ожидаемый штраф.

Схема использования этих оценок в процедуре планирования показана на рис. 2.2. Планировщик формирует два множества кандидатных последовательностей действий: последовательности, порождённые текущей стратегией, и последовательности, полученные сэмплированием из нормального распределения. Для каждой последовательности модель мира вычисляет оценки J^M и J^M_c. Затем на основе оценок траекторий, порождённых стратегией, задаются пороги d^R и d^c, после чего выбираются элитные траектории, одновременно удовлетворяющие требованиям по вознаграждению и штрафов.

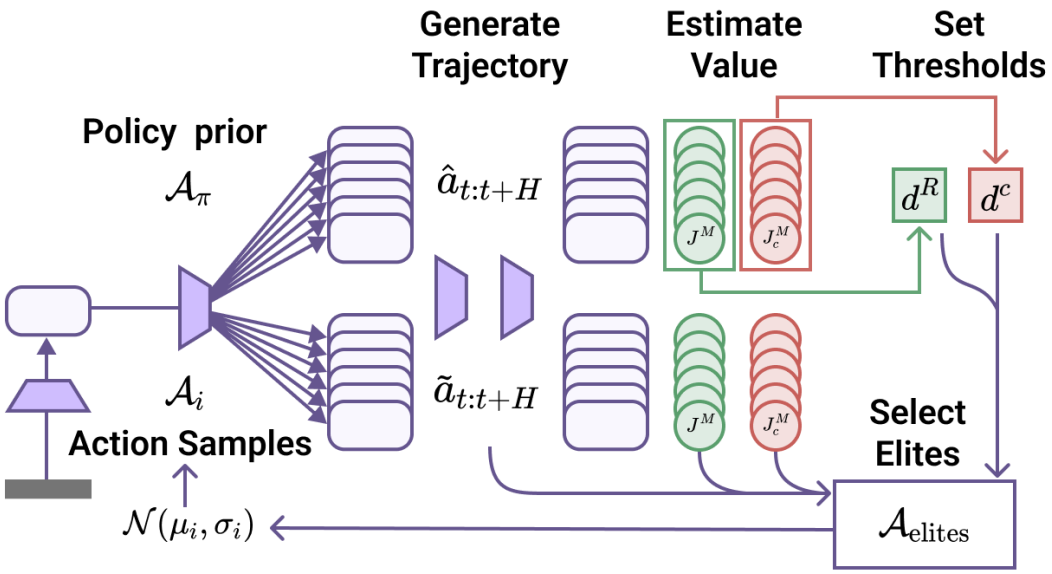


Рисунок 2.2 — Схема безопасного планирования в SPOWL. Планировщик оценивает кандидатные траектории по ожидаемому вознаграждению (J_M) и штрафов (J_M^c), после чего выбирает элитные траектории с учётом порогов (d_R) и (d_c).

Для каждой кандидатной последовательности действий SPOWL отдельно оценивает ожидаемое вознаграждение и ожидаемые штрафы. Оценка вознаграждения включает две части: награды, предсказанные моделью внутри горизонта планирования, и терминальную функцию оценки накопленного вознаграждения в конце этого горизонта:

$$J_M^{c,\text{global}}(z_t, a_{t:t+H}) = \sum_{i=0}^{H-1} \gamma^i \hat{r}_{t+i} + \gamma^H \hat{Q}_{\text{agg}}(z_{t+H}, a_{t+H}). \tag{2.12}$$

Если при планировании учитывать только предсказанные мгновенные штрафы,

$$J_M^{c,\text{local}}(z_t, a_{t:t+H}) = \sum_{i=0}^{H-1} \gamma_c^i \hat{c}_{t+i}, \tag{2.13}$$

то оценка безопасности становится локальной. Однако при разреженных штрафах он может считать безопасной траекторию, которая фактически ведёт к нарушению.

2.1.4 Агрегация ансамбля функций оценки будущих накопленных штрафов

Для повышения устойчивости оценки в модели мира используется ансамбль функций оценки будущих накопленных штрафов:

$$\{\hat{Q}^c_1, \hat{Q}^c_2, \ldots, \hat{Q}^c_N\}. \tag{2.14}$$

Итоговая оценка будущих накопленных штрафов получается агрегацией значений ансамбля:

$$\hat{Q}^c_{\text{agg}}(z_t,a_t) = \text{Agg}^N_{j=1}\, \hat{Q}^c_j(z_t,a_t). \tag{2.15}$$

В данной работе рассматриваются три способа агрегации:

$$\hat{Q}^c_{\min}(z_t,a_t) = \min_{j=1,\ldots,N} \hat{Q}^c_j(z_t,a_t), \tag{2.16}$$

$$\hat{Q}^c_{\max}(z_t,a_t) = \max_{j=1,\ldots,N} \hat{Q}^c_j(z_t,a_t), \tag{2.17}$$

$$\hat{Q}^c_{\text{avg}}(z_t,a_t) = \frac{1}{N}\sum_{j=1}^{N} \hat{Q}^c_j(z_t,a_t). \tag{2.18}$$

Минимальная агрегация использует наиболее низкую оценку штрафов среди элементов ансамбля. В этом случае планировщик фактически опирается на самый благоприятный прогноз риска. Такой вариант может быть полезен, когда важно не подавить исследование слишком рано: агент чаще допускает траектории, которые отдельные модели ансамбля считают рискованными. Однако у этого есть очевидный недостаток — если хотя бы одна функция будущих накопленных штрафов недооценивает будущие нарушения, итоговая оценка также становится заниженной.

Максимальная агрегация, наоборот, берёт наиболее высокую оценку штрафов. Это делает планировщик более осторожным: траектория отбрасывается уже тогда, когда хотя бы один элемент ансамбля считает её опасной. Такой подход снижает вероятность выбора явно рискованных действий, но может слишком сильно ограничивать поиск. В результате агент способен избегать не только опасных, но и потенциально полезных траекторий.

Усреднение по ансамблю занимает промежуточное положение между этими двумя режимами. Оно не полагается на единственную наиболее оптимистичную

или наиболее пессимистичную оценку, а учитывает общий прогноз ансамбля. За счёт этого снижается влияние отдельных выбросов в функциях оценки будущих накопленных штрафов.

2.2 Экспериментальная проверка метода SPOWL и исследование оценки накопленных штрафов

В данном разделе рассматривается экспериментальная проверка роли оценки будущих накопленных штрафов в безопасном обучении с подкреплением на основе модели мира. Основное внимание уделяется тому, как способ построения и агрегации функций оценки будущих накопленных штрафов влияет на безопасность и эффективность агента. При этом сначала приводится общее сравнение полной конфигурации SPOWL с базовыми методами, а затем рассматриваются абляционные эксперименты, связанные с оценкой будущих накопленных штрафов.

Эксперименты проводятся на задачах Safety Gymnasium, описание которых приведено в разделе 1.8. Рассматриваются задачи Goal, Push и Button с разными телами агента: Point, Car, Doggo и Ant. В основном сравнении используются конфигурации PointGoal1, PointGoal2, PointPush1, PointButton1, CarGoal1, DoggoGoal1 и AntGoal1. Далее для краткости используются обозначения P, C, D и A для тел Point, Car, Doggo и Ant, а обозначения G1, G2, P1 и B1 соответствуют задачам Goal1, Goal2, Push1 и Button1. Например, PG1 обозначает PointGoal1, а AG1 — AntGoal1.

Эксперименты направлены на ответы на следующие исследовательские вопросы.

RQ1: обеспечивает ли полная конфигурация SPOWL конкурентоспособное качество по сравнению с существующими методами безопасного обучения с подкреплением?

RQ2: как использование функции оценки будущих накопленных штрафов Q^c влияет на оценку безопасности кандидатных траекторий по сравнению с локальной оценкой только по мгновенным штрафам?

RQ3: как способ агрегации ансамбля функций оценки будущих накопленных штрафов влияет на баланс между достижением цели и соблюдением ограничений безопасности?

RQ4: как размер ансамбля и размер подвыборки при агрегации функций штрафов влияют на итоговую безопасность и эффективность агента?

Для сравнения используются как методы обучения с подкреплением на основе модели мира, так и методы безопасного обучения с подкреплением без модели мира.

TD-MPC2 [55] используется как метод обучения с подкреплением на основе модели мира без учёта ограничений безопасности. Этот метод позволяет оценить, какой уровень эпизодического вознаграждения может быть достигнут при игнорировании штрафов. Поэтому TD-MPC2 обычно получает высокое вознаграждение, но накапливает больше штрафов.

SafeDreamer [18] является методом безопасного обучения с подкреплением на основе модели мира на базе архитектуры Dreamer. Метод использует модель мира и планирование с учётом ограничений безопасности. Он является наиболее близким базовым методом обучения с подкреплением на основе модели мира, поскольку также использует предсказания модели мира для безопасного поведения.

PPOLag [6] — метод, использующий данные текущей стратегии (on-policy), не использующий модель мира, основанный на PPO и учёте ограничений на основе функции лагранжиана. Рассматриваются две версии метода: PPOLag(2) и PPOLag(25), где число в скобках обозначает допустимый бюджет за эпизод.

CPO [42] — метод оптимизации стратегии с ограничениями, использующий данные текущей стратегии, в котором обновление стратегии строится с учётом ограничения на ожидаемый штраф. В экспериментах используется версия CPO(25) с допустимым бюджетом нарушений 25.

CVPO [87] — метод безопасного обучения с подкреплением, не использующий данные текущей стратегии (off-policy), на основе оптимизации стратегии с ограничениями. В экспериментах используется версия CVPO(25).

2.2.1 Сравнение с базовыми методами

Сначала проводится общее сравнение полной конфигурации SPOWL с базовыми методами. Это сравнение необходимо для проверки того, что предложенная конфигурация модели мира, включающая оценку будущих накопленных штрафов и ансамблевую агрегацию функций штрафов, приводит не только к улучшению

отдельных внутренних компонент, но и к конкурентоспособному итоговому поведению агента.

Результаты приведены в табл. 2. Во всех задачах оцениваются три метрики: R — среднее вознаграждение за эпизод, C — средний штраф за эпизод, ρ — средний штраф за шаг обучения.

Таблица 2 — Сравнение SPOWL с базовыми методами на задачах Safety Gymnasium. TD-MPC2 не учитывает ограничения безопасности. Обозначения PPOLag(2), PPOLag(25), CPO(25), CVPO(25) указывают порог допустимого накопленного штрафа за эпизод. Метрика R обозначает среднее вознаграждение за эпизод, C — средний штраф за эпизод, ρ — средний штраф за шаг обучения. Все значения приведены после $5 \cdot 10^6$ шагов взаимодействия со средой.

Task	Metric	**SPOWL**	TD-MPC2	SafeDreamer	PPOLag(2)	PPOLag(25)	CPO(25)	CVPO(25)
PG1	$R \uparrow$	26.9 ± 0.4	27.5 ± 0.2	12.0 ± 4.0	8.5 ± 3.5	14.5 ± 0.6	19.2 ± 3.0	15.3 ± 6.4
	$C \downarrow$	1.5 ± 1.1	52.3 ± 8.6	10.3 ± 9.5	13.5 ± 7.2	19.7 ± 3.0	31.0 ± 5.8	22.9 ± 8.5
	$\rho \times 10^4 \downarrow$	133 ± 2	515 ± 9	160 ± 16	222 ± 19	361 ± 20	275 ± 21	296 ± 18
PG2	$R \uparrow$	13.7 ± 3.2	27.4 ± 0.5	5.2 ± 3.9	1.8 ± 1.7	2.0 ± 0.9	3.2 ± 3.2	2.0 ± 1.2
	$C \downarrow$	4.8 ± 1.2	179.0 ± 12.2	0 ± 0	35.9 ± 14.3	33.7 ± 16.3	26.1 ± 0.8	22.6 ± 21.3
	$\rho \times 10^4 \downarrow$	280 ± 5	1641 ± 18	221 ± 32	397 ± 53	570 ± 73	354 ± 45	391 ± 6
PP1	$R \uparrow$	18.7 ± 1.4	20.8 ± 0.6	12.5 ± 7.2	1.5 ± 0.6	4.4 ± 2.7	2.4 ± 1.8	10.4 ± 2.7
	$C \downarrow$	1.8 ± 2.5	34.2 ± 11.6	7.3 ± 10.4	33.5 ± 16.4	24.2 ± 12.4	25.5 ± 8.1	25.8 ± 9.8
	$\rho \times 10^4 \downarrow$	103 ± 5	353 ± 6	71 ± 3	123 ± 13	276 ± 16	254 ± 7	253 ± 12
PB1	$R \uparrow$	10.0 ± 1.5	33.4 ± 0.4	0.1 ± 1.4	0.2 ± 0.4	3.7 ± 2.5	1.3 ± 0.6	10.1 ± 1.7
	$C \downarrow$	5.4 ± 2.7	103.3 ± 3.1	0.3 ± 0.5	43.7 ± 35.4	33.6 ± 7.7	22.8 ± 5.4	53.6 ± 26.5
	$\rho \times 10^4 \downarrow$	269 ± 3	1219 ± 10	159 ± 3	395 ± 142	392 ± 27	336 ± 12	358 ± 19
CG1	$R \uparrow$	31.3 ± 0.8	34.8 ± 0.3	6.6 ± 1.2	3.5 ± 3.2	18.4 ± 3.9	21.6 ± 2.4	20.2 ± 2.1
	$C \downarrow$	1.0 ± 1.0	51.2 ± 7.9	0 ± 0	7.5 ± 6.8	30.5 ± 5.0	25.6 ± 2.8	34.8 ± 3.4
	$\rho \times 10^4 \downarrow$	113 ± 2	563 ± 11	127 ± 15	214 ± 6	345 ± 9	321 ± 10	283 ± 10
DG1	$R \uparrow$	19.0 ± 1.9	27.9 ± 1.5	1.1 ± 0.9	0 ± 0	0 ± 0	0 ± 0	0 ± 0
	$C \downarrow$	0.3 ± 0.4	72.6 ± 20.6	0 ± 0	0 ± 0	21.8 ± 30.8	0 ± 0	0 ± 0
	$\rho \times 10^4 \downarrow$	286 ± 15	659 ± 33	260 ± 70	249 ± 15	376 ± 70	224 ± 79	332 ± 24
AG1	$R \uparrow$	38.9 ± 1.4	61.0 ± 2.6	0.2 ± 0.2	0.2 ± 0.2	5.1 ± 3.9	0 ± 0	4.3 ± 1.9
	$C \downarrow$	2.0 ± 0.2	70.9 ± 6.0	0 ± 0	0 ± 0	23.6 ± 18.2	0 ± 0	41.5 ± 44.1
	$\rho \times 10^4 \downarrow$	275 ± 6	682 ± 6	218 ± 58	220 ± 141	638 ± 115	466 ± 38	598 ± 33

Из табл. 2 видно, что TD-MPC2 достигает высокого вознаграждения, но систематически нарушает ограничения безопасности, поскольку не учитывает штрафы при обучении и планировании. Например, в задачах PG2, PB1 и AG1 он получает высокое вознаграждение, но накапливает значительно большие штрафы по сравнению со SPOWL.

SafeDreamer, напротив, часто обеспечивает низкие штрафы, но во многих задачах делает это за счёт сильного ухудшения эпизодического вознаграждения. В задачах DoggoGoal1 и AntGoal1 значения вознаграждения близки к нулю, что указывает на неспособность метода решить задачу при сохранении безопасности.

Результаты методов без модели мира также показывают, что настройка ограничения существенно влияет на итоговое поведение агента. Для PPOLag это особенно заметно при сравнении двух порогов штрафов. Жёсткий вариант PPOLag(2) сильнее ограничивает исследование, из-за чего в ряде задач агент почти не продвигается к цели. Более мягкий вариант PPOLag(25) позволяет получать большее вознаграждение, но вместе с этим чаще допускает нарушения безопасности. CPO демонстрирует похожую проблему: метод может удерживать штрафы на низком уровне, однако в сложных задачах это нередко сопровождается почти нулевым вознаграждением.

CVPO в отдельных задачах оказывается эффективнее on-policy методов по целевой метрике, но выигрыш по вознаграждению не всегда сопровождается безопасным поведением. Например, в задаче PB1 CVPO получает эпизодическое вознаграждение, близкое к SPOWL, однако эпизодический штраф у него существенно выше. Это показывает, что высокое вознаграждение само по себе не означает успешного решения безопасной задачи.

В целом сравнение с базовыми методами показывает, что SPOWL занимает более устойчивое положение между двумя крайними режимами. TD-MPC2 хорошо решает целевую задачу, но практически не контролирует штрафы. Часть безопасных методов, наоборот, снижает нарушения за счёт сильного падения эпизодического вознаграждения. SPOWL учитывает штрафы уже на этапе планирования и при этом сохраняет ненулевую эпизодическое вознаграждение в более сложных задачах. Это указывает на практическую пользу компонентов модели мира, связанных с оценкой будущих накопленных штрафов и ансамблевой агрегацией функций штрафов.

2.2.2 Сравнение локальных и глобальных оценок штрафов

Следующий эксперимент проверяет, какую роль играет функция будущих накопленных штрафов Q^c при выборе кандидатных траекторий. Для этого

сравниваются локальная оценка $J_c^{M,\text{local}}$ и глобальная оценка $J_c^{M,\text{global}}$. В первом случае планировщик учитывает только предсказанные мгновенные штрафы внутри конечного горизонта. Во втором случае к этой локальной сумме добавляется терминальная оценка Q^c, которая должна учитывать штрафы возможных нарушений после окончания горизонта планирования.

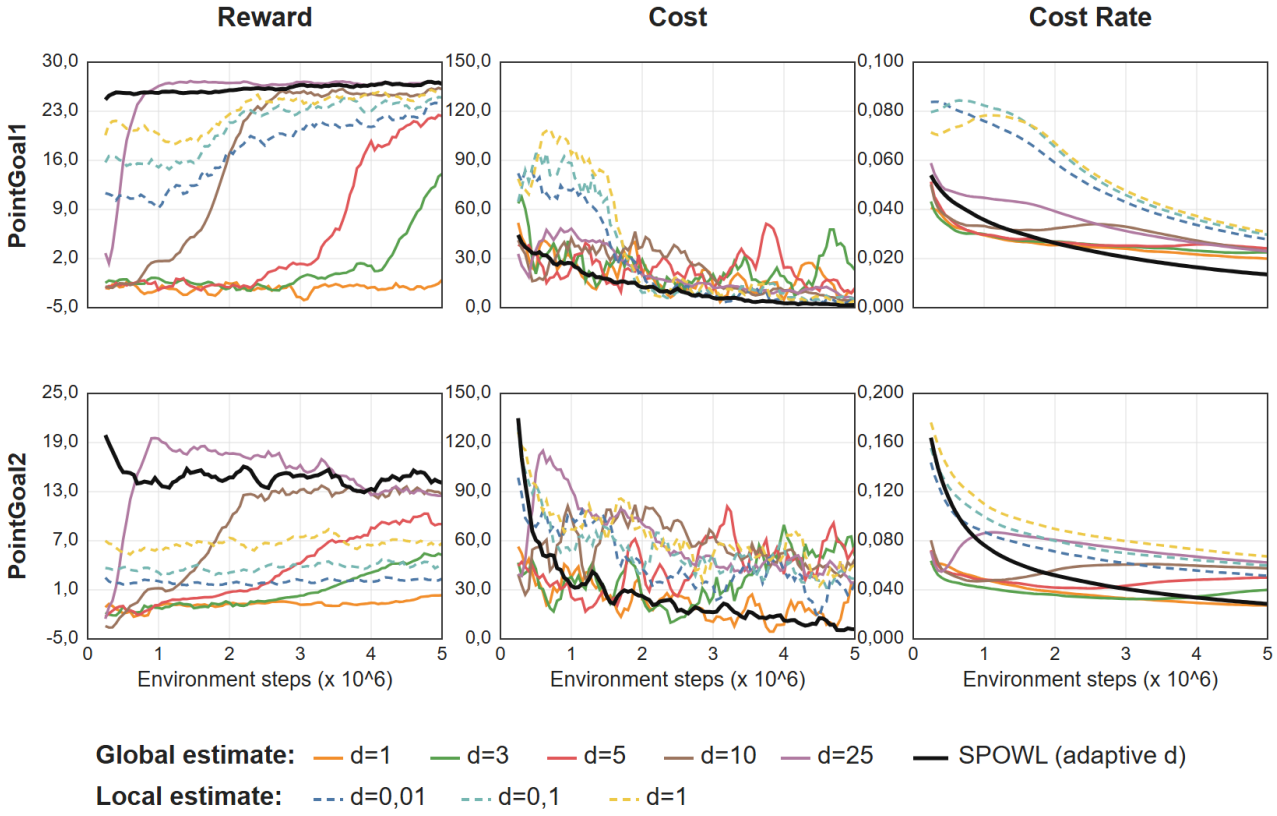


Рисунок 2.3 — Сравнение локальной и глобальной оценок штрафов траектории на средах PointGoal1 и PointGoal2. Сплошными линиями показана глобальная оценка с фиксированными порогами $d^c \in \{1, 3, 5, 10, 25\}$, пунктирными линиями — локальная оценка с порогами $d^c \in \{0{,}01, 0{,}1, 1\}$. Чёрной линией обозначена полная конфигурация SPOWL с адаптивным порогом d^c. Кривые усреднены по трём случайным инициализациям.

Результаты на рис. 2.3 показывают, что локальная и глобальная оценка штрафов приводит к различному поведению агента при выборе порога безопасности. Локальная оценка обладает ограниченной видимостью будущего. В средах с разреженными штрафами нарушение может не проявиться в пределах горизонта планирования, поэтому агент получает слишком оптимистичную оценку безопасности. Это может ускорять рост вознаграждения на ранних этапах обучения, но одновременно повышает риск небезопасного поведения. Чтобы поддерживать

безопасность при локальной оценке, необходимо задавать очень малые пороги допустимых накопленных штрафов, что ухудшает достижение цели.

Глобальная оценка ведёт себя иначе. Поскольку она использует функцию будущих накопленных штрафов Q^c, на ранних этапах обучения оценка риска может быть высокой. Это ограничивает исследование среды, но позволяет учитывать будущие нарушения, которые не видны при локальной оценке. По мере обучения модели и стратегии оценка штрафов становится более точной, после чего агент получает возможность выбирать более продуктивные траектории без резкого роста нарушений безопасности.

2.2.3 Сравнение способов агрегации ансамбля функций оценки будущих накопленных штрафов

Второй эксперимент исследует, как способ агрегации ансамбля функций оценки будущих накопленных штрафов влияет на безопасность и эффективность агента. Рассматриваются три варианта агрегации: минимум, максимум и среднее.

Экспериментальные результаты показывают, что усреднение по ансамблю позволяет избежать крайних эффектов. Оно не приводит к такой сильной недооценке риска, как минимум, и не создаёт чрезмерной консервативности, характерной для максимума. Поэтому средняя агрегация обеспечивает наиболее устойчивый баланс между безопасностью и достижением цели. Сравнение способов агрегации приведено на рис. 2.4.

Этот результат показывает, что сама по себе функция оценки будущих накопленных штрафов недостаточна: важно также корректно агрегировать оценки ансамбля. Неправильная агрегация может изменить поведение агента даже при той же архитектуре модели мира и тех же данных обучения.

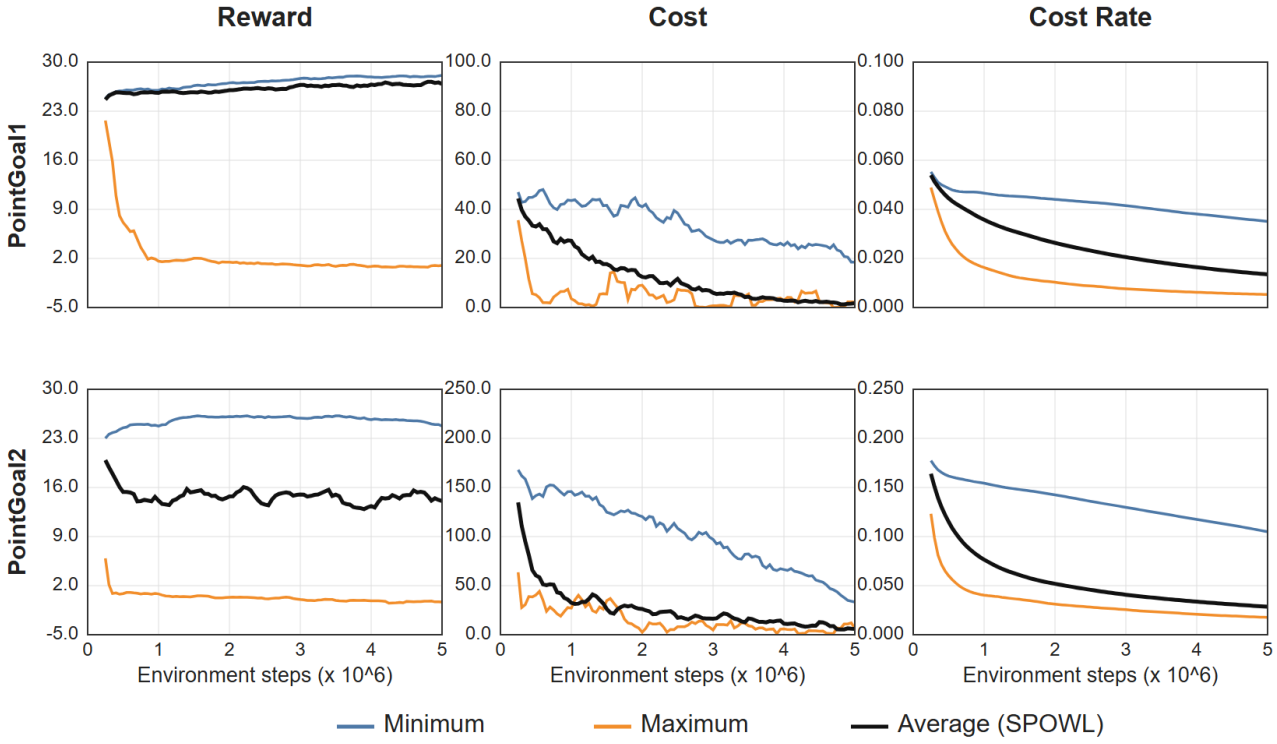


Рисунок 2.4 — Сравнение способов агрегации ансамбля функций будущих накопленных штрафов.

2.2.4 Влияние размера ансамбля и размера подвыборки

Третий эксперимент направлен на анализ параметров ансамбля функций штрафов. Исследуется влияние двух факторов: общего размера ансамбля и размера подвыборки, используемой при агрегации оценок.

Если ансамбль слишком мал, оценка штрафов становится нестабильной и сильно зависит от ошибок отдельной функции. В этом случае агент может либо недооценивать риск, либо переоценивать его в зависимости от случайного смещения одной модели. Эксперименты показывают, что использование единственной функции штрафов уступает ансамблевым вариантам по совокупности метрик.

Увеличение размера ансамбля повышает устойчивость оценки, однако чрезмерное увеличение не даёт существенного улучшения. Это связано с тем, что после определённого размера ансамбля дополнительное усреднение уже слабо изменяет итоговую оценку, но увеличивает вычислительные затраты.

Размер подвыборки также влияет на безопасность. Более крупные подвыборки позволяют получать более устойчивую оценку штрафов и уменьшают

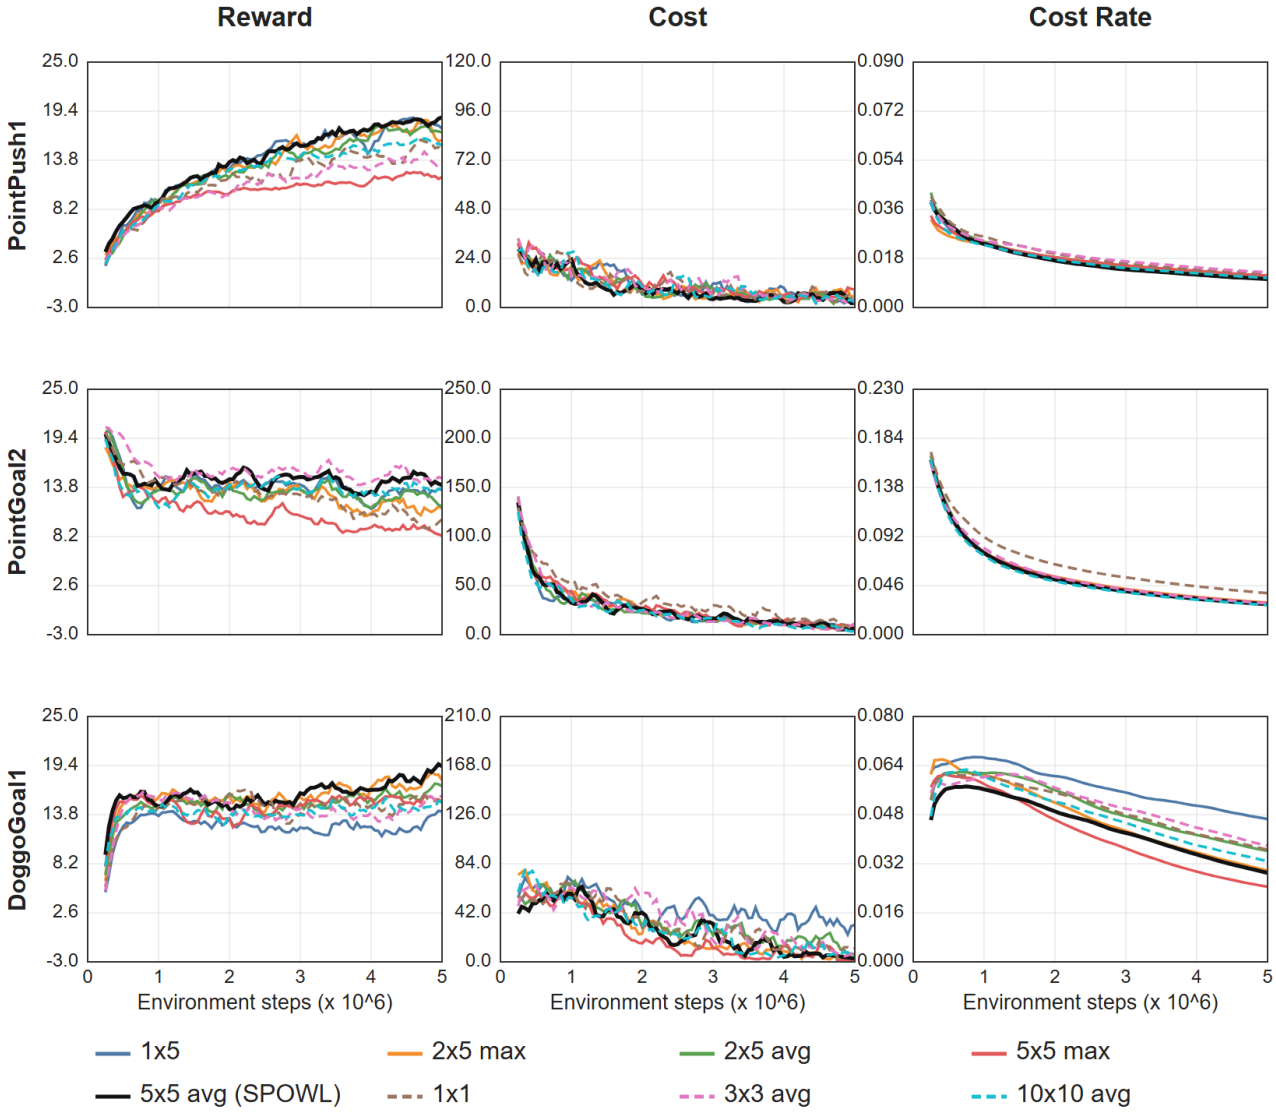


Рисунок 2.5 — Абляционное исследование размера ансамбля и подвыборки функций будущих накопленных штрафов.

число нарушений безопасности. Однако слишком пессимистичная агрегация, например максимум по крупной подвыборке, может снижать вознаграждение без соответствующего выигрыша по безопасности. В таких случаях агент становится более осторожным, но не получает существенного уменьшения нарушений. Результаты абляционного исследования приведены на рис. 2.5.

На основании проведённого анализа в SPOWL используется схема 5×5 с усреднением: пять функций в ансамбле и агрегация средним значением. Такая конфигурация обеспечивает достаточно устойчивую оценку штрафов без заметного ухудшения эпизодического вознаграждения.

2.3 Выводы по главе

В данной главе рассмотрена задача оценки будущих накопленных штрафов в обучении с подкреплением на основе модели мира. В качестве базовой архитектуры использован метод SPOWL. Основное внимание уделено компонентам модели мира, которые отвечают за предсказание мгновенных штрафов и оценку ожидаемого накопленного штрафа.

Показано, что при безопасном планировании недостаточно учитывать только сумму мгновенных штрафов на конечном горизонте. Такая локальная оценка отражает ближайшие нарушения, но может пропускать риск, который возникает после завершения кандидатной траектории. Это особенно важно в задачах с разреженными штрафами, где небезопасное действие не всегда приводит к немедленному штрафу, но может переводить агента в состояние, из которого дальнейшее нарушение становится более вероятным.

Для учёта такого риска в SPOWL используется функция будущих накопленных штрафов Q^c. За счёт этого штраф кандидатной траектории учитывает не только локальные нарушения, но и возможные опасные продолжения за пределами короткого горизонта планирования.

Также в главе рассмотрена агрегация ансамбля функций оценки будущих накопленных штрафов. Усреднение по ансамблю оказалось более устойчивым вариантом, поскольку оно уменьшает влияние отдельных заниженных или завышенных оценок штрафов.

Анализ размера ансамбля и размера подвыборки показывает, что использование нескольких функций штрафов повышает устойчивость оценки по сравнению с одиночной функцией. При этом чрезмерное увеличение ансамбля не даёт заметного улучшения по всем метрикам, но увеличивает вычислительные затраты.

Общее сравнение с базовыми методами показывает, что полная конфигурация SPOWL занимает промежуточное положение между небезопасным, но эффективным планированием и чрезмерно осторожным безопасным поведением.

Глава 3. Решение проблемы безопасного исследования с помощью иерархической структуры

В предыдущей главе рассматривалось использование модели мира для оценки последствий действий до их выполнения. Такой подход полезен для безопасного планирования, однако он плохо масштабируется на задачи с большим горизонтом. Чем длиннее требуется траектория, тем сильнее накапливается ошибка модели, и тем менее надёжной становится оценка всей последовательности действий.

На задачах с большим горизонтом эти ограничения проявляются особенно явно. В табл. 3 приведены итоговые результаты обучения современных методов безопасного обучения с подкреплением на навигационной среде POLAMP Level 2.

Таблица 3 — Результаты базовых методов безопасного обучения с подкреплением на POLAMP Level 2. SR — доля успешных эпизодов, CR — частота столкновений, MTSC — средний накопленный штраф за эпизод. Результаты усреднены по 5 случайным запускам.

Method	SR↑	CR↓	MTSC↓
SAC-LAG	0.000	0.004	1.319
SAC	0.000	0.010	5.054
SAC-NCMP	0.000	1.000	1.369
SAC-RCBF	0.008	0.050	8.625
ADVICE	0.000	0.010	0.010
L-RRT	0.125	0.664	12.154

Данная глава посвящена решению этой проблемы с помощью иерархической структуры (рис. 3.1). Основная идея состоит в том, что вместо прямого поиска траектории к удалённой цели агент использует промежуточные подцели, которые направляют исследование среды. В методе SG-Safe [38] стратегия, генерирующая подцели применяется на этапе обучения и помогает безопасной стратегии находить более информативные области пространства состояний. При этом подцели не являются жёсткими командами, обязательными для точного достижения, а используются как дополнительный обучающий сигнал. На этапе исполнения (inference) применяется только обученная безопасная стратегия, что позволяет избежать дополнительных затрат на планирование.

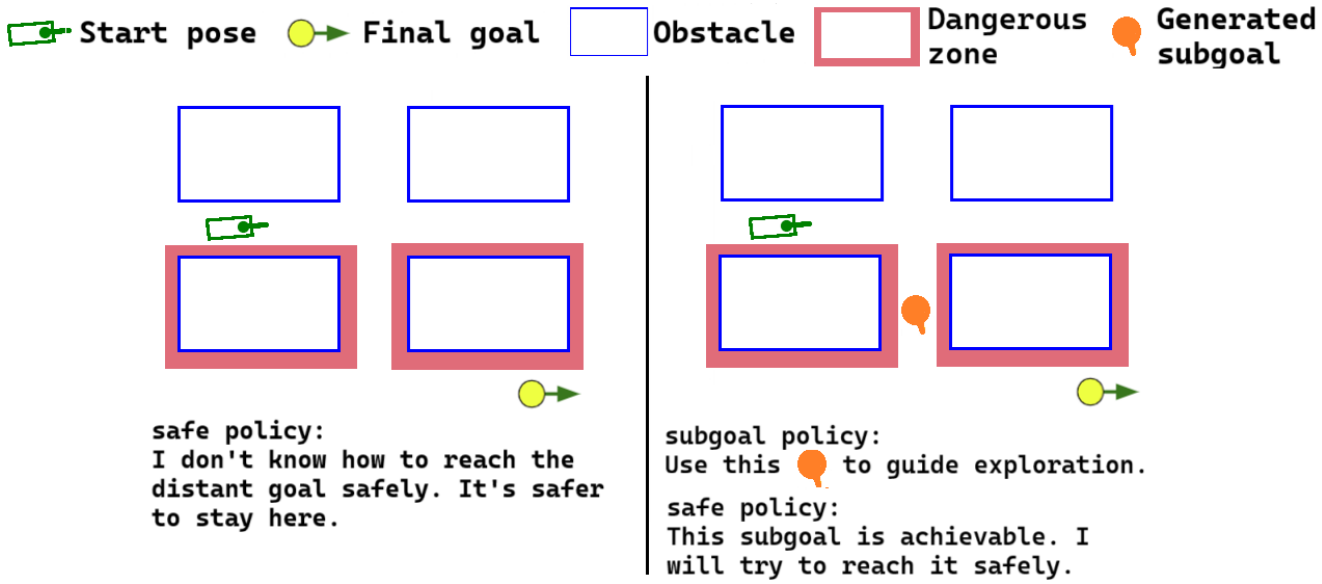


Рисунок 3.1 — Безопасное исследование с использованием подцелей. **Слева**: одноуровневая безопасная стратегия может не находить траекторию к удалённой цели. **Справа**: промежуточные подцели направляют исследование и упрощают достижение цели.

3.1 Метод SG-Safe

В SG-Safe безопасная стратегия обучается вместе со стратегией, генерирующей подцели. Безопасная стратегия выбирает действия с учётом награды и штрафов, а стратегия, генерирующая подцели используется для того, чтобы направлять обучение в задачах с длинным горизонтом. Вместо прямого поиска полной траектории к конечной цели агент получает промежуточные подцели, которые упрощают достижение исходной цели. Безопасная стратегия обучается при помощи функции лагранжиана, что позволяет максимизировать вознаграждение и одновременно оставаться в безопасном множестве состояний. Как показано на рис. 3.2, SG-Safe чередует две основные процедуры: 1) сбор опыта безопасной стратегией и сохранение траекторий в буфере с переопределением целей (Hindsight Experience Replay, HER) с переиспользованием опыта и подстановкой достигнутых целей; 2) обновление безопасной стратегии с использованием подцелей, сгенерированных на основе переходов из буфера. Такая схема повышает эффективность обучения в задачах с разреженным вознаграждением и большим горизонтом.

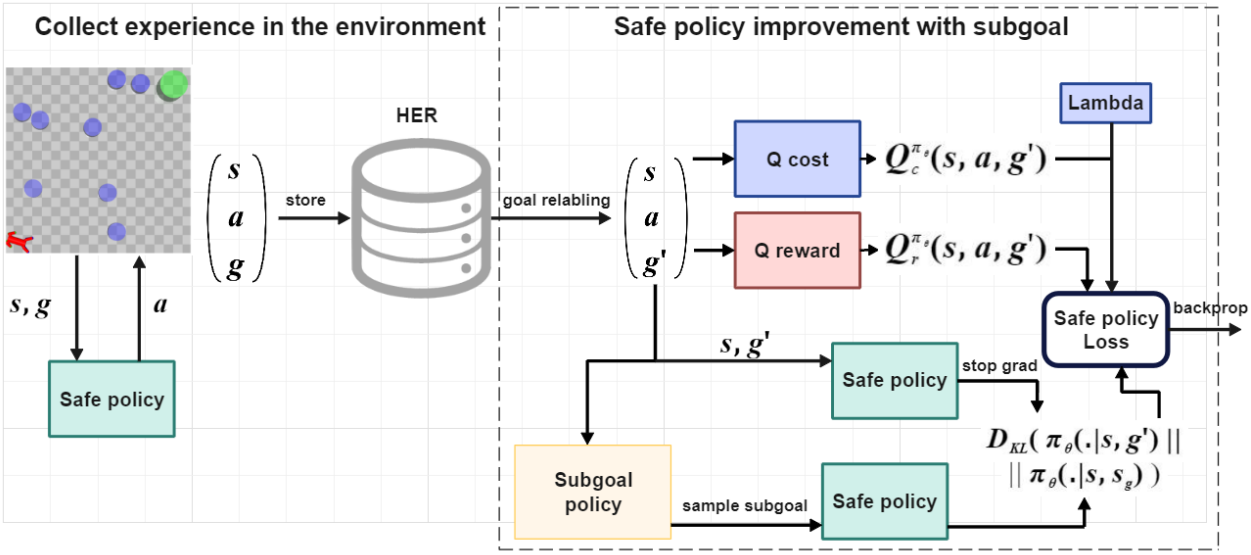


Рисунок 3.2 — Схема метода SG-Safe. Метод включает сбор опыта безопасной стратегией с сохранением траекторий в HER и последующее улучшение безопасной стратегии с использованием промежуточных подцелей.

3.1.1 Безопасная стратегия метода SG-Safe

Одним из распространённых подходов к решению марковских процессов принятия решений с ограничениями являются методы на основе функции лагранжиана, которые часто комбинируются с внеполитическим градиентным алгоритмом SAC. Подход на основе функции лагранжиана сводит задачу оптимизации с ограничениями к безусловной задаче оптимизации с помощью множителей Лагранжа λ_i, задающих веса ограничений безопасности. Эти множители штрафуют нарушения ограничений, учитывая расхождение между допустимым бюджетом нарушений d_i и ожидаемыми дисконтированными штрафами $J_{C,i}(\pi)$. В данной работе рассматривается случай одного ограничения безопасности, поэтому далее используется один множитель Лагранжа $\lambda_i = \lambda$, один допустимый бюджет нарушений $d_i = d$ и одни дисконтированные штрафы $J_C(\pi)$.

Для награды и штрафов обучаются две Q-функции: $Q_r^{\pi_\theta}$ для оценки награды и $Q_c^{\pi_\theta}$ для оценки штрафов. Они минимизируют ошибки Беллмана с учётом энтропии:

$$\left(Q_r^{\pi_\theta}(s_t,a_t) - \left(r(s_t,a_t) + \gamma Q_r^{\pi_\theta}(s_{t+1},a_{t+1}) - \alpha \log \pi_\theta(a_{t+1}|s_{t+1})\right)\right)^2, \tag{3.1}$$

$$\left(Q_c^{\pi_\theta}(s_t,a_t) - \left(c(s_t,a_t) + \gamma Q_c^{\pi_\theta}(s_{t+1},a_{t+1}) - \alpha' \log \pi_\theta(a_{t+1}|s_{t+1})\right)\right)^2, \tag{3.2}$$

где $a_{t+1} \sim \pi(a_{t+1}|s_{t+1})$.

Стратегия оптимизируется при помощи функции лагранжиана:

$$L(\theta,\lambda) = \mathbb{E}\Big[\alpha' \log \pi_\theta(a_t|s_t) - Q_r^{\pi_\theta}(s_t,a_t) + \lambda Q_c^{\pi_\theta}(s_t,a_t)\Big]. \tag{3.3}$$

Множитель Лагранжа λ обучается адаптивно за счёт минимизации функции потерь:

$$J_s(\lambda) = \mathbb{E}\Big[\lambda\big(Q_c^{\pi_\theta}(s_t,a_t) - d\big)\Big]. \tag{3.4}$$

Такое правило обновления уменьшает вес безопасности λ, когда ограничение выполняется, то есть $Q_c^{\pi_\theta}(s_t,a_t) \leqslant d$, и увеличивает его при нарушении ограничения. В результате при превышении допустимого бюджета штрафов оптимизация стратегии сильнее штрафует небезопасные действия.

В реализации для критиков вознаграждения и штрафов используются парные Q-функции: $\{Q_{r,1}, Q_{r,2}\}$ и $\{Q_{c,1}, Q_{c,2}\}$. При вычислении целевых значений Беллмана берётся минимум по соответствующим целевым критикам, что снижает переоценку значений. Целевые сети для всех критиков обновляются с помощью полиномиального усреднения с коэффициентом $\tau = 0.005$. Следующее действие a_{t+1} выбирается текущей стратегией π_θ, а целевое значение включает стандартный энтропийный член SAC: $-\alpha' \log \pi_\theta(a_{t+1} \mid s_{t+1})$. Температура энтропии $\alpha' = 0.1$ рассматривается как фиксированный гиперпараметр.

3.1.2 Стратегия, генерирующая подцели

Стратегия, генерирующая подцели используется для повышения эффективности обучения в задачах с большим горизонтом. Она генерирует промежуточные подцели между начальным состоянием и конечной целью, тем самым направляя низкоуровневую стратегию к достижимым и информативным состояниям. В основе данного компонента лежит подход RIS [88], включающий стратегию, генерирующую подцели и низкоуровневую стратегию. Стратегия, генерирующая подцели формирует достижимые подцели и при этом сохраняет согласованность с распределением состояний, которые агент способен посещать, за счёт ограничения дивергенции Кульбака–Лейблера.

Пусть V^{π_θ} обозначает функцию оценки накопленных вознаграждений. Тогда для подцели s_g вводится величина

$$\psi_{\pi_\theta}(s_g|s,g) = \max\left(\left|V^{\pi_\theta}(s,s_g)\right|, \left|V^{\pi_\theta}(s_g,g)\right|\right). \tag{3.5}$$

Она оценивает, насколько сложно достичь подцели из текущего состояния и затем достичь конечной цели из этой подцели.

Стратегия, генерирующая подцели π^H выбирает такие подцели, которые находятся в середине пути от s до g с точки зрения метрики $|V^{\pi_\theta}(s,g)|$. Обновление стратегии, генерирующей подцели выполняется при ограничении относительно распределения посещаемых состояний p_s:

$$\pi^H = \arg\max \mathbb{E}\left[A^{\pi_k^H}(\hat{s}_g|s,g)\right], \quad \text{s.t.} \quad D_{\mathrm{KL}}\left(\pi^H(\cdot|s,g) \,\|\, p_s(\cdot)\right) \leqslant \varepsilon. \tag{3.6}$$

Здесь функция преимущества определяется как

$$A^{\pi_k^H}(\hat{s}_g|s,g) = \mathbb{E}\left[\psi_{\pi_\theta}(\hat{s}_g|s,g) - \psi_{\pi_\theta}(s_g|s,g)\right], \tag{3.7}$$

и измеряет ожидаемое улучшение при использовании выбранной подцели, где $\hat{s}_g \sim D$ из буфера HER.

Для обучения низкоуровневой стратегии для каждого перехода выбирается подцель $s_g \sim \pi^H$. Затем низкоуровневая стратегия оптимизируется так, чтобы максимизировать значение функции оценки накопленных вознаграждений и одновременно уменьшать расхождение между распределением действий при условии конечной цели и распределением действий при условии подцели:

$$\pi_\theta = \arg\max \mathbb{E}\left[Q_r^{\pi_\theta}(s,a,g) - \alpha D_{\mathrm{KL}}\left(\pi_\theta(\cdot|s,g) \,\|\, \pi_\theta(\cdot|s,s_g)\right)\right]. \tag{3.8}$$

Таким образом, подцели направляют низкоуровневую стратегию к промежуточным состояниям, но при этом не заменяют исходную цель задачи.

3.1.3 Обновление безопасной стратегии с применением подцелей

SG-Safe объединяет стратегию, генерирующую подцели, с оптимизацией стратегии при ограничениях безопасности для решения задач безопасного исследования с большим горизонтом. Во время обучения подцели направляют

Алгоритм 1 SG-Safe

Инициализировать буфер HER D
Инициализировать $Q_r^{\pi_\theta}$, $Q_c^{\pi_\theta}$, π_θ, λ, π^H
for $k = 1, 2, \ldots$ **do**
    Собрать опыт в среде с помощью стратегии π_θ и сохранить его в D
    Выбрать мини-пакет переходов $(s_t, a_t, r_t, c_t, s_{t+1}, g) \sim D$
    Выбрать мини-пакет кандидатов подцелей $s'_g \sim D$
    Обновить $Q_r^{\pi_\theta}$ и $Q_c^{\pi_\theta}$ с использованием ошибок Беллмана с учётом энтропии
    Обновить множитель Лагранжа λ
    Обновить стратегию, генерирующую подцели π^H
    Обновить безопасную стратегию π_θ с использованием подцелей
end for

исследование среды, а на этапе исполнения используется только обученная безопасная стратегия.

Модифицированная целевая функция безопасной стратегии учитывает как награду за выполнение задачи, так и ограничения безопасности:

$$J(\pi_\theta) = \mathbb{E}_{(s,g)\sim D}\mathbb{E}_{a\sim\pi_\theta(\cdot|s,g)}\Big[Q_r^{\pi_\theta}(s,a,g) - \lambda Q_c^{\pi_\theta}(s,a,g) - \alpha D_{\mathrm{KL}}\left(\pi_\theta(\cdot|s,g) \,\|\, \pi_\theta(\cdot|s,s_g)\right)\Big]. \tag{3.9}$$

Здесь $Q_r^{\pi_\theta}$ отвечает за максимизацию награды, $Q_c^{\pi_\theta}$ штрафует нарушения безопасности, а член с дивергенцией Кульбака–Лейблера направляет стратегию к действиям, согласованным с сгенерированной подцелью. Обозначение D соответствует буферу HER.

Как показано на рис. 3.2, сначала опыт собирается в среде только с помощью безопасной стратегии $\pi_\theta(\cdot|s,g)$ и сохраняется в буфер HER. Для улучшения сходимости в задачах с разреженным вознаграждением в траекториях, в которых агент не дошёл до изначальной цели, переопределяется функция вознаграждения относительно той цели, до которой фактически дошёл агент. Это позволяет получать более частые обучающие сигналы и повышает устойчивость обучения.

Далее из буфера HER выбираются мини-пакеты (batch) переходов, по которым обновляются критик награды $Q_r^{\pi_\theta}$, критик штрафов $Q_c^{\pi_\theta}$, безопасная стратегия π_θ и стратегия, генерирующая подцели π^H. Экспериментальные результаты показали, что использование двух критиков штрафов с минимальной агрегацией

их оценок обеспечивает устойчивый баланс между безопасностью и эффективностью.

Стратегия, генерирующая подцели формирует подцель s_g как полный вектор состояния, $s_g \in \mathcal{S}$. Благодаря этому не требуется вручную задавать отдельное пространство подцелей, как в ряде других иерархических подходов. Подцели используются как регуляризатор для безопасной стратегии, позволяя ей адаптивно балансировать между исследованием среды и соблюдением требований безопасности.

Безопасная стратегия реализована на основе адаптированной версии SAC-Lagrangian. Такой подход позволяет использовать произвольные функции штрафов без явного задания аналитической модели объекта управления, при этом нет необходимости знать явные функции вознаграждения или штрафов. Это отличает SG-Safe от методов, основанных на барьерных функциях, экранировании действий или дополнительных слоях безопасности.

3.2 Экспериментальная проверка метода SG-Safe

В данном разделе проводится экспериментальная проверка метода SG-Safe. Эксперименты направлены на ответ на следующие исследовательские вопросы.

RQ1. Улучшает ли использование стратегии, генерирующей подцели в SG-Safe безопасное исследование среды и итоговую эффективность безопасной стратегии?

RQ2. Как SG-Safe ведёт себя по сравнению с методами, требующими полной наблюдаемости среды или дополнительных априорных знаний, например Lyapunov-RRT, с точки зрения успешности решения задачи и вычислительной эффективности на этапе исполнения?

RQ3. Как SG-Safe сравнивается с современными методами безопасного обучения с подкреплением по балансу между безопасностью и эффективностью?

RQ4. Как ключевые компоненты и гиперпараметры метода, включая число критиков штрафов и параметры алгоритма, влияют на баланс между безопасностью и эффективностью?

Эксперименты проводились на графическом ускорителе NVIDIA TITAN RTX. Среднее время обучения на средах Safety Gym составило около 25 часов, а на средах POLAMP — около 48 часов.

Эксперименты проводились на задачах Safety Gym и POLAMP, описание которых приведено в разделе 1.8. Для Safety Gym используются целеобусловленные навигационные задачи с разными типами тел агента: Point, Car, Doggo и Sweeps. Эти задачи позволяют проверить, способен ли метод находить безопасные подцели и достигать целевого состояния, избегая опасных областей. Дополнительно метод оценивается на бенчмарке POLAMP, где агент с кинематической моделью велосипеда должен перемещаться в средах со статическими препятствиями и узкими коридорами. В экспериментах используются два набора задач различной сложности: Level 1 и Level 2. POLAMP используется для проверки способности метода решать более сложные задачи безопасной навигации с ограничениями на манёвры.

Оценка проводилась по метрикам, введённым в разделе 1.9. Для анализа используются доля успешных эпизодов (SR), частота столкновений (CR) и средний накопленный штраф безопасности за эпизод (MTSC). Метрика SR отражает способность агента достигать цели, а CR и MTSC характеризуют уровень нарушений безопасности. Совместный анализ этих метрик позволяет оценить баланс между успешностью решения задачи и безопасностью поведения агента.

Метод SG-Safe сравнивался с рядом базовых и современных методов безопасного обучения с подкреплением. Для всех обучаемых методов использовались согласованные гиперпараметры. Исключением является энкодер, который применялся только в среде POLAMP из-за более высокой размерности пространства состояний.

Базовые методы на Safety Gym. На средах Safety Gym метод SG-Safe сравнивался с SAC [89], SAC-LAG, CPO [42] и Lyapunov RRT (L-RRT) [26]. Все методы, кроме L-RRT, являются стратегиями, обучаемыми напрямую во взаимодействии со средой. Метод L-RRT сочетает планировщик RRT* [90] и контроллер на основе функции Ляпунова, а также предполагает полную наблюдаемость среды. Для методов использовались одинаковые настройки обучения, за исключением CPO, для которого применялась плотная функция награды. Для SAC использовался фиксированный коэффициент энтропии $H = 0.2$, допустимый бюджет нарушений $d = 3.0$ и начальное значение множителя Лагранжа $\lambda_0 = 0.5$.

Базовые методы на POLAMP. На бенчмарке POLAMP метод SG-Safe сравнивался с SAC, SAC-RCBF [10], SAC-LAG, SAC-NCMP [91], ADVICE [47], L-RRT и классическим RRT с управлением Дубинса [92]. Метод SAC-RCBF использует квадратичное программирование для вычисления безопасных действий. Метод SAC-NCMP реализует постановку марковского процесса принятия решений с ограничением на вероятность нарушения безопасности. Метод L-RRT обучался в средах без препятствий при полной наблюдаемости состояния $(x, y, \theta, v, \delta)$ и затем оценивался с использованием геометрического планировщика RRT* [26].

Каждая из 96 задач на уровнях сложности Level 1 и Level 2 запускалась 5 раз для повышения устойчивости оценки. Метод ADVICE относится к подходам с фильтрацией действий после выбора стратегии: он обучает контрастивную латентную модель переходов для разделения безопасных и небезопасных областей, после чего применяет непараметрический фильтр для замены действий, предсказанных как небезопасные.

Все обучаемые методы использовали одинаковые настройки обучения на соответствующих бенчмарках. Метод CPO рассматривался только на Safety Gym, поскольку эти задачи имеют меньшую размерность и более простую динамику. В задачах POLAMP метод CPO не обучал содержательную стратегию. Для POLAMP дополнительно включён метод SAC-RCBF, основанный на фильтрации действий с использованием информации о динамике робота. Это позволяет сравнить SG-Safe с семейством методов, требующих дополнительной информации, недоступной стандартным агентам обучения с подкреплением.

3.2.1 Улучшение безопасного исследования

Для оценки влияния стратегии, генерирующей подцели, на качество безопасной стратегии было проведено несколько экспериментов. Метод SG-Safe сравнивался с тремя базовыми методами: SAC, SAC-Lagrangian (SAC-LAG) и SG-NoSafe (см. рис. 3.3). Метод SG-NoSafe соответствует исходному методу RIS без ограничений безопасности и использует коэффициент влияния подцелей $\alpha = 0.05$. Он был включён в сравнение для явной оценки вклада безопасной стратегии. При этом SAC-LAG и SG-Safe учитывают ограничения безопасности во время

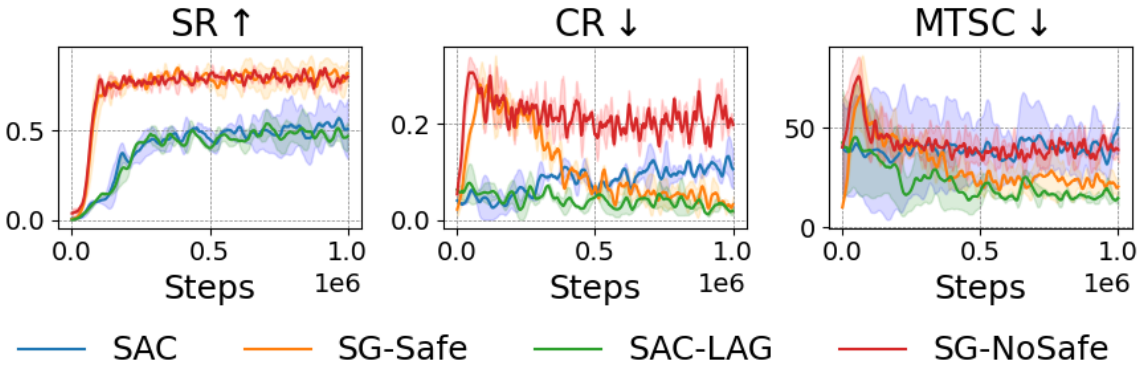


Рисунок 3.3 — Обучение SAC, SAC-LAG, SG-NoSafe и SG-Safe в среде Safety Gym Point. Показаны доля успешных эпизодов (SR), MTSC ($C(\pi)$), частота столкновений (CR) и число взаимодействий со средой. Результаты усреднены по трём запускам.

обучения, а SG-Safe и SG-NoSafe дополнительно используют стратегию, генерирующую подцели для решения задач с большим горизонтом.

Эксперименты на бенчмарке Safety Gym (рис. 3.3) показывают, что включение стратегии, генерирующей подцели в SG-Safe увеличивает долю успешных эпизодов до 0.40 по сравнению с SAC-Lagrangian при сохранении уровня безопасности, сопоставимого с SAC-Lagrangian. Это показывает, что SG-Safe успешно совмещает исследование среды через подцели с ограничениями безопасности, тем самым улучшая безопасное исследование. Сходные тенденции наблюдаются в табл. 4–6 и табл. 7–9. Наиболее заметное отличие видно в POLAMP Level 2 (табл. 8). В этой постановке SAC-LAG не достигает цели: доля успешных эпизодов остаётся равной нулю. Это указывает на то, что методов на основе функции лагранжиана оказывается недостаточно для выхода из локального поведения. SG-Safe, напротив, использует подцели как дополнительный обучающий сигнал и за счёт этого находит траектории к цели даже при частичной наблюдаемости. В результате метод достигает ($SR = 0.84$) при сохранении низкой частоты нарушений безопасности.

3.2.2 Сравнение с методами, использующими априорную информацию

В этом блоке SG-Safe сравнивался с методами, которые требуют априорной информации о среде. Таким методом является L-RRT.

Результаты в табл. 7–9 показывают, что SG-Safe достигает меньшего значения MTSC в отличие от L-RRT, поскольку L-RRT может строить геометрически проходимые траектории с точки зрения модели объекта управления робота, но такие траектории могут быть длиннее, чем у SG-Safe, и проходить близко к препятствиям. Поскольку контроллер в L-RRT на основе функции Ляпунова не учитывает информацию о препятствиях во время слежения по траектории, он может сталкиваться с препятствиями.

Отдельно был проведён эксперимент на устойчивость SG-Safe и L-RRT при увеличении числа препятствий в среде Safety Gym (рис. 3.4). Количество препятствий менялось от $N_{\text{obs}} = 2$ до $N_{\text{obs}} = 10$; по результатам SG-Safe демонстрирует более устойчивое поведение при росте количества препятствий и не допускает столкновений до $N_{\text{obs}} = 6$, в то время как L-RRT сильно увеличивает количество столкновений, начиная с $N_{\text{obs}} = 4$. При $N_{\text{obs}} = 8$–10 различие становится сильнее, поскольку L-RRT становится сложнее построить допустимые траектории.

Результаты в табл. 10 показывают различие между планировщиками более детально. RRT с кривыми Дубинса может давать высокую долю успешных эпизодов, но его траектории проходят близко к препятствиям и используют только кинематическое управление (v,γ). В L-RRT дополнительно возникает проблема отслеживания траектории в узких коридорах: промежуточные точки могут быть геометрически допустимыми, но труднодостижимыми для контроллера. В таких случаях агент либо сталкивается с препятствием, либо останавливается из-за блокировки следующего действия защитным фильтром.

SG-Safe устроен иначе. Он не строит отдельную траекторию во время исполнения, а сразу выдаёт кинодинамически допустимое действие (a,ω) обученной стратегией. Поэтому на этапе применения метод не тратит время на планирование и работает примерно в 10 раз быстрее, сохраняя конкурентную долю успешных эпизодов и лучшее время достижения цели. Рис. 3.5 показывает типичные ошибки L-RRT в коридорных задачах и иллюстрирует, почему отсутствие отдельного планировщика во время исполнения может быть преимуществом для SG-Safe.

SG-Safe требует дополнительных вычислений на этапе обучения, поскольку оптимизирует дополнительную стратегию, генерирующую подцели (формула 3.9) вместе со стандартными обновлениями безопасного актор-критика по мини-пакетам из буфера воспроизведения опыта. Однако эти дополнительные затраты ограничены этапом обучения и не влияют на применение метода. На эта-

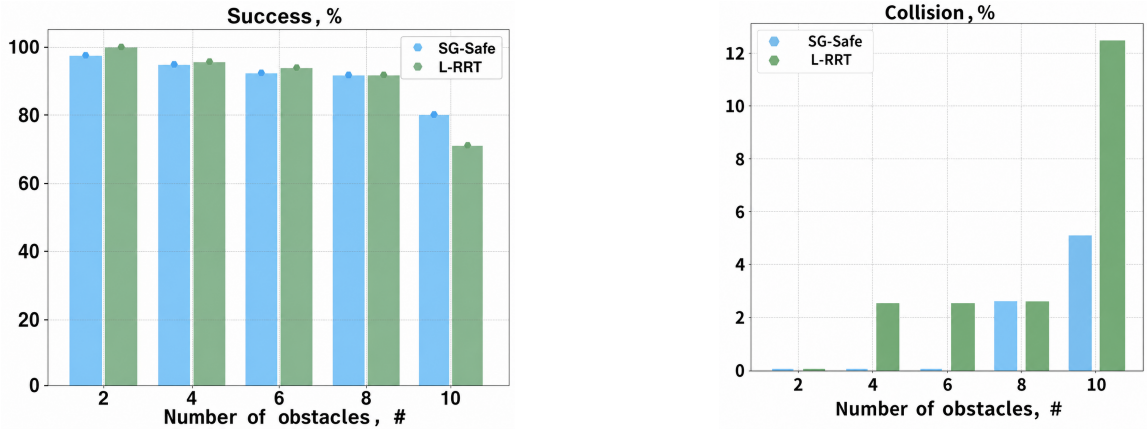


Рисунок 3.4 — Сравнение SG-Safe и Lyapunov RRT в Safety Gym Point при разном числе препятствий. **Слева** показана доля успешных эпизодов, **справа** — частота столкновений. Результаты усреднены по трём запускам.

пе исполнения стратегия, генерирующая подцели отбрасывается, и используется только обученная безопасная низкоуровневая стратегия. Поэтому вычисление действия на каждом шаге сводится к одному прямому проходу через актор, что сопоставимо с SAC-LAG. В отличие от этого, методы на основе планирования дополнительно требуют затрат на планирование и отслеживание траектории во время исполнения, например ненулевого времени планирования в табл. 10, чего предложенный метод избегает на этапе применения.

3.2.3 Сравнение с базовыми методами

Бенчмарк Safety Gym. В табл. 4–6 приведены результаты на Safety Gym. Среди обучаемых методов SG-Safe достигает наименьшей средней частоты столкновений ($CR = 0.03$, табл. 6), сохраняя высокую долю успешных эпизодов ($SR = 0.87$). SAC-LAG достигает немного меньшего значения MTSC, однако это в основном связано с чрезмерно консервативным поведением: стратегия часто остаётся неподвижной, что снижает воздействие опасных зон, но ухудшает выполнение задачи. В отличие от SAC-LAG, SG-Safe сохраняет направленное к цели поведение и снижает число столкновений за счёт остановки на безопасном расстоянии от опасных зон. Также наблюдается, что SG-Safe может превосходить SG-NoSafe на некоторых задачах, например Point и Doggo, что показывает: явная оптимизация безопасности может повышать эффективность исследования за счёт предотвра-

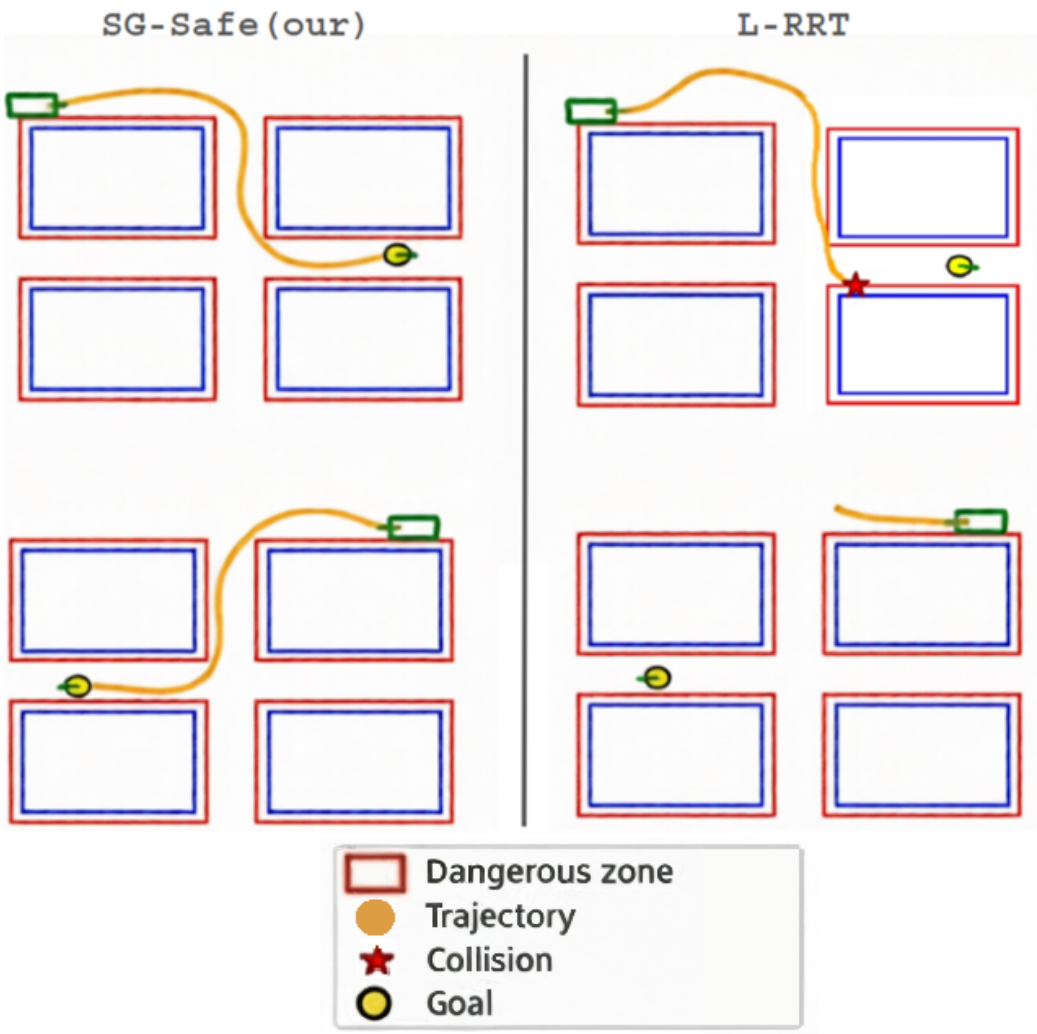


Рисунок 3.5 — Примеры траекторий SG-Safe и L-RRT в задачах POLAMP.

щения небезопасных обходных траекторий и повторного восстановления после нарушений.

Бенчмарк POLAMP. Результаты на POLAMP приведены в табл. 7–9 и табл. 10. Наиболее сложной является постановка Level 2, где агенту требуется проходить длинные маршруты при частичной наблюдаемости и наличии препятствий. В этой группе задач SG-Safe достигает доли успешных эпизодов ($SR = 0.897$), тогда как у одноуровневых базовых методов значения находятся в диапазоне 0–0.363. При этом метод сохраняет низкое значение MTSC. Такой результат показывает, что подцели в SG-Safe не просто ускоряют обучение, а помогают агенту находить траектории, которые одноуровневая стратегия с ограничениями обычно не обнаруживает.

В сравнение также включён ADVICE как метод, использующий дополнительную информацию для фильтрации действий. В POLAMP он показывает почти

Таблица 4 — Результаты на Safety Gym Point и Car. Значения — среднее по трём случайным запускам. SR — доля успешных эпизодов, CR — частота столкновений, MTSC — Mean Total Safety Cost, средний накопленный штраф безопасности за эпизод ($C(\pi)$); меньше — лучше для CR и MTSC. Жирным выделены лучшие значения в каждой среде; красным — методы с полной наблюдаемостью.

Method	SR↑	CR↓	MTSC↓
Point			
SG-Safe (ours)	0.93	**0.02**	20.7
SG-NoSafe	0.89	0.11	33.2
L-RRT	**1**	0.00	42.2
SAC-LAG	0.54	0.04	**13.4**
SAC	0.61	0.12	26.3
CPO	0.60	0.28	146.1
Car			
SG-Safe (ours)	0.75	**0.05**	20.7
SG-NoSafe	0.76	0.24	33.4
L-RRT	**0.95**	**0.05**	37.6
SAC-LAG	0.56	**0.04**	**13.8**
SAC	0.30	0.78	17.3
CPO	0.62	0.33	133.6

нулевую долю успешных эпизодов. Одна из причин состоит в том, что метод основан на DDPG и не использует переопределение целей в стиле HER, что особенно важно в задачах с большим горизонтом и разреженным вознаграждением. Поэтому для SAC-подобных базовых методов в данной работе используется HER, чтобы сравнение было устойчивым и не сводилось только к проблеме редкого обучающего сигнала.

Методы с фильтрацией действий во время исполнения, например SAC-RCBF, требуют дополнительного знания о модели объекта управления и несут дополнительные вычислительные затраты на этапе выбора действия. Одноуровневые методы, такие как SAC и SAC-LAG, в Level 2 также оказываются недостаточными: штрафы ограничивает исследование, но не даёт механизма, который направлял бы агента через длинную последовательность промежуточных состояний.

Разброс между случайными запусками связан главным образом со стохастической инициализацией сетей, выборкой мини-пакетов из HER и шумом

Таблица 5 — Результаты на Safety Gym Doggo и Sweeps. Обозначения метрик — см. табл. 4.

Method	SR↑	CR↓	MTSC↓
Doggo			
SG-Safe (ours)	0.79	**0.05**	**12.5**
SG-NoSafe	0.74	0.20	40.2
L-RRT	**0.93**	0.08	17.1
SAC-LAG	0.02	0.10	22.6
SAC	0.08	0.15	44.63
CPO	0.65	0.30	86.8
Sweeps			
SG-Safe (ours)	**1**	**0**	**0.98**
SG-NoSafe	**1**	**0**	12.87
L-RRT	**1**	**0**	9.0
SAC-LAG	0.47	**0**	1.25
SAC	0.55	0.05	5.16
CPO	0.15	0.85	102

Таблица 6 — Усреднённые результаты на Safety Gym (Avg.) по средам Point, Car, Doggo и Sweeps. Обозначения метрик — см. табл. 4.

Method	SR↑	CR↓	MTSC↓
SG-Safe (ours)	0.87	**0.03**	**13.7**
SG-NoSafe	0.85	0.14	29.9
L-RRT	**0.97**	0.03	26.5
SAC-LAG	0.40	**0.05**	12.8
SAC	0.39	0.28	23.3
CPO	0.51	0.44	117.1

исследования. В Safety Gym дополнительный вклад дают случайные начальные положения целей и опасных зон. POLAMP устроен более детерминированно, поэтому там вариативность результатов в большей степени определяется самим процессом оптимизации.

В целом SG-Safe достигает лучшего баланса между безопасностью и эффективностью на обоих бенчмарках среди сквозных методов обучения с подкреплением, сохраняя применимость в рассматриваемой постановке с частичной наблюдаемостью и ограниченной информацией о среде.

Таблица 7 — Результаты на POLAMP Level 1 с указанием неопределённости. Каждая метрика — среднее ± стандартное отклонение; ниже указан 95%-ный бутстрэп-доверительный интервал (CI95). SR — доля успешных эпизодов, CR — частота столкновений, MTSC — Mean Total Safety Cost, средний накопленный штраф безопасности за эпизод. Красным выделены методы с привилегированной информацией и/или явными моделями.

Method	SR↑	CR↓	MTSC↓
SG-Safe (ours)	**0.919±0.009**	**0.025±0.012**	1.567±0.331
	CI95 [0.913, 0.925]	CI95 [0.017, 0.033]	CI95 [1.288, 1.838]
SAC-LAG	0.727±0.011	0.029±0.009	6.765±2.954
	CI95 [0.717, 0.735]	CI95 [0.023, 0.035]	CI95 [5.069, 9.456]
SAC	0.610±0.040	0.023±0.014	11.252±3.718
	CI95 [0.579, 0.642]	CI95 [0.010, 0.031]	CI95 [8.221, 14.002]
SAC-NCMP	0.427±0.000	0.573±0.000	**0.869±0.015**
	CI95 [0.427, 0.427]	CI95 [0.573, 0.573]	CI95 [0.856, 0.880]
SAC-RCBF	0.344±0.032	0.240±0.025	4.456±3.076
	CI95 [0.320, 0.368]	CI95 [0.220, 0.256]	CI95 [2.236, 6.834]
ADVICE	0.000±0.000	0.031±0.000	0.031±0.000
	CI95 [0.000, 0.000]	CI95 [0.031, 0.031]	CI95 [0.031, 0.031]
L-RRT	0.551±0.152	0.350±0.028	8.335±1.898
	CI95 [0.444, 0.672]	CI95 [0.331, 0.373]	CI95 [6.996, 9.990]

Таблица 8 — Результаты на POLAMP Level 2 с указанием неопределённости. Обозначения метрик — см. табл. 7.

Method	SR↑	CR↓	MTSC↓
SG-Safe (ours)	**0.875±0.052**	**0.031±0.017**	5.103±2.632
	CI95 [0.843, 0.915]	CI95 [0.018, 0.044]	CI95 [2.838, 6.981]
SAC-LAG	0.000±0.000	**0.004±0.006**	1.319±0.802
	CI95 [0.000, 0.000]	CI95 [0.000, 0.008]	CI95 [0.763, 2.004]
SAC	0.000±0.000	0.010±0.015	5.054±2.325
	CI95 [0.000, 0.000]	CI95 [0.000, 0.023]	CI95 [3.340, 7.035]
SAC-NCMP	0.000±0.000	1.000±0.000	1.369±0.020
	CI95 [0.000, 0.000]	CI95 [1.000, 1.000]	CI95 [1.350, 1.383]
SAC-RCBF	0.008±0.010	0.050±0.025	8.625±1.823
	CI95 [0.000, 0.015]	CI95 [0.030, 0.070]	CI95 [7.188, 10.133]
ADVICE	0.000±0.000	0.010±0.000	**0.010±0.000**
	CI95 [0.000, 0.000]	CI95 [0.010, 0.010]	CI95 [0.010, 0.010]
L-RRT	0.125±0.050	0.664±0.165	12.154±4.167
	CI95 [0.089, 0.160]	CI95 [0.547, 0.780]	CI95 [9.208, 15.100]

Таблица 9 — Усреднённые результаты на POLAMP (Avg.) по Level 1 и Level 2 с указанием неопределённости. Обозначения метрик — см. табл. 7.

Method	SR↑	CR↓	MTSC↓
SG-Safe (ours)	**0.897±0.026**	0.028±0.010	3.335±1.327
	CI95 [0.878, 0.920]	CI95 [0.017, 0.039]	CI95 [2.063, 4.409]
SAC-LAG	0.364±0.006	**0.017±0.005**	4.042±1.530
	CI95 [0.358, 0.368]	CI95 [0.012, 0.022]	CI95 [2.916, 5.730]
SAC	0.305±0.020	**0.017±0.010**	8.153±2.192
	CI95 [0.290, 0.321]	CI95 [0.005, 0.027]	CI95 [5.780, 10.519]
SAC-NCMP	0.214±0.000	0.787±0.000	1.119±0.012
	CI95 [0.214, 0.214]	CI95 [0.787, 0.787]	CI95 [1.103, 1.131]
SAC-RCBF	0.176±0.017	0.145±0.017	6.541±1.788
	CI95 [0.160, 0.192]	CI95 [0.125, 0.163]	CI95 [4.712, 8.483]
ADVICE	0.000±0.000	0.021±0.000	**0.021±0.000**
	CI95 [0.000, 0.000]	CI95 [0.021, 0.021]	CI95 [0.021, 0.021]
L-RRT	0.338±0.080	0.507±0.084	10.245±2.289
	CI95 [0.267, 0.416]	CI95 [0.439, 0.576]	CI95 [8.102, 12.545]

Таблица 10 — Результаты экспериментов на средах POLAMP метода SG-Safe и классическими планировщиками. TTR — время достижения цели в шагах среды, PT — время планирования в секундах, ET — время исполнения в секундах. Базовые методы, выделенные красным, используют полную информацию о состоянии, включая точные положения препятствий и геометрию робота.

Method	SR↑	CR↓	MTSC↓	TTR↓, t	PT↓, s	ET↓, s
Level 1						
SG-Safe (ours)	0.92	0.03	**1.57**	**47.52**	**0**	$9 \cdot 10^{-3}$
L-RRT	0.55	0.35	8.34	104.2	10.4	$9 \cdot 10^{-3}$
RRT	**1**	0	2.1	86.3	18.3	–
Level 2						
SG-Safe (ours)	0.88	0.03	**5.10**	164.53	**0**	$9.3 \cdot 10^{-3}$
L-RRT	0.12	0.66	12.15	170.1	30.2	$9.2 \cdot 10^{-3}$
RRT	**1**	0	9	**111.4**	51.4	–

3.2.4 Анализ компонент метода

Анализ архитектуры критика штрафов. Был исследован алгоритм SG-Safe с архитектурами, использующими один и два критика штрафов $Q_c^{\pi_\theta}$. Для проверки устойчивости результатов при разных конфигурациях были проведены экспе-

рименты в среде Safety Gym с двумя роботами: Point и Car. В существующей литературе встречаются реализации как с одним критиком [17], так и с двумя критиками [93], однако сравнительный анализ этих архитектур ранее не проводился.

Результаты, приведённые на рис. 3.6, показывают, что использование одного критика штрафов приводит к переоценке дисконтированных накопленных штрафов $J_C(\pi)$. В результате алгоритм становится более консервативным и сильнее приоритизирует безопасность в ущерб эффективности решения задачи. Такой же эффект наблюдается при выборе максимального значения между двумя критиками. В случае выбора минимального значения агент становится менее консервативным и больше исследует среду. В SG-Safe используется минимальная агрегация оценок критиков, поскольку это способствует лучшему исследованию среды, а эпизодические штрафы остаются в рамках допустимого бюджета нарушений d.

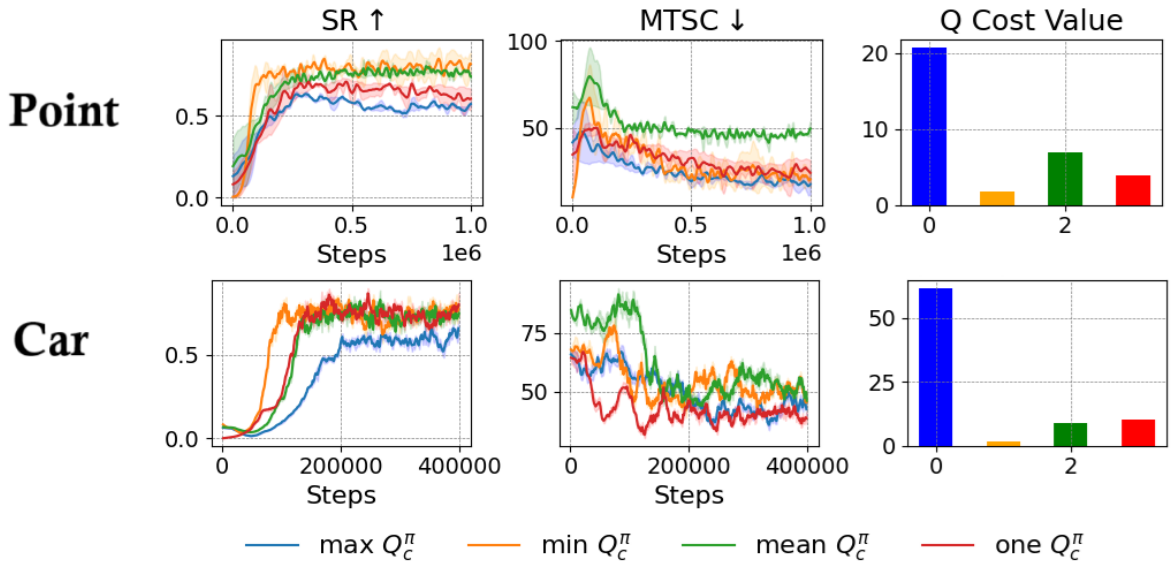


Рисунок 3.6 — Влияние числа критиков штрафов ($Q_c^{\pi_\theta}$) на обучение SG-Safe в средах Safety Gym Point и Safety Gym Car. Показаны доля успешных эпизодов (SR), MTSC ($C(\pi)$), итоговая оценка критика штрафов и число взаимодействий со средой. Результаты усреднены по трём запускам.

Анализ чувствительности к гиперпараметрам. Дополнительно был произведён абляционный анализ гиперпараметров метода: вес влияния подцелей (α), начальное значение множителя Лагранжиана (λ_0), допустимый бюджет нарушений (d) (рис. 3.7).

Наиболее заметный эффект даёт гиперпараметр α. При $\alpha = 1.0$ подцели начинают слишком сильно влиять на обновление стратегии, и обучение становится

неустойчивым: доля успешных эпизодов снижается до 0.2. Это связано с тремя факторами: 1) плохое качество подцелей вначале обучения, 2) наличие задач с коротким горизонтом, которые могут быть решены без подцелей (где подцели потенциально могут мешать решению), 3) в случае небезопасных подцелей большое α заставляет агента их достигать, из-за чего безопасная стратегия вынуждена стоять на месте, чтобы не нарушать ограничения.

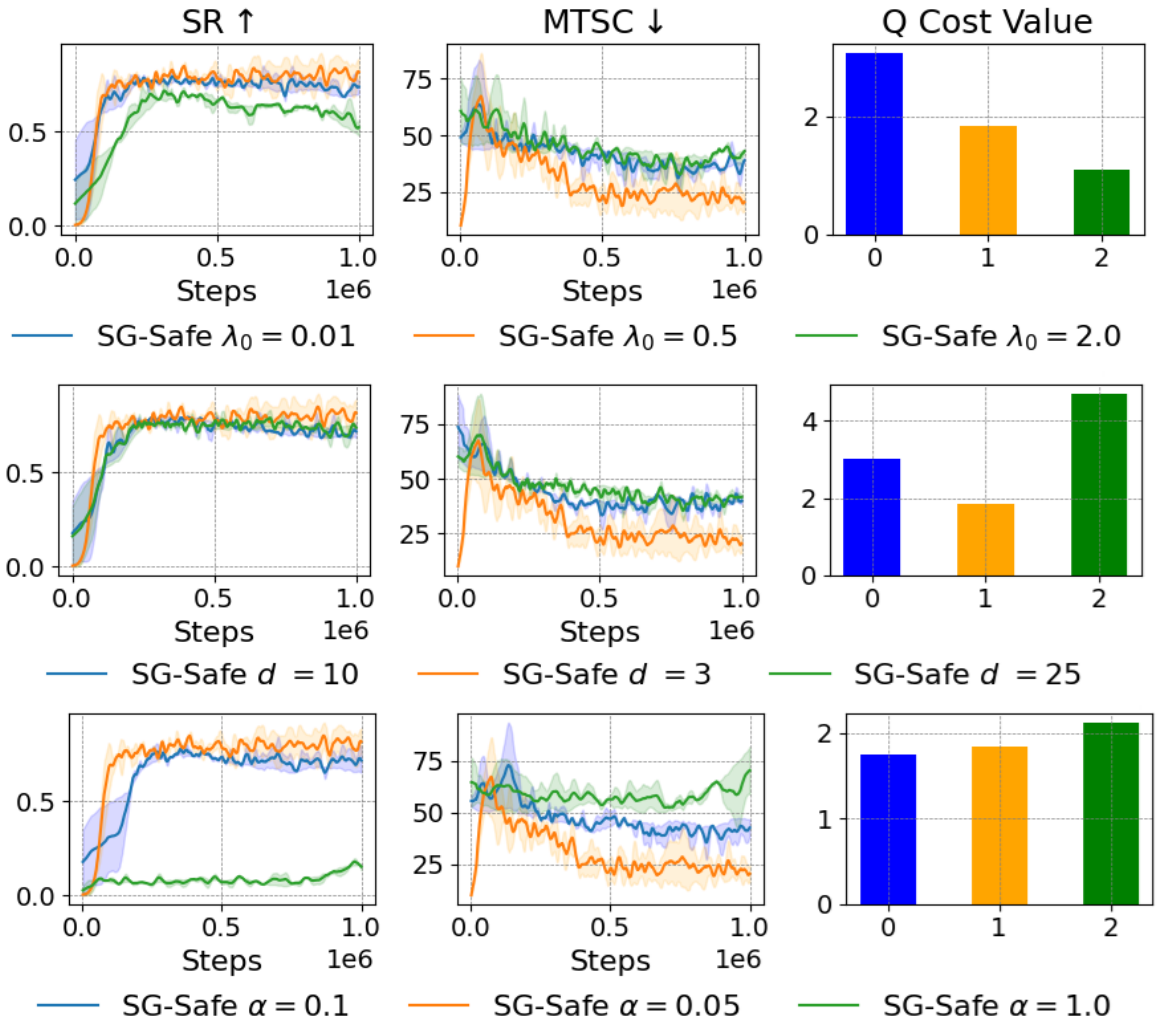


Рисунок 3.7 — Исследование гиперпараметров алгоритма SG-Safe: начального значения множителя Лагранжа λ_0, бюджета штрафов d и коэффициента α в среде Safety Gym Point. SR — доля успешных эпизодов, MTSC — Mean Total Safety Cost, средний накопленный штраф безопасности за эпизод ($C(\pi)$). Эксперименты проводились по трём случайным запускам.

Основные выводы анализа компонент метода:

– **Критики штрафов**: два критика с выбором минимального значения обеспечивают наилучший баланс между безопасностью и эффективностью.

– **Влияние подцелей** (α): меньшие значения ($\alpha < 1.0$) предотвращают расхождение в обучении.
– **Коэффициент безопасности** (λ_0): умеренная инициализация позволяет эффективно обучать ограничения безопасности.
– **Бюджет штрафов** (d): более строгие ограничения повышают безопасность, но снижают эффективность решения задачи.

3.3 Выводы по главе

В данной главе был представлен метод SG-Safe, направленный на повышение исследовательской способности безопасных стратегий в задачах с большим горизонтом. Метод использует стратегию, генерирующую подцели на этапе обучения: подцели не являются жёсткими командами, а выступают как дополнительный обучающий сигнал, смещающий безопасную стратегию к более информативным областям пространства состояний. На этапе исполнения используется только обученная безопасная стратегия, поэтому SG-Safe является вычислительно эффективным подходом.

Экспериментальные результаты показывают, что SG-Safe улучшает баланс между достижением цели и безопасностью по сравнению с другими методами безопасного обучения с подкреплением. На Level 2 бенчмарка POLAMP, состоящего из навигационных задач с большим горизонтом, безопасные стратегии не способны решать задачу: SAC-LAG и SAC достигают $SR = 0$, как и другие базовые методы. В то время как SG-Safe достигает $SR = 0.875$ при $CR = 0.031$. Эти результаты показывают, что подцели помогают агенту выходить из локального минимума и исследовать среду для решения задачи.

В сравнении с L-RRT метод SG-Safe не требует априорных знаний о среде, работая с частичной наблюдаемостью, а также не требует вычислительных ресурсов для планирования, при этом достигая лучшего качества решения задач и соблюдения ограничений: на Level 2 бенчмарка POLAMP L-RRT имеет $SR = 0.125$ при $CR = 0.664$ против SG-Safe с $SR = 0.875$ при $CR = 0.031$.

Эти результаты показывают, что стратегия, генерирующая подцели, помогает закрыть слабое место безопасных стратегий — недостаточное исследование в задачах большого горизонта. При этом важно отметить ограничение метода: без-

опасность подцелей не имеет строгих гарантий. Поэтому следующий шаг состоит в контроле безопасности непосредственно на уровне выбора подцелей и на уровне исполнения действий, что рассматривается в следующей главе.

Глава 4. Развитие иерархического безопасного обучения с подкреплением с использованием модели мира

В предыдущей главе был рассмотрен метод SG-Safe, использующий генерацию промежуточных подцелей для улучшения исследовательских способностей безопасной стратегии. Однако в SG-Safe безопасность самих подцелей не гарантируется явно. Метод ITES, рассматриваемый в данной главе, решает более сильную задачу: обеспечить безопасность как при выборе промежуточных подцелей, так и при их достижении низкоуровневой стратегией (рис. 4.1).

Основная проблема состоит в том, что существующие методы безопасного обучения с подкреплением плохо работают в задачах с большим горизонтом. Одноуровневые безопасные стратегии часто не способны одновременно исследовать среду, достигать удалённой цели и соблюдать ограничения безопасности: они либо нарушают ограничения, либо становятся чрезмерно консервативными и не находят успешное поведение. Эта проблема особенно выражена в задачах с длинной последовательностью действий, сложной динамикой агента, высокой размерностью пространства действий или разреженным вознаграждением.

Метод ITES [28] (Imagine To Ensure Safety in Hierarchical Reinforcement Learning) продолжает линию иерархического безопасного обучения, но делает отдельный акцент на безопасности самой иерархии. В SG-Safe подцели в основном помогали безопасной стратегии лучше исследовать среду. В ITES дополнительно проверяется, какие подцели предлагает верхний уровень и насколько безопасно низкоуровневая стратегия движется к выбранной подцели.

4.1 Метод ITES

Предложенный подход обеспечивает безопасность на двух взаимодополняющих уровнях: при генерации безопасных подцелей и при безопасном достижении выбранных подцелей. Для генерации подцелей, расположенных в безопасной области пространства состояний, используется модель штрафов C_M, классифицирующая состояния как безопасные или небезопасные, а также верхнеуровневый критик штрафов $Q_c^h(s, s_g, g)$, оценивающий ожидаемые накопленные штрафы при

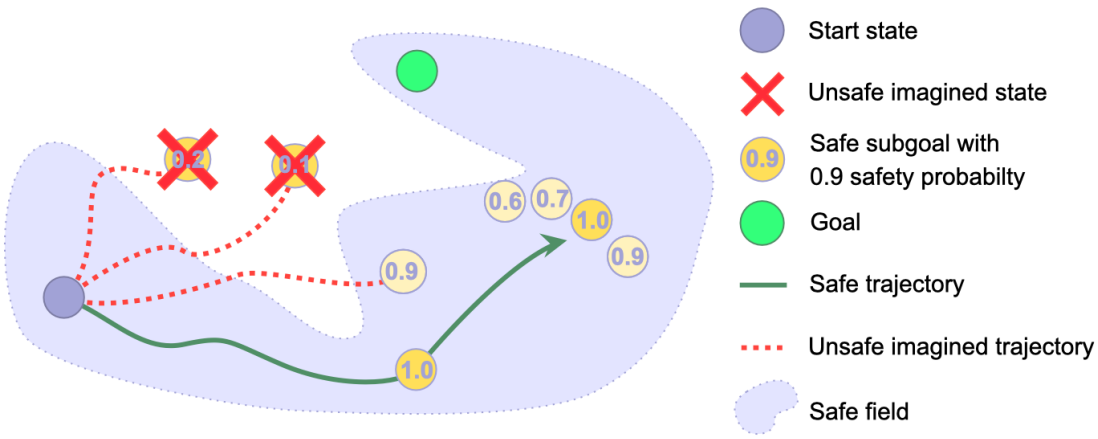


Рисунок 4.1 — Схема метода ITES. Верхний уровень выбирает промежуточные подцели с учётом штрафов, а нижний уровень проверяет безопасность движения к ним с помощью модели мира.

выборе подцели s_g. Эти компоненты направляют верхнеуровневую стратегию к подцелям, которые одновременно являются безопасными и достижимыми.

Для безопасного достижения выбранных подцелей используется модель мира M, предсказывающая короткие фрагменты траектории в виде переходов $s' = M_{\theta_m}(s, a)$. В сочетании с моделью штрафов C_M модель мира позволяет оценивать безопасность низкоуровневых траекторий до выполнения действий в среде. Благодаря этому низкоуровневая стратегия может избегать небезопасного поведения при движении к заданной подцели.

Иерархическая структура. В качестве базового алгоритма используется HRAC [24] (Hierarchical Reinforcement Learning with k-step Adjacency Constraint). Данный метод включает две стратегии: верхнеуровневую стратегию $\pi^h_{\theta_h}(s_g|s, g)$ и низкоуровневую стратегию $\pi^l_{\theta_l}(a|s, s_g)$. Основная идея HRAC состоит в генерации подцелей, расположенных на заданном расстоянии k от текущего состояния агента. Для этого используется сеть смежности ψ, которая отображает каждое состояние s в его векторное представление $\psi(s)$. Данная сеть обучается с использованием следующей функции потерь:

$$L_{adj} = \mathbb{E}_{s_i,s_j\in\mathcal{S}}\Big[l \cdot \max\left(\|\psi(s_i) - \psi(s_j)\| - \varepsilon, 0\right) + (1-l) \cdot \max\left(\varepsilon + \delta - \|\psi(s_i) - \psi(s_j)\|, 0\right)\Big]. \tag{4.1}$$

где $\delta > 0$ задаёт зазор между векторными представлениями, ε является масштабирующим коэффициентом, а $l \in \{0, 1\}$ обозначает метку k-шаговой смежности. Эта функция потерь позволяет обучить сеть смежности так, чтобы для состояний s_i и

s_j, достижимых друг из друга за k шагов, выполнялось условие $\|\psi(s_i) - \psi(s_j)\| < \varepsilon$.

Далее сеть смежности используется при обновлении верхнеуровневой стратегии на основе алгоритма TD3 [94]. Для этого в функцию потерь верхнеуровневой стратегии добавляется дополнительный член:

$$L^h = -Q^h_{\theta_{qh}}(s, s_g, g) + \beta^h_{adj} L_{adj}(s, s_g), \tag{4.2}$$

где β^h_{adj} — коэффициент при функции потерь смежности, являющийся масштабирующим гиперпараметром. Для низкоуровневой стратегии используется алгоритм TD3 без дополнительных модификаций со следующей функцией потерь:

$$L^l = -Q^l_{\theta_{ql}}(s, a, s_g), \tag{4.3}$$

где $Q^h_{\theta_{qh}}$ и $Q^l_{\theta_{ql}}$ — два критика вознаграждений верхнего и низкого уровня соответственно, аппроксимируемые нейронными сетями и оценивающие дисконтированную внешнюю и внутреннюю награды соответственно.

HRAC позволяет решать задачи с большим горизонтом, однако не может быть напрямую применён в постановке марковского процесса принятия решений с ограничениями. Далее показывается, как обеспечить безопасность как при генерации подцелей, так и при исполнении низкоуровневой стратегии.

4.1.1 Безопасность на верхнем уровне: генерация безопасных подцелей

Схема обновления верхнеуровневой стратегии приведена на рис. 4.2. Обновление выполняется на основе переходов $\langle s, s_g, R^h \rangle$ и таких модулей, как модель штрафов C_M и критика вознаграждений $Q^h_{\theta_{qh}}$, которые оценивают безопасность и полезность сгенерированной подцели.

Модель штрафов. Задача модели штрафов C_M состоит в предсказании вероятности того, что произвольная подцель s_g является безопасной, с использованием локальной информации о состоянии s:

$$safety^h(s_g, s) = C_M(s_g, s) \in [0,1]. \tag{4.4}$$

Поскольку в экспериментах функция штрафов c зависит только от состояния, $c : \mathcal{S} \to [0,1]$, модель штрафов может использоваться для предсказания

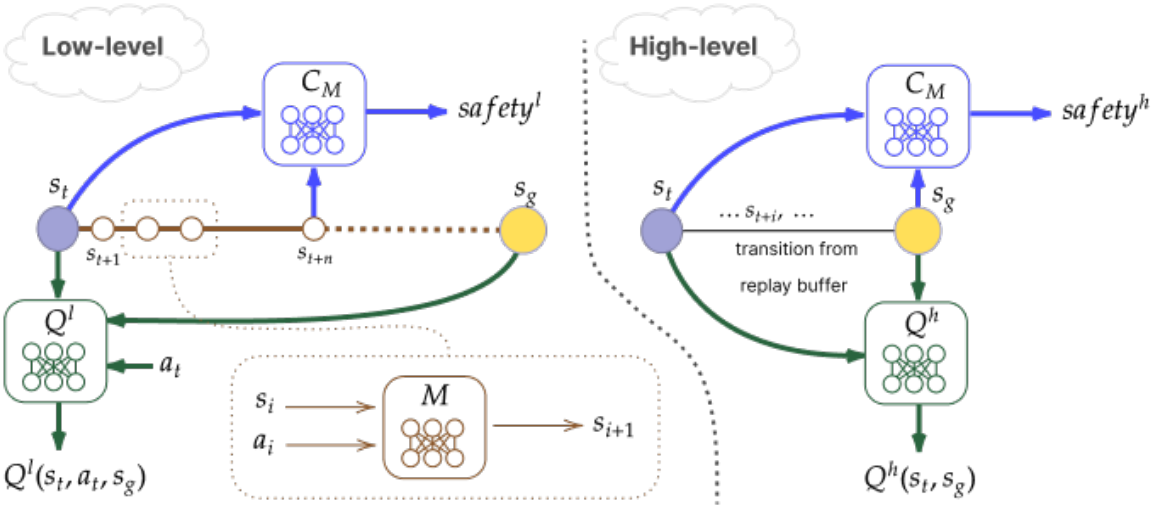


Рисунок 4.2 — Схема обучения низкоуровневой и верхнеуровневой стратегий. **Слева**: модель штрафов C_M и модель мира M отвечают за обеспечение безопасности при обновлении низкоуровневой стратегии, тогда как функция $Q^l_{\theta_{ql}}$ используется для оптимизации награды. **Справа**: модель штрафов C_M используется для учёта безопасности при обновлении верхнеуровневой стратегии, а функция $Q^h_{\theta_{qh}}$ используется для оптимизации награды.

значения штрафов состояний. Однако в данной работе предлагается рассматривать безопасность подцелей как вероятность их безопасности. Оптимизация такой величины способствует генерации подцелей, находящихся дальше от границы между безопасными и небезопасными состояниями. Для реализации модели штрафов используется нейронная сеть, а именно многослойный перцептрон, параметризованный θ_c. В качестве функции потерь для обучения используется бинарная кросс-энтропия. Модель обучается в процессе взаимодействия со средой с использованием того же буфера опыта, который используется для модели мира M.

Модель штрафов использует только локальные наблюдения о препятствиях, однако остаётся достаточно точной для предсказания безопасности ближайших подцелей, поскольку HRAC генерирует подцели на коротком горизонте s_g в пределах наблюдаемой области.

Целевая функция верхнеуровневой стратегии. Чтобы верхнеуровневая стратегия генерировала безопасные подцели, в функцию потерь HRAC (формула 4.2) был добавлен член $L_{safety^h}(s, s_g) = -safety^h(s_g, s)$ с коэффициентом β^h_{safe}, отвечающим за вклад безопасности:

$$L_{safety^h}(s,s_g) = -safety^h(s_g,s). \tag{4.5}$$

Итоговая функция потерь высокоуровневой стратегии записывается как:

$$L^h = -Q^h_{\theta_{qh}}(s,s_g,g) + \beta^h_{adj} L_{adj}(s,s_g) + \beta^h_{safe} L_{safety^h}(s,s_g), \tag{4.6}$$

где β^h_{safe} задаёт вес компоненты безопасности.

Эксперименты показали, что использования только модели штрафов C_M для генерации безопасных подцелей недостаточно. В этом случае верхнеуровневая стратегия может научиться предсказывать подцели, находящиеся в безопасных областях, но недостижимые для низкоуровневой стратегии. Например, подцель может быть расположена за препятствием, что вынуждает низкоуровневую стратегию решать задачу обхода препятствий с большим горизонтом. Для решения этой проблемы используется верхнеуровневый критик штрафов $Q^h_c(s, s_g, g)$, который оценивает ожидаемую дисконтированные штрафы до конца эпизода. Он добавляется в целевую функцию верхнеуровневой стратегии, а множитель Лагранжа λ обучается адаптивно для выполнения ограничения безопасности $Q^h_c(s, s_g, g) \leqslant d$. Итоговая целевая функция верхнеуровневой стратегии имеет вид:

$$L^h = -Q^h_{\theta_{qh}}(s,s_g,g) + \beta^h_{adj} L_{adj}(s,s_g) + \beta^h_{safe} L_{safety^h}(s,s_g) + \lambda Q^h_c(s,s_g,g). \tag{4.7}$$

Множитель Лагранжа λ обновляется с помощью градиентного спуска и проецируется на область $\lambda \geqslant 0$:

$$\lambda \leftarrow \left[\lambda + \left(Q^h_c(s,s_g,g) - d\right)\right]_+. \tag{4.8}$$

Верхнеуровневый критик штрафов $Q^h_c(s, s_g, g)$ обучается стандартной беллмановской регрессией на верхнеуровневых переходах, аналогично критику награды, с использованием накопленных штрафов, собранной за соответствующий k-шаговый интервал достижения подцели.

4.1.2 Безопасность на нижнем уровне: безопасное достижение подцелей

Модель штрафов используется для оценки подцелей, сгенерированных верхнеуровневой стратегией, и для их оптимизации в сторону безопасных подцелей. Однако даже если выбранная подцель является безопасной, агент может

нарушить ограничения безопасности в процессе её достижения. Например, мобильный робот может чрезмерно ускориться при движении к подцели. Для решения этой проблемы используется комбинация модели штрафов и модели мира, что соответствует левой части схемы на рис. 4.2.

Пусть для агента задана текущая подцель s_g. Для проверки безопасности в воображении последовательно генерируются действия с помощью низкоуровневой стратегии $a \sim \pi^l_{\theta_l}(a|s, s_g)$, после чего модель мира используется для получения следующего состояния $s' = M_{\theta_m}(s, a)$. Эта процедура повторяется n раз. Здесь n — число шагов воображения, выбираемое из дискретного равномерного распределения $n \sim U(\{1, \ldots, k-1\})$; соответствующая схема показана в левой части рис. 4.2. Итоговая безопасность для низкоуровневой стратегии вычисляется с использованием модели штрафов и модели мира следующим образом:

$$safety^l(s, s_g) = C_M(\varphi(s_n), s) \in [0, 1]. \tag{4.9}$$

Хотя безопасность оценивается только в одном случайно выбранном воображаемом состоянии, равномерный выбор n делает такую оценку несмещённой оценкой средней безопасности воображаемой траектории. Поэтому оптимизация этой величины улучшает безопасность всей траектории в среднем. Использование накопленных штрафов в воображении вместо случайного выбора n показало меньшую устойчивость обучения и худшие показатели безопасности. Это связано с двумя факторами. Во-первых, вычисление значений штрафов через модель штрафов для всех воображаемых состояний может приводить к взрыву градиентов, особенно при больших горизонтах воображения в 10–20 шагов. Во-вторых, для моделей мира характерно накопление ошибки предсказания при увеличении горизонта воображения. Использование случайного состояния для оценки безопасности вместо полного воображаемого развёртывания позволяет избежать длинных вычислительных траекторий и одновременно уменьшить влияние накопленной ошибки модели мира. Кроме того, такой подход снижает время обучения.

Полученное значение $safety^l(s, s_g)$ используется в итоговой функции потерь актора:

$$\begin{aligned} L^l &= -Q^l_{\theta_{ql}}(s, a, s_g) + \beta^l_{safe} L_{safety^l}(s, s_g), \\ L_{safety^l}(s, s_g) &= -safety^l(s, s_g). \end{aligned} \tag{4.10}$$

Здесь β^l_{safe} — гиперпараметр, аналогичный β^h_{safe} из формулы 4.6. Воображаемая безопасность может быть добавлена как дополнительный член функции

потерь верхнеуровневой стратегии, а не низкоуровневой. Однако генерация подцелей является более сложной задачей, и в экспериментах низкоуровневая стратегия обучалась достижению подцелей быстрее, чем верхнеуровневая стратегия обучалась их предсказывать. Поэтому воображаемая безопасность добавляется именно в функцию потерь низкоуровневой стратегии. Для обучения модели штрафов и модели мира используется начальный сбор данных: выполняется $30\,000$ случайных шагов в среде, после чего обе модели предварительно обучаются в течение 100 эпох.

4.1.3 Практическая реализация

Подход ITES представлен в алгоритме 2, где приведён цикл обучения верхнеуровневой и низкоуровневой стратегий. В методе используются две вспомогательные компоненты: модель штрафов $C_{M_{\theta_c}}$ и модель мира M.

Для обучения модели штрафов поддерживается буфер опыта со сбалансированным распределением безопасных и небезопасных состояний. Это позволяет уменьшить дисбаланс классов и снизить риск переобучения, что является типичной проблемой в задачах безопасного обучения с подкреплением.

В качестве модели мира используется лёгкая модель из работы [95], а не более сложные архитектуры, такие как рекуррентная модель в пространстве состояний (Recurrent State-Space Model, RSSM), применяемая в Dreamer [53] и требующая более длительного обучения. Поскольку метод ITES работает с подцелями на коротком горизонте, достаточно использовать модель мира для краткосрочного предсказания. Это снижает накопление ошибки предсказания и позволяет эффективно выполнять планирование внутри горизонта каждой подцели.

Функция переходов $p(s'|s,a)$ моделируется с помощью ансамбля из n нейронных сетей, обозначаемого как M_{θ_m}. Каждая модель M_i предсказывает следующее состояние $s' = M_i(s,a)$, а итоговое предсказание получается усреднением по ансамблю:

$$M_{\theta_m}(s,a) = \frac{1}{n}\sum_{i=1}^{n} M_i(s,a). \tag{4.11}$$

Алгоритм 2 ITES

Вход: среда env, верхнеуровневая стратегия π^h, низкоуровневая стратегия π^l, модель мира M, модель штрафов C_M, сеть смежности ψ, частота выбора верхнеуровневого действия k, число обучающих эпизодов N, частота обучения сети смежности L.
Предварительно обучить M_{θ_m} и C_M на случайном опыте.
for $n = 1$ **до** N **do**
    Сбросить среду и получить начальное состояние s_0
    $t \leftarrow 0$
    repeat
        if $t \equiv 0 \pmod{k}$ **then**
            Выбрать подцель $s_g \sim \pi^h_{\theta_h}(s_g|s_t, g)$
        end if
        Выбрать низкоуровневое действие $a_t \sim \pi^l_{\theta_l}(a_t|s_t,s_g)$
        Выполнить шаг в среде: $s_{t+1}, r_t, c_t, done \leftarrow env(s_t, a_t)$
        Вычислить внутреннюю награду $r_{in} \leftarrow r_{in}(s_{t+1},s_g)$
        $t \leftarrow t + 1$
    until $done$ равно $true$
    Обучить C_M с использованием сбалансированного по классам буфера воспроизведения опыта
    Обучить модель мира M_{θ_m}
    Обучить верхнеуровневую стратегию π^h с использованием формулы (4.7)
    Обучить низкоуровневую стратегию π^l с использованием формулы (4.10)
    if $n \equiv 0 \pmod{L}$ **then**
        Дообучить ψ с использованием формулы (4.1)
    end if
end for

Использование ансамбля позволяет снизить влияние эпистемической и алеаторической неопределённости при предсказании переходов среды.

Таблица 11 — **Итоговые результаты на SafeAntMaze и SafePusher.** SAM-C — SafeAntMaze C-shape, SAM-W — SafeAntMaze W-shape, SR — доля успешных эпизодов. Методы, удовлетворяющие условию безопасности (Final Cost $\leqslant d$), выделены **зелёным**, а методы, нарушающие ограничение, выделены **красным**. Результаты усреднены по 5 случайным запускам.

Env	Method	Final SR↑	Final Cost↓
SAM C	ITES	**0.88** $\pm$ 0.01	15.2 $\pm$ 17.3
	SafeDreamer	0	13 $\pm$ 18.11
	CUP	0	**6.8** $\pm$ 22.4
	FOCOPS	0	19.4 $\pm$ 50.9
	TD3L/R	0.38 $\pm$ 0.04	83.6 $\pm$ 37.2
	PPOLAG	0.2 $\pm$ 0.2	41.2 $\pm$ 1.1
	TD3LAG	0.13 $\pm$ 0.33	133.45 $\pm$ 184.4
SAM W	ITES	**0.35** $\pm$ 0.05	183 $\pm$ 16.5
	TD3L/R	0.05 $\pm$ 0.02	154 $\pm$ 13.5
	CUP	0	**103.5** $\pm$ 21.5
	FOCOPS	0	141.0 $\pm$ 26.0
	TD3LAG	0	128.68 $\pm$ 210
	PPOLAG	0	105 $\pm$ 20.1
	SafeDreamer	0	216.3 $\pm$ 199
Pusher	ITES	**0.42** $\pm$ 0.02	**12.8** $\pm$ 0.87
	SafeDreamer	0	6.7 $\pm$ 2.7
	TD3LAG	0.05 $\pm$ 0.03	54.72 $\pm$ 3.16
	CUP	0.01	46.14 $\pm$ 0.42
	FOCOPS	0	55.83 $\pm$ 1.67
	PPOLAG	0	51.25 $\pm$ 1.25

4.2 Экспериментальная проверка метода ITES

В данном разделе рассматриваются три исследовательских вопроса. **RQ1**: способен ли метод ITES решать задачи с большим горизонтом при заданном ограничении на штраф? **RQ2**: как ITES работает на задачах Safety Gym с коротким горизонтом, где достаточно одноуровневой стратегии? **RQ3**: какой вклад в ито-

говую безопасность и эффективность вносят предложенные компоненты метода: безопасная генерация подцелей на верхнем уровне и воображаемая безопасность на нижнем уровне?

Для ответа на эти вопросы используются среды SafeAntMaze, SafePusher и Safety Gym, описание которых приведено в разделе 1.8. SafeAntMaze и SafePusher используются как задачи с большим горизонтом, в которых агент должен достигать цели при наличии ограничений безопасности и сложной динамики. Дополнительно метод оценивается на задачах Safety Gym с коротким горизонтом, где проверяется, не ухудшает ли иерархическая структура качество решения более простых навигационных задач. Отдельно рассматривается вариант PointGoal sparse с разреженным вознаграждением, усложняющий исследование среды. Из-за отсутствия в литературе полностью обучаемых методов, одновременно относящихся к безопасному и иерархическому обучению с подкреплением, для проверки RQ1 был дополнительно разработан иерархический базовый метод HRAC-LAG. Кроме того, предложенный подход оценивался на бенчмарке Safety Gym с коротким горизонтом в сравнении с дополнительными одноуровневым методами PPOLAG и методом обучения с подкреплением на основе модели мира MBPPOL. Описание экспериментальных сред и метрик оценки приведено в разделах 1.8 и 1.9. Все эксперименты запускались на NVIDIA GeForce RTX 3060 с 8 ГБ памяти. При одинаковом числе взаимодействий со средой ITES требовал 24 часа обучения на AntMaze и 12 часов на Safety Gym, тогда как SafeDreamer требовал 72 и 34 часа соответственно из-за более тяжёлой модели мира.

Рассматриваются два типа базовых методов: иерархические методы HRAC и HRAC-LAG, а также одноуровневые методы CUP [43], FOCOPS [44], MBPPOL [15], TD3LAG [7]. Для корректного сравнения предложенной компоненты безопасности с подходом на основе функции лагранжиана к алгоритму HRAC был добавлен множитель Лагранжа в верхнеуровневую стратегию. Полученный метод обозначается как **HRAC-LAG** и используется как базовый метод, объединяющий безопасное и иерархическое обучение с подкреплением.

Для сравнения с подходами обучения с подкреплением на основе модели мира был предложен алгоритм **MBPPOL**: одноуровневый метод, использующий модель мира для обучения Lagrangian PPO в симулированной среде. Также рассматривается современный метод безопасного обучения с подкреплением **SafeDreamer** [18], использующий модель мира на основе RSSM, множитель Лагранжа для учёта ограничений и планирование в латентном пространстве. Для

сравнения с внеполитическими подходами был предложен алгоритм **TD3LAG**, состоящий из стратегии TD3 и множителя Лагранжа. Метод **TD3L/R** расширяет TD3LAG с помощью обучения с расписанием (curriculum learning): при неудаче он генерирует промежуточные подцели, чтобы усилить исследование через постепенное достижение целей.

Методы LyapunovRRT, IAHRL и Safe HIRO не использовались как основные базовые методы, поскольку они несовместимы с предложенными средами из-за своих ограничений. В частности, LyapunovRRT требует точных положений препятствий, тогда как все рассматриваемые среды работают в условиях частичной наблюдаемости. IAHRL использует опции, которые трудно реализовать в данных средах. Safe HIRO требует априорного знания функции штрафов и её дифференцируемости, тогда как агенты в рассматриваемых задачах не имеют доступа к такой информации, а используемые функции штрафов являются недифференцируемыми.

4.2.1 Сравнение ITES с базовыми методами на задачах с большим горизонтом

Рис. 4.3 показывает преимущество ITES по сравнению с HRAC-LAG и HRAC на бенчмарках SafeAntMaze и SafePusher. В среде SafeAntMazeCshape все методы достигают сопоставимой доли успешных эпизодов, равной 0.89–0.93, однако ITES снижает нарушения штрафов на 42% за счёт использования модели мира и модели штрафов. Это отличается от HRAC-LAG, где оценки Q_c^l являются более шумными. В SafePusher метод ITES повышает долю успешных эпизодов на 18% по сравнению с HRAC, поскольку минимизация штрафов способствует более быстрому обучению и улучшению финальной доли успешных эпизодов.

По всем трём средам с большим горизонтом, приведённым в табл. 11, ITES существенно превосходит остальные базовые методы по доле успешных эпизодов при соблюдении ограничений безопасности. По сравнению с SafeDreamer метод ITES повышает долю успешных эпизодов на 88% в SAM-C, на 35% в SAM-W и на 42% в SafePusher, что даёт среднее улучшение около 55% по трём средам. При этом ITES удовлетворяет ограничениям безопасности во всех рассмотренных постановках.

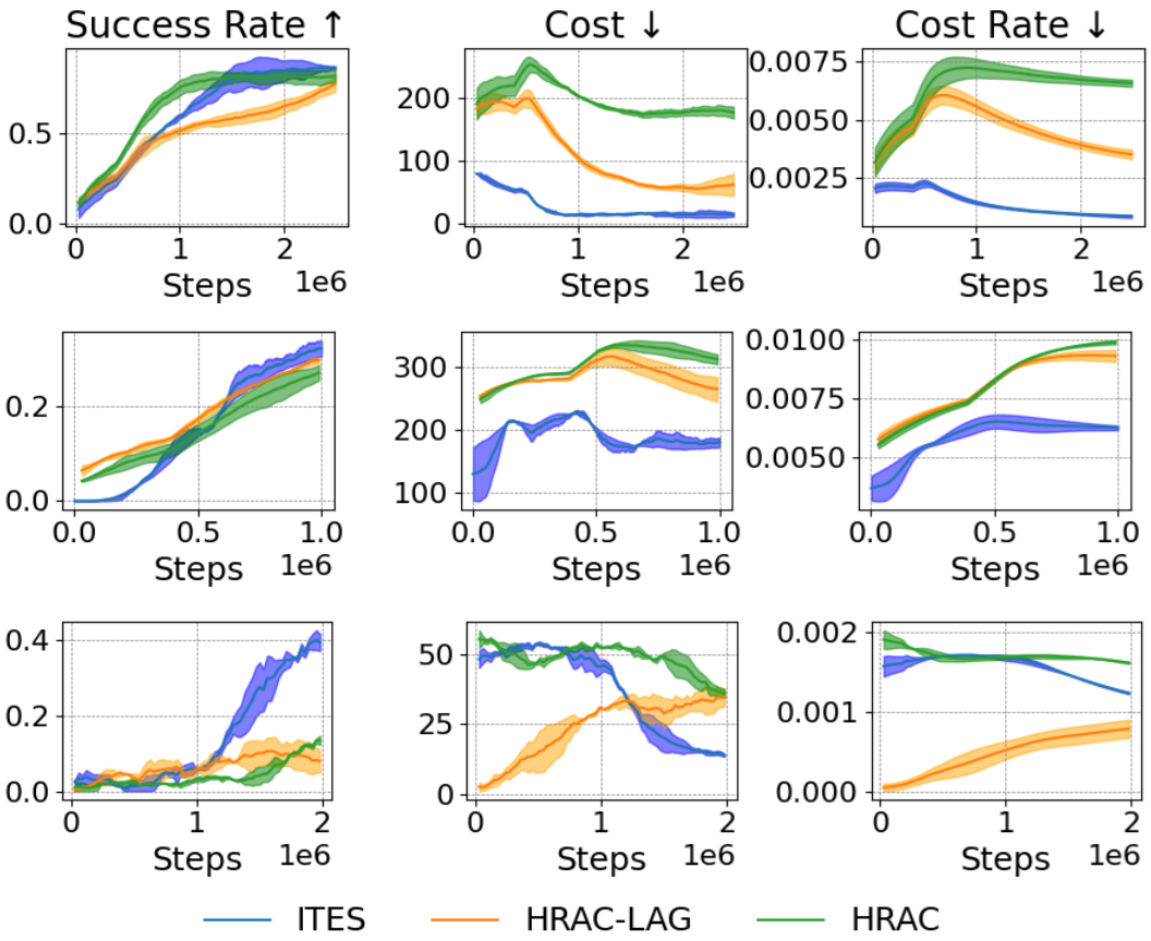


Рисунок 4.3 — **Сравнение с базовыми методами на бенчмарках SafeAntMaze и SafePusher**. Сравнение предложенного метода ITES с безопасным иерархическим методом HRAC-LAG и небезопасным методом HRAC. **Первая строка**: среда SafeAntMazeCshape. **Вторая строка**: среда SafeAntMazeWshape. **Третья строка**: среда SafePusher. Каждый запуск проводился по 5 случайным инициализациям. Заштрихованная область соответствует стандартному отклонению.

4.2.2 Сравнение ITES с базовыми методами на задачах с коротким горизонтом

На рис. 4.4 показано сравнение с иерархическими стратегиями на бенчмарке Safety Gym. В средах PointGoal1 и CarGoal1 предложенный метод превосходит HRAC-LAG по безопасности при сопоставимой доле успешных эпизодов.

Табл. 12 содержит сравнение итоговых значений одноуровневых методов CUP и FOCOPS с предложенным методом ITES на Safety Gym. В среде CarGoal1, где динамика агента сложнее, а размерность пространства состояний больше, чем в PointGoal1, одноуровневые методы хуже сохраняют высокую эффективность:

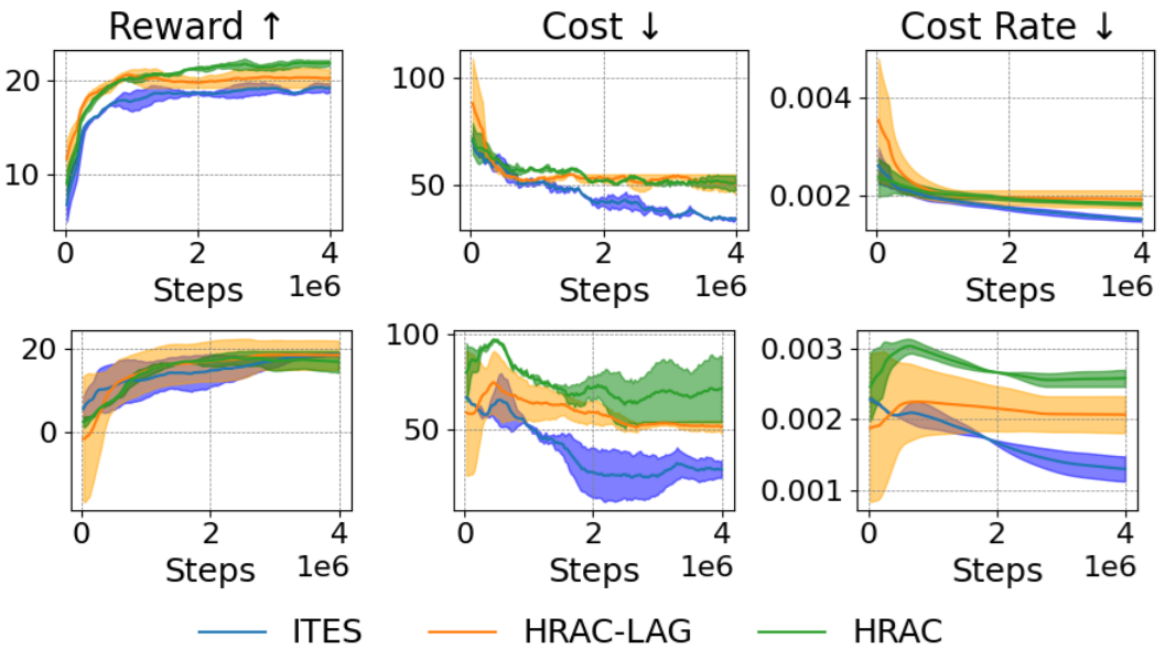


Рисунок 4.4 — **Сравнение с базовыми методами на Safety Gym**. **Первая строка**: PointGoal1. **Вторая строка**: CarGoal1. Результаты усреднены по 5 случайным запускам.

TD3-Lagrangian достигает только 8.21, а SafeDreamer — 6.6. Эти методы переходят к консервативному поведению и решают меньше задач. Из-за этого они могут выглядеть более безопасными, например SafeDreamer имеет нулевой штраф, однако такое поведение является неоптимальным в рамках заданной спецификации безопасности, где стратегия считается безопасной, если её штрафы не превышают 40. В отличие от них, ITES успешно балансирует эффективность и безопасность, достигая более высокой награды: PointGoal1 — 19.6, CarGoal1 — 18.3, при сохранении штрафов ниже допустимого порога.

Результаты на среде PointGoal sparse, приведённые в табл. 12, показывают, что простые одноуровневые алгоритмы без модели мира не способны научиться решать задачу: CUP достигает значения 1.755, а TD3LAG — 0.07. Такие низкие значения показывают, что оба подхода не решают задачу эффективно. В случае CUP агент остаётся неподвижным, что приводит к минимальным штрафам, тогда как TD3LAG выполняет жадные действия, но не может научиться решать задачу в условиях разреженного вознаграждения.

В исходной реализации MBPPOL использует истинную информацию о препятствиях вместо данных лидара во время обучения в средах PointGoal1, PointCar1 и PointGoal sparse. Это приводит к некорректному сравнению, поэтому его значения отмечены знаком “—”. Тем не менее даже в такой постановке данный

Таблица 12 — **Итоговые результаты на бенчмарке Safety Gym.** PG1 — PointGoal1, CG1 — CarGoal1, PGs — PointGoal1 sparse. Для каждой среды используется ограничение штрафов $d = 40$. Результаты усреднены по 5 случайным запускам.

Env	Method	Final Reward↑	Final Cost↓
PG1	ITES	**19.6** $\pm$ 0.46	32.83 ± 1.97
	TD3LAG	15.75 ± 0.39	56.22 ± 0.85
	FOCOPS	14.97 ± 9.01	33.72 ± 42.24
	CUP	14.42 ± 6.74	19.02 ± 20.08
	PPOLAG	12.96 ± 6.95	25.80 ± 34.99
	SafeDreamer	12 ± 4	10.3 ± 9.5
	MBPPOL	—	—
CG1	ITES	**18.3** $\pm$ 0.03	21.72 ± 0.59
	FOCOPS	15.23 ± 10.76	31.66 ± 93.51
	PPOLAG	13.27 ± 9.26	21.72 ± 32.06
	TD3LAG	8.21 ± 6.88	53.7 ± 9.45
	SafeDreamer	6.6 ± 1.2	0
	CUP	6.14 ± 6.97	36.12 ± 89.56
	MBPPOL	—	—
PGs	ITES	**8.64** $\pm$ 0.38	33.46 ± 1.47
	FOCOPS	7.635 ± 0.2	22.9 ± 1.5
	PPOLAG	6.85 ± 0.76	32.645 ± 5.9
	MBPPOL	6.15 ± 0.15	34.1 ± 3.6
	CUP	1.755 ± 0.95	12.925 ± 5.3
	SafeDreamer	0.5 ± 0.5	3.22 ± 2.34
	TD3LAG	0.07 ± 0.01	64.7 ± 1.91

подход уступает ITES на задачах PointGoal sparse, поскольку испытывает трудности при обучении в условиях разреженного вознаграждения. SafeDreamer в разреженной постановке достигает итоговой награды только 0.5, так как использует модель награды, обученную на несбалансированном наборе данных из-за разреженности вознаграждения. Это приводит к чрезмерно консервативному поведению, поскольку метод не может научиться решать задачи, требующие большего горизонта, чем исходная PointGoal1. Эти результаты показывают, что при сопоставимых условиях безопасности ITES демонстрирует более высокую

эффективность по сравнению с базовыми методами, достигая значения 8.64 и сохраняя ограничения безопасности.

4.2.3 Абляционное исследование: влияние компонент ITES на безопасность

Сравнение ITES w/o HLS и ITES w/o LLS. Чтобы проверить, можно ли обеспечить безопасность только на одном уровне иерархии, ITES сравнивался с двумя вариантами: (i) **ITES w/o LLS**, где отсутствует безопасность на нижнем уровне, а безопасность обеспечивается только на верхнем уровне; (ii) **ITES w/o HLS**, где отсутствует безопасность на верхнем уровне, а безопасность обеспечивается только на нижнем уровне. Сравнение проводилось на **SafeAntMazeCshape**. Как показано на рис. 4.5 в первой строке, безопасность на верхнем уровне существенно снижает накопленные штрафы и средний штраф за все время обучения, а добавление безопасности на нижнем уровне дополнительно повышает безопасность и снижает разброс. В частности, ITES w/o LLS показывает более высокую дисперсию штрафов, поскольку агент может нарушать ограничения во время движения к безопасной подцели.

Сравнение одноуровневого ITES без верхнего уровня и полного ITES. Результаты обучения ITES и TD3 с воображаемой безопасностью, вычисляемой с помощью модели мира, обозначенного как TD3IMG, представлены на рис. 4.5 во второй строке. Хотя метрика штрафов показывает, что ITES значительно безопаснее TD3IMG, это различие возникает из-за того, что TD3IMG может минимизировать безопасность в воображении только на горизонте 10 шагов, а не до конца эпизода. Увеличить этот горизонт невозможно, поскольку при этом модель мира начинает расходиться. В отличие от TD3IMG, ITES генерирует подцели на 10 шагов вперёд, что позволяет стратегии TD3 безопасно достигать этих целей.

Влияние верхнеуровневого критика штрафов Q_c^h на безопасность. Дополнительно исследовалось, как включение верхнеуровневого критика штрафов Q_c^h в целевую функцию верхнеуровневой стратегии влияет на результат. Соответствующее сравнение приведено на рис. 4.5 в третьей строке.



Рисунок 4.5 — **Первая строка**: анализ безопасности на нижнем и верхнем уровнях. На рисунке показаны разные варианты ITES: ITES w/o LLS — ITES без безопасности на нижнем уровне, где безопасность реализуется только на верхнем уровне; ITES w/o HLS — ITES без безопасности на верхнем уровне, где безопасность реализуется только на нижнем уровне, на SafeAntMazeCshape. **Вторая строка**: сравнение ITES без верхнеуровневой стратегии и полного ITES на PointGoal1. **Третья строка**: сравнение ITES и ITES без верхнеуровневого критика штрафов Q_c^h на PointGoal1. Графики получены по 5 случайным запускам.

4.3 Выводы по главе

В данной главе рассмотрен метод ITES, предназначенный для безопасного обучения в задачах с большим горизонтом. В отличие от одноуровневых методов, ITES использует иерархическую структуру: верхний уровень выбирает

промежуточные подцели, а нижний уровень отвечает за их достижение. При этом безопасность учитывается на обоих уровнях. Для выбора подцелей используются модель штрафов и верхнеуровневый критик штрафов, а для низкоуровневой стратегии применяется модель мира, позволяющая проверять воображаемые переходы при движении к подцели.

Эксперименты на SafeAntMaze и SafePusher показывают, что одноуровневые безопасные методы испытывают трудности в задачах большого горизонта. В одних случаях они нарушают ограничение на штраф, в других — почти не продвигаются к цели и получают низкие штрафы за счёт фактической стагнации. ITES в этих условиях достигает ненулевой доли успешных эпизодов и при этом удерживает штрафы в пределах заданного ограничения в тех постановках, где это требуется спецификацией эксперимента.

На задачах Safety Gym с более коротким горизонтом метод также остаётся конкурентоспособным. В PointGoal1, CarGoal1 и PointGoal sparse ITES сохраняет штрафы ниже допустимого порога и при этом получает более высокое итоговое вознаграждение по сравнению с большинством базовых методов. Это показывает, что иерархическая структура не приводит к ухудшению качества в более простых задачах, где одноуровневая стратегия уже может быть достаточной.

Глава 5. Переход к мультимодальной безопасности в задачах с естественно-языковыми целями и ограничениями

В предыдущих главах рассматривались постановки, где цель и ограничение безопасности уже заданы в формальном виде: цель при помощи координат, а ограничение при помощи явной математической функции или логического условия. Тем не менее если рассматривать задачи робототехники в реальном мире, то роботу необходимо взаимодействовать с человеком, что требует от робота понимания задачи и ограничений, заданных естественным языком.

Поэтому развитие безопасного обучения с подкреплением требует перехода к мультимодальной постановке, где агент должен одновременно понимать текст, сопоставлять его с наблюдениями среды и принимать безопасные решения.

Существующие бенчмарки для безопасного обучения с подкреплением с естественно-языковыми ограничениями имеют существенные ограничения: в них цель часто остаётся заданной в структурированном виде, задачи сводятся к простой навигации, а среда является статической или недостаточно сложной. В данной главе рассматривается бенчмарк Caged CrafText [39] (рис. 5.1), расширяющий CrafText [96] до постановки, в которой и целевая инструкция, и ограничение безопасности задаются естественным языком.

Caged CrafText предназначен для оценки агентов в сложных задачах с большим горизонтом, где требуется не только следование инструкции, но и безопасное исследование, память, рассуждение, долгосрочное планирование и связывание текста с объектами и состояниями среды. В разд. 5.1 описываются постановка бенчмарка, типы ограничений и уровни датасета. В разд. 5.2 приводится экспериментальное сравнение базовых методов безопасного обучения с подкреплением и агентов на основе больших языковых моделей.

5.1 Бенчмарк Caged CrafText

Бенчмарк Caged CrafText предназначен для систематической оценки способностей агента в задачах с различными типами текстовых ограничений. В табл. 13 приведена таксономия четырёх сценариев ограничений, соответствую-

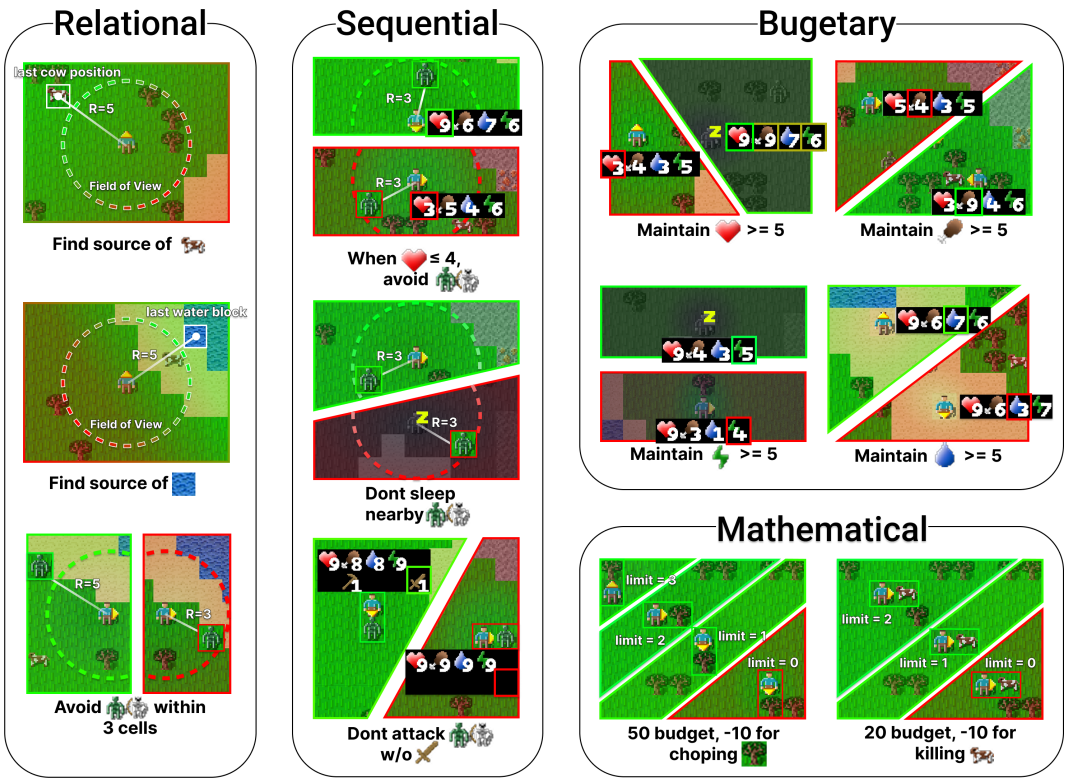


Рисунок 5.1 — **Caged CrafText benchmark.**

щие инструкции задач и основные способности агента, проверяемые в каждом типе задач.

5.1.1 Сценарии

Caged CrafText основан на таксономии задач на естественном языке, предложенной в [96]. В бенчмарке реализованы четыре типа ограничений, каждый из которых направлен на проверку различных способностей агента в задачах с большим горизонтом, таких как сбор ресурсов и создание предметов. Каждая задача в бенчмарке состоит из ⟨целевой инструкции⟩ и ⟨текстового ограничения⟩. Целевая инструкция выбирается из 17 простых целей достижения, как в [96]. К таким целям относятся, например, «Craft Wooden Pickaxe», «Defeat Skeleton», «Eat Cow» и «Wake Up». Текстовое ограничение берётся из одного из наборов, приведённых в табл. 13. Такая комбинация даёт четыре группы задач: Budgetary содержит $17 \times 4 = 68$ задач, Sequential — $17 \times 3 = 51$, Mathematical — $17 \times 2 = 34$, Relational — $17 \times 3 = 51$.

Таблица 13 — Таксономия задач Caged CrafText и способностей агента, которые они проверяют. Иконки обозначают объекты и ресурсы, связанные с ограничениями: еду, воду, энергию, здоровье, деревянный меч, дерево, корову, зомби и скелета. Обозначения способностей: M — память, DE — глубокое исследование среды, SE — безопасное исследование, R — рассуждение, LU — понимание языка.

Сценарий	**Ограничение**	**M**	**DE**	**SE**	**R**	**LU**
Budgetary	Maintain $\geqslant 5$	✓	✓	✓		
	Maintain $\geqslant 5$	✓	✓	✓		
	Maintain $\geqslant 5$			✓		
	Maintain $\geqslant 5$	✓	✓	✓	✓	
Sequential	Don't attack w/o		✓	✓	✓	
	Don't sleep nearby			✓	✓	
	When $\leqslant 4$, avoid			✓	✓	
Mathematical	20 budget, -10 for killing	✓		✓	✓	
	50 budget, -10 for chopping	✓		✓	✓	
Relational	Avoid within 3 cells	✓		✓	✓	
	Find source of	✓	✓	✓		
	Find source of	✓	✓	✓		
Budgetary All		✓	✓	✓	✓	
Sequential All			✓	✓	✓	
Mathematical All		✓		✓	✓	
Relational All		✓	✓	✓	✓	
Caged		✓	✓	✓	✓	✓

Бюджетные ограничения (Budgetary). В этих задачах агент должен поддерживать заданный показатель (уровень еды, воды, энергии или здоровья) выше определённого порога. Для этого агенту необходимо запоминать, где находятся требуемые ресурсы, и возвращаться к ним при необходимости, при этом продолжать решать исходную задачу. В этих задачах проверяются способности: память, а также глубокое исследование среды, поскольку в случае ограничения на здоровье дополнительно требуется избегать монстров и одновременно следить за остальными показателями.

Последовательные ограничения (Sequential). В этой группе безопасность зависит от последовательности двух или более состояний. Каждое из состояний может быть безопасно само по себе, но в последовательности они приводят к на-

рушениям ограничений по безопасности. Например, сон рядом с монстром или атака без меча. Поэтому такие задачи проверяют способность к рассуждению, не будет ли следующее состояние нарушать ограничения, учитывая предыдущие, а также проверяется умение глубокого исследования, поскольку, например, для создания меча необходимо собрать дополнительные ресурсы.

Математические ограничения (Mathematical). Здесь агент получает абстрактный бюджет и если он израсходовал этот бюджет, то получает штраф. Например, ограничение может задавать допустимое число деревьев, которое можно срубить. Такое ограничение мотивировано тем, чтобы агент не срубал все деревья, а держал их в области видимости, и рубил только если ему необходим ресурс. В отличие от бюджетных ограничений, где агент видит значение показателей, здесь речь идёт об абстрактных показателях.

Отношенческие ограничения (Relational). В этой группе ограничения задаются по дистанции между агентом и объектами среды. Например, агенту необходимо держаться на безопасном расстоянии от врагов, или наоборот держать источник воды в радиусе видимости. Поэтому важно не только понять текст, но и связать его с расположением объектов в окружении. Такие задачи проверяют пространственное рассуждение, память о найденных объектах и способность исследовать среду без нарушения заданного правила.

5.1.2 Настройка среды

Caged CrafText сохраняет основную реализацию CrafText на JAX, но изменяет постановку задачи так, чтобы текстовое ограничение участвовало в обучении и оценке агента. Для этого расширяются наблюдения, функция вознаграждения, функция штрафов и условия завершения эпизода. В частности, агент получает не только целевую инструкцию, но и отдельное текстовое правило безопасности.

Наблюдение. Агент получает пиксельное наблюдение среды в виде изображения размером $63 \times 63 \times 3$, а также строку на естественном языке, задающую целевую инструкцию, например «Craft a wooden pickaxe», и текстовое ограничение, например «Maintain health above 5». Агент должен научиться считывать состояние своего инвентаря из пиксельного наблюдения.

Действия. Пространство действий состоит из 17 дискретных действий, включая движение в четырёх направлениях, взаимодействие с объектами, сон, размещение объектов и создание инструментов. Для каждого инструмента и объекта предусмотрено отдельное действие. Инструменты хранятся в инвентаре, а объекты размещаются перед игроком. Действия, для которых отсутствуют необходимые материалы, не оказывают эффекта.

Вознаграждение. Агент получает разреженное вознаграждение $+1$ за выполнение основной задачи. Дополнительно, как в CrafText, могут использоваться малые масштабированные награды за достижения с коэффициентом $1/50$, чтобы упростить исследование среды.

Штраф. Штраф $+1$ начисляется сразу при нарушении ограничения безопасности. После нарушения эпизод продолжается. Для каждого типа ограничений задан допустимый бюджет нарушений d на эпизод: для Budgetary, Sequential и Mathematical используется $d = 0.1$, для Relational — $d = 10$.

Завершение эпизода. Эпизод завершается при успешном выполнении задачи, смерти агента или достижении предельного числа шагов.

Проверяющие функции для ограничений также реализованы на JAX. Это позволяет выполнять большое число параллельных симуляций и использовать ускорение на GPU или TPU без вынесения проверки ограничений во внешний Python-код.

5.1.3 Уровни датасета

Для оценки используются два уровня задач.

Отладочный уровень содержит отдельные пары цели и ограничения из наборов Budgetary, Sequential, Relational и Mathematical. В этом режиме агент во время обучения работает с одной фиксированной формулировкой цели и одним фиксированным ограничением. Такой уровень нужен для анализа конкретных ошибок поведения: например, умеет ли агент поддерживать количество определённого ресурса, избегать опасной последовательности действий.

Основной уровень объединяет задачи одного типа в общие наборы Budgetary All, Sequential All, Mathematical All и Relational All. В каждом эпизоде агент получает одно из нескольких ограничений соответствующей категории.

Поэтому здесь проверяется уже не только обучение под одно правило, но и способность связывать разные текстовые формулировки с объектами, действиями и состояниями среды. Набор Caged дополнительно включает переформулированные ограничения, что позволяет проверить устойчивость агента к разным языковым описаниям одного и того же правила.

5.2 Сравнение методов в среде Caged CrafText

В данном разделе рассматриваются следующие исследовательские вопросы.

RQ1: Сравнение базовых методов. Как наиболее распространённые подходы, объединяющие безопасное обучение с подкреплением и обработку естественного языка, работают на предложенном бенчмарке Caged CrafText?

RQ2: Проблема безопасного исследования. Создаёт ли предложенный бенчмарк существенные трудности безопасного исследования для современных методов?

RQ3: Абляционный анализ безопасного поведения. Позволяет ли Caged CrafText дать глубокий количественный анализ безопасного поведения агентов?

RQ4: Подходы на основе больших языковых моделей. Как большие языковые модели ведут себя в среде Caged CrafText и в какой степени они способны соблюдать текстовые ограничения?

5.2.1 Базовые методы

В экспериментах рассматриваются три базовых алгоритма. Первый метод — стандартный PPO, который игнорирует сигнал штрафа и используется для оценки верхней границы эффективности жадной стратегии; для него применяются гиперпараметры по умолчанию из работы CrafText [96]. Второй метод — PPO Lagrangian (PPO LAG) [6], распространённый метод безопасного обучения с подкреплением, использующий множитель Лагранжа для баланса между вознаграждением за задачу и соблюдением ограничений; для него используется

начальное значение $\lambda_{\text{init}} = 1.0$. Третий метод — PPO COST, в котором сигнал штрафа добавляется в функцию награды с коэффициентом 0.5.

Во всех подходах целевая инструкция и текстовое ограничение кодировались с помощью BERT, после чего полученные представления объединялись и подавались на вход стратегии.

Все подходы обучались на RTX TITAN в течение 24 часов, что соответствует 500 млн шагов взаимодействия со средой. Все результаты усреднены по 5 случайным запускам. На всех графиках показано стандартное отклонение.

5.2.2 Сравнение базовых методов

Итоговые результаты приведены в табл. 14, где показаны накопленное вознаграждение и штраф для каждой задачи в отладочном и основном наборах данных. Результаты показывают, что PPO-LAG достигает высокого эпизодического вознаграждения и сохраняет безопасность только на отдельных ограничениях, например $R = 0.22$, $C = 0.10$ в задаче Maintain $\geqslant 5$ и $R = 0.11$, $C = 9.55$ в задаче Avoid within 3 cells. Однако на остальных задачах метод показывает низкую эффективность. Это связано с тем, что алгоритм предпочитает оставаться в безопасном состоянии вместо выполнения основной задачи, что указывает на недостаточную способность к безопасному исследованию.

Отдельно стоит отметить, что сама целевая часть задач не является недостижимой для PPO-подобных алгоритмов. Стандартный PPO получает высокое эпизодическое вознаграждение почти во всех задачах, но делает это без учёта штрафов. Поэтому высокое вознаграждение сопровождается частыми нарушениями ограничений: например, штраф достигает ($C = 57.94$) в одной из задач Maintain $\geqslant 5$ и ($C = 111.88$) в математическом ограничении 20 budget, -10 for killing .

PPO-Cost за счёт фиксированного штрафного коэффициента (0.5) в среднем лучше контролирует штрафы, чем PPO-LAG. Однако это не решает основную проблему. На отдельных ограничениях, например Avoid within 3 cells, метод остаётся сравнительно безопасным (($C = 7.72$)), но почти не продвигается к цели (($R = 0.04$)). Иными словами, агент находит безопасный режим поведения, но затем не возвращается к активному выполнению целевой инструкции.

Таблица 14 — Сравнение базовых алгоритмов и LLM-агента на бенчмарке Caged CrafText. Лучшие результаты в каждом столбце выделены жирным. Результаты усреднены по 5 случайным запускам.

	PPO		PPOLAG		PPOCOST		LLM	
	R↑	C↓	R↑	C↓	R↑	C↓	R↑	C↓
Budgetary ($d = 0.1$)								
Maintain $\geqslant 5$	**0.22**	17.16	0.04	0.75	0.11	0.12	0.19	28.7
Maintain $\geqslant 5$	**0.22**	57.94	0.04	1.12	0.05	0.73	0.19	31.2
Maintain $\geqslant 5$	0.20	20.57	**0.22**	0.10	0.20	**0.01**	0.19	26.4
Maintain $\geqslant 5$	**0.23**	22.12	0.02	**0.06**	0.08	1.32	0.19	29.8
Sequential ($d = 0.1$)								
Don't attack w/o	**0.23**	1.76	0.20	0.10	0.20	**0.00**	0.19	18.3
Don't sleep nearby	0.20	8.12	**0.23**	1.06	0.20	**0.00**	0.19	22.6
When $\leqslant 4$, avoid	**0.23**	9.54	0.03	1.21	0.09	0.93	0.19	24.1
Mathematical ($d = 0.1$)								
20 budget, -10 for killing	0.22	111.88	**0.24**	0.10	0.18	0.04	0.19	18.3
50 budget, -10 for chopping	0.21	114.81	0.21	0.11	0.20	0.08	0.19	8.3
Relational ($d = 10$)								
Avoid within 3 cells	**0.21**	51.96	**0.11**	9.55	0.04	7.72	0.18	47.3
Find source of	**0.21**	95.96	0.03	11.80	0.04	12.09	0.18	52.6
Find source of	**0.22**	20.67	0.03	13.40	0.04	12.24	0.19	49.8
Budgetary All ($d = 0.1$)	**0.23**	11.38	0.05	0.36	0.11	0.12	0.19	40.1
Sequential All ($d = 0.1$)	**0.24**	7.65	0.05	1.02	0.08	0.82	0.19	22.7
Mathematical All ($d = 0.1$)	**0.23**	110.42	**0.24**	**0.10**	0.18	0.05	0.19	16.9
Relational All ($d = 10$)	**0.22**	31.36	0.11	11.69	0.04	8.18	0.18	15.2
Caged ($d = 0.1$)	**0.22**	103.66	0.03	0.17	0.14	0.13	**0.20**	43.4

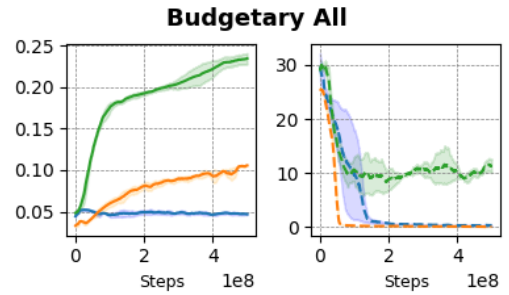
Эти результаты показывают, что для Caged CrafText недостаточно просто добавить штраф за нарушение ограничения. Агент должен уметь исследовать среду безопасно, но при этом не застревать в первом найденном безопасном поведении. После стабилизации штрафов ему всё равно нужно продолжать движение к основной цели.

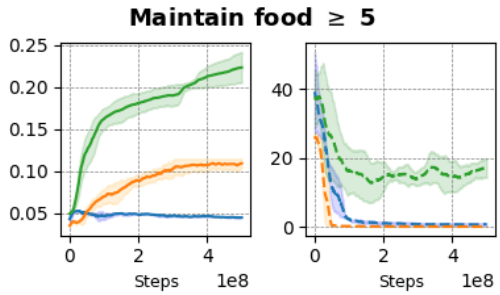
Также видно, что PPO-LAG и PPO-Cost крайне плохо работают на задачах поддержания здоровья и отношенческих задачах, требующих рассуждения и долгосрочного планирования. В задаче Maintain ❤ $\geqslant 5$ PPO-LAG достигает только $R = 0.02$, а PPO-Cost — $R = 0.08$, что существенно ниже результата PPO, равного $R = 0.23$. Аналогично, в отношенческих задачах Find source of 💧 и Find source of 🍗 оба безопасных подхода показывают минимальную награду ($R = 0.03$–0.04), сохраняя при этом высокие штрафы ($C = 11.80$–13.40). Такое низкое качество связано со сложностью одновременного управления несколькими ресурсными ограничениями, такими как вода и голод, при сохранении уровня здоровья и безопасности. Это требует более сложного рассуждения и долгосрочного планирования, которых не хватает современным методам безопасного обучения с подкреплением.

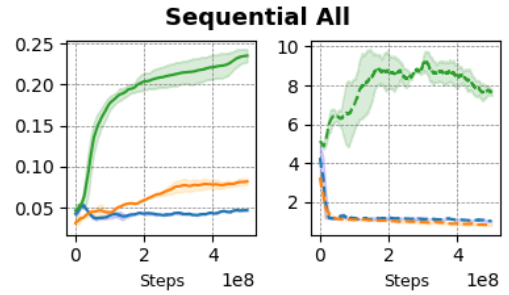
5.2.3 Проблема безопасного исследования

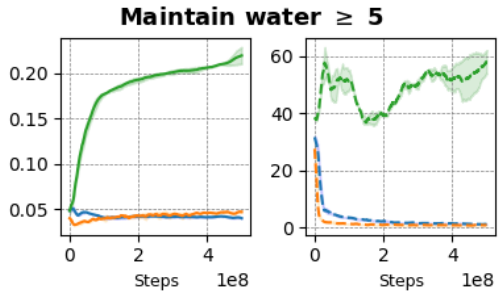
Рис. 5.2 и рис. 5.4 показывают кривые обучения базовых моделей на основном наборе задач и на наборе Caged. Безопасные подходы PPO-LAG и PPO-Cost успешно решают только набор Mathematical All. Во всех остальных задачах агенты остаются безопасными, но не увеличивают эпизодическое вознаграждение, что указывает на слабую способность к безопасному исследованию.

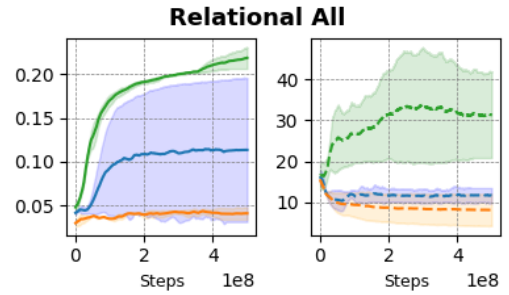
Например, на рис. 5.3 при бюджетных ограничениях Maintain 💧 $\geqslant 5$ агент учится находиться рядом с источником воды, чтобы быстро восполнять её уровень, и при этом не пытается исследовать среду. Ограничение Maintain ⚡ $\geqslant 5$ оказывается наиболее простым для агента, поскольку требует выполнения одного действия — сна, которое не мешает исследованию среды и поддержанию уровня энергии.

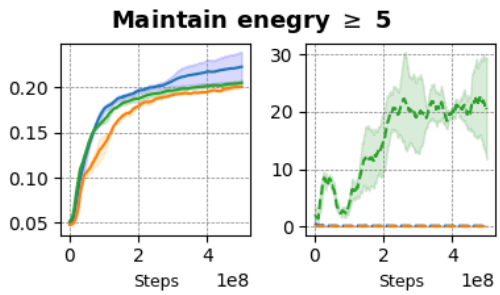


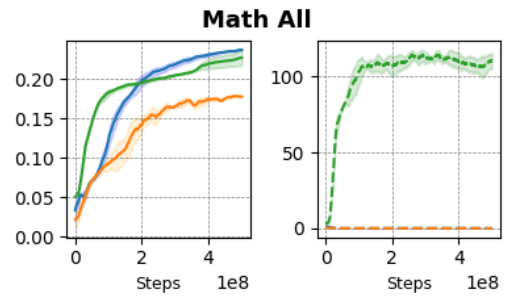


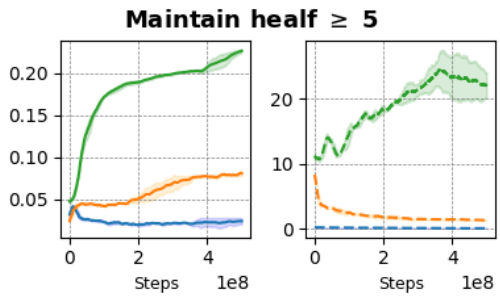


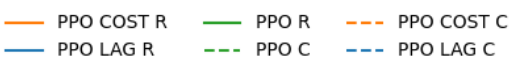












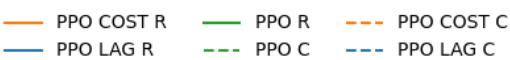
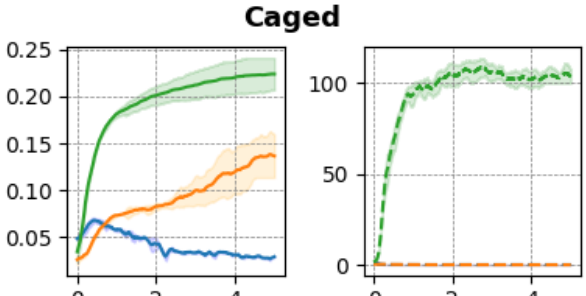


Рисунок 5.2 — **Сравнение базовых ме-**Рисунок 5.3 — **Сравнение базовых ме-**

тодов на основном наборе задач. R **тодов на бюджетных ограничениях**. R — эпизодическое вознаграждение, C —— эпизодическое вознаграждение, C — эпизодический штраф. эпизодический штраф.



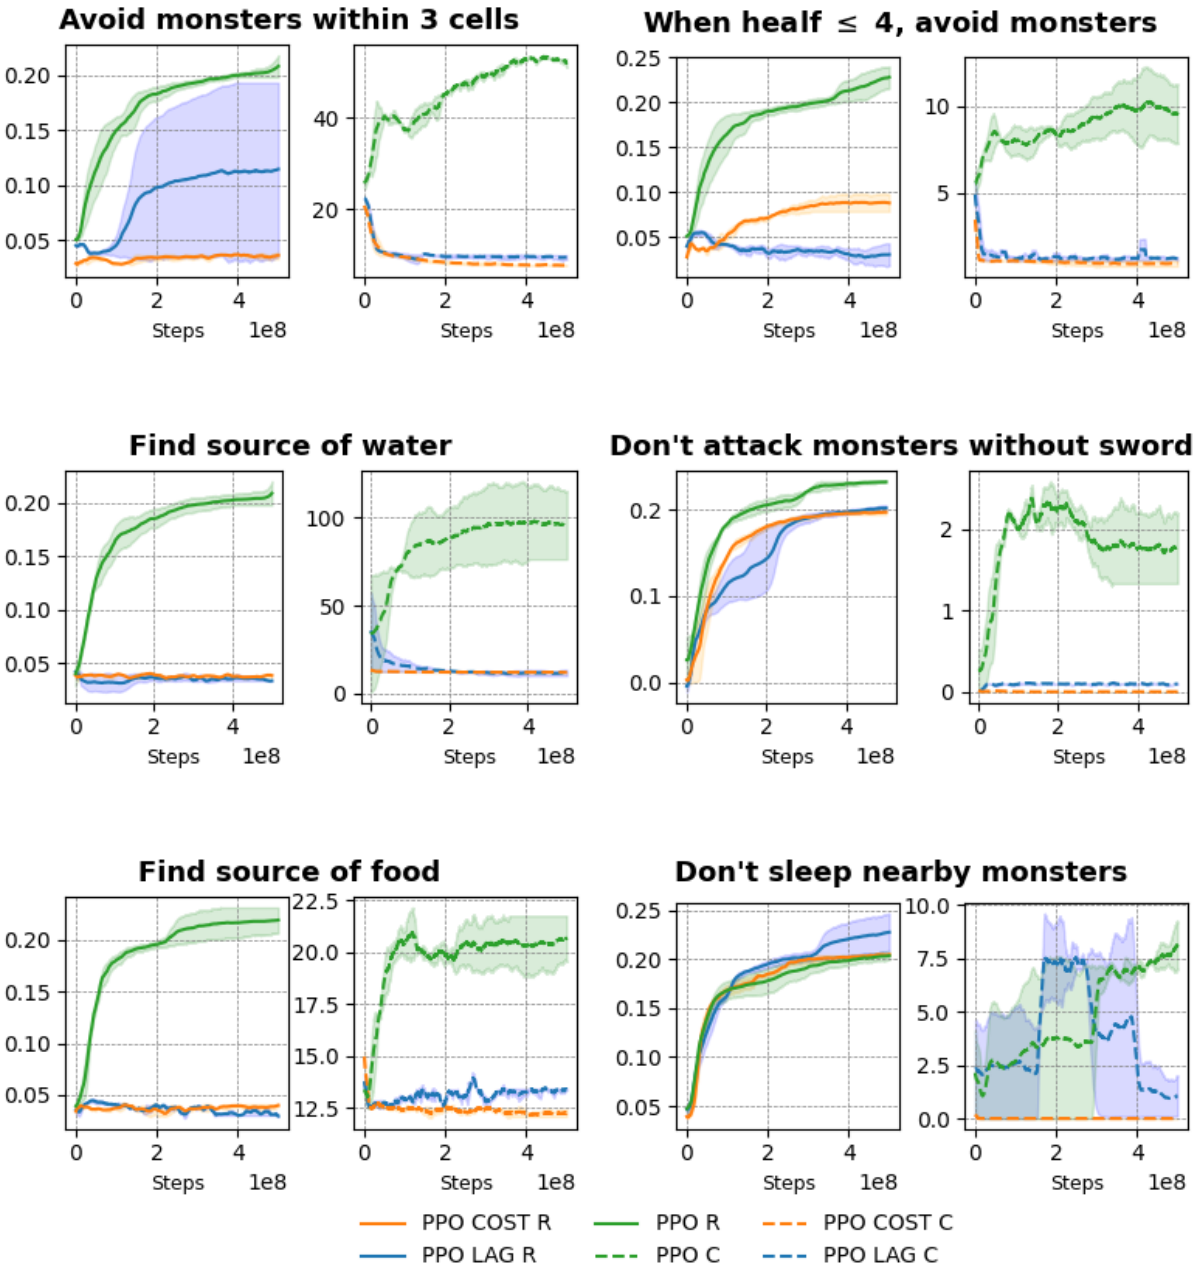


Рисунок 5.5 — **Слева**: сравнение базовых методов на отношенческом наборе задач. **Справа**: сравнение базовых методов на последовательном наборе задач. R — эпизодическое вознаграждение, C — эпизодический штраф.

На рис. 5.6 на математическом наборе безопасные методы обучились соблюдать ограничение за счёт простого поведения — перестать рубить деревья и убивать коров, что может приводить к гораздо меньшему уровню эпизодического вознаграждения (PPO-LAG).

5.2.4 Абляционный анализ безопасного поведения

Важной особенностью бенчмарка Caged CrafText является наличие большого набора метрик оценки поведения агентов, например «Eat Cow», «Defeat Skeleton», «Wake Up». Это позволяет проводить абляционный анализ и изучать, за счёт какого поведения агент снижает штрафы и становится безопасным. Отслеживая достижения в процессе обучения, можно выявлять конкретные изменения в поведении агента.

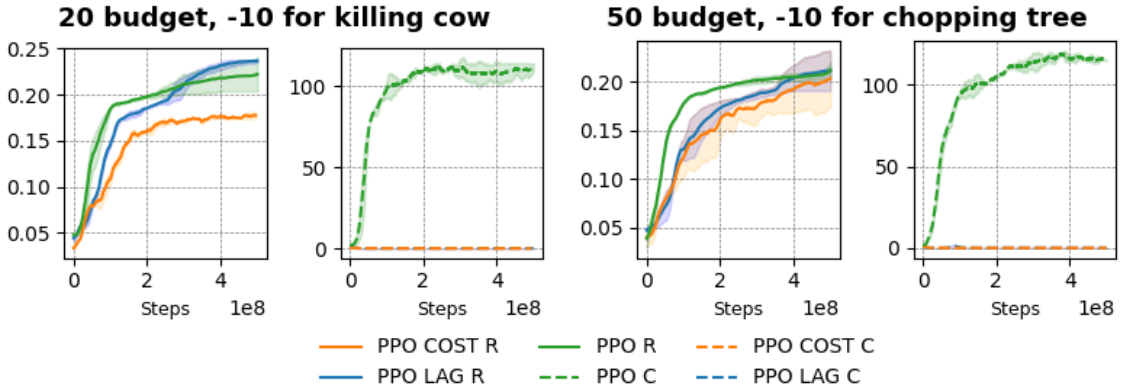


Рисунок 5.6 — **Сравнение базовых методов на математическом наборе задач**. R — эпизодическое вознаграждение, C — эпизодический штраф.

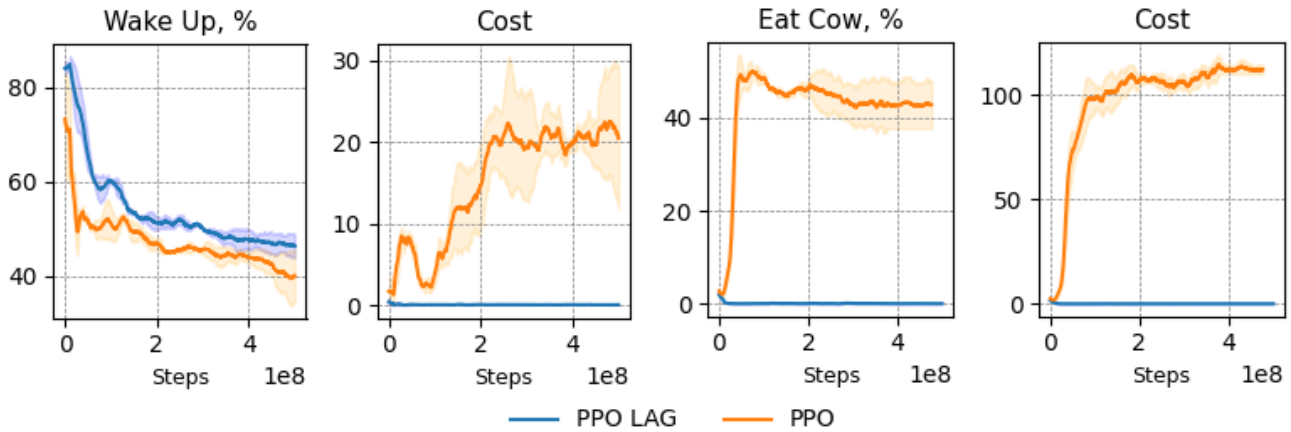


Рисунок 5.7 — **Слева**: достижение «Eat Cow» при ограничении «20 budget, -10 for killing  ». **Справа**: достижение «Wake Up» при ограничении «Maintain  $\geqslant 5$».

На рис. 5.7 слева показано, что безопасное поведение PPO-LAG в задаче с математическим ограничением достигается за счёт того, что агент перестаёт убивать коров. На рис. 5.7 справа видно, что PPO-LAG превращается в «спящего

агента»: он постоянно выполняет действие сна и тем самым поддерживает высокий уровень энергии.

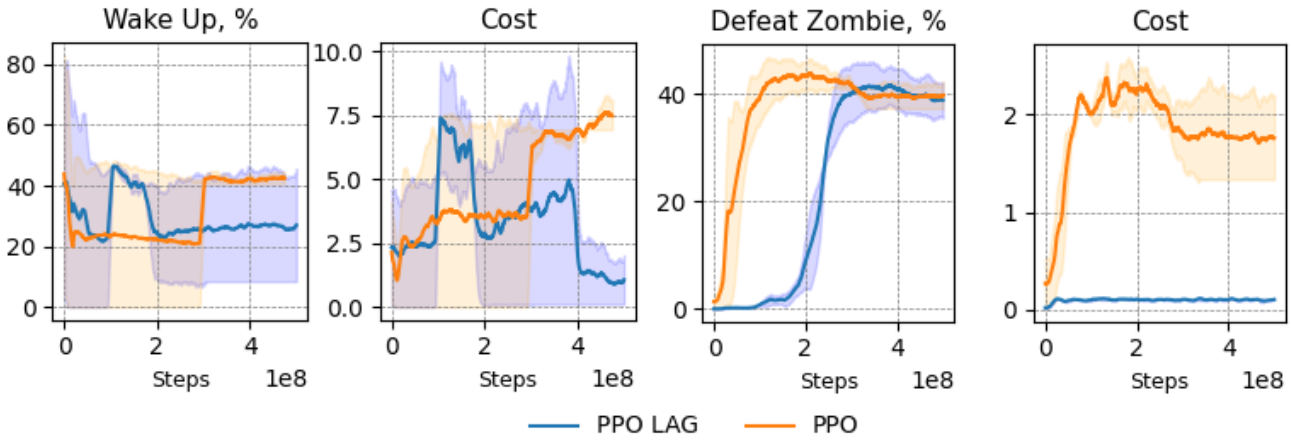


Рисунок 5.8 — **Слева**: достижение «Wake Up» при ограничении «Don't sleep nearby  ». **Справа**: достижение «Defeat Zombie» при ограничении «Don't attack  w/o  ».

В отличие от этого, рис. 5.8 слева показывает, что при ограничении «не спать рядом с монстрами» агент PPO-LAG почти полностью прекращает спать, поскольку оптимальная стратегия для соблюдения такого ограничения состоит в минимизации сна и попытке решить задачу как можно быстрее. Рис. 5.8 справа показывает, что в задаче «не атаковать монстров без деревянного меча» агент PPO-LAG сначала избегает монстров, убегая от них. После того как агент обучается создавать меч, он начинает активно уничтожать монстров сразу после создания меча.

5.2.5 Подходы на основе больших языковых моделей

Одной из особенностей Caged CrafText является естественная поддержка языкового интерфейса, что позволяет использовать большие языковые модели. Оценка Qwen2.5-72B-Instruct в режиме без обучения (zero-shot) показывает, что LLM-агент достигает одинаковых значений эпизодического вознаграждения ($R \approx 0.19$) для всех категорий ограничений: бюджетных, последовательных, математических и отношенческих. Это указывает на его способность к рассуждению и долгосрочному планированию, позволяющую поддерживать стабильное выполнение целевых инструкций.

Как показано в табл. 14, значения штрафов существенно различаются между типами ограничений. В бюджетных задачах, например Maintain  $\geqslant 5$, LLM-агент получает высокие штрафы ($C \approx 28$–31). Основная причина состоит в том, что он не поддерживает ресурсы стабильно: агент может понимать цель, но не выстраивает надёжный цикл сбора воды, еды или восстановления других показателей. В отношенческих задачах возникает другая ошибка. При ограничениях вроде избегания монстров в радиусе трёх клеток агент часто нарушает правило во время перемещения и накапливает штрафы ($C \approx 47$–53). В этих случаях текстовое правило не всегда достаточно точно связывается с конкретным положением объектов в среде.

Математические ограничения оказываются для LLM-агента проще. В них штраф начисляется за отдельные действия, например рубку деревьев или убийство коров, поэтому правило можно применить как явный запрет или счётчик. Поэтому штрафы на таких задачах ниже ($C \approx 8$–18). Это говорит не о полной безопасности LLM-агента, а о том, что дискретные текстовые запреты ему легче соблюдать, чем ограничения, требующие постоянного контроля ресурсов или пространственных отношений.

Основные выводы. Эксперименты на Caged CrafText показывают разные слабые места у обучаемых агентов с подкреплением и LLM-агента. PPO-LAG и PPO-Cost умеют снижать штрафы, но часто делают это за счёт остановки исследования и перехода к локально безопасному поведению. LLM-агент, наоборот, лучше сохраняет выполнение целевой инструкции и получает схожие значения эпизодического вознаграждения на разных типах задач ($R = 0.18$–0.20), но хуже контролирует физическое выполнение текстовых ограничений в среде.

5.3 Выводы по главе

В данной главе рассмотрен переход от классической постановки безопасного обучения с подкреплением к мультимодальной постановке, где и цель, и ограничение безопасности задаются на естественном языке. Для этого представлен бенчмарк Caged CrafText, расширяющий CrafText задачами с текстовыми ограничениями безопасности. Постановка бенчмарка, типы ограничений и уровни датасета описаны в разд. 5.1.

Бенчмарк включает четыре типа ограничений: бюджетные, последовательные, математические и отношенческие. Они позволяют оценивать память, глубокое исследование среды, безопасное исследование, рассуждение, долгосрочное планирование и понимание естественного языка. Отладочный набор задач используется для анализа отдельных типов ошибок, а основной набор проверяет способность агента работать с разными текстовыми ограничениями и их переформулировками.

Эксперименты в разд. 5.2 показывают, что существующие методы безопасного обучения с подкреплением плохо справляются с ограничениями и задачами, заданными на естественном языке. PPO достигает высокого эпизодического вознаграждения, но при этом не учитывает условия по безопасности. PPO-LAG и PPO-Cost учитывают ограничения по безопасности, но за счёт консервативного поведения: агент перестаёт исследовать среду и не продвигается к цели.

Абляционный анализ в разд. 5.2.4 показывает, что Caged CrafText позволяет численно оценить, за счёт какого поведения различные агенты становятся безопасными; например, эффект «спящего агента» позволяет агенту не нарушать ограничения по энергии.

Агент на основе большой языковой модели способен решать исходные задачи, но часто нарушает ограничения безопасности (в бюджетных и отношенческих задачах), поскольку у него отсутствует навык связывания текстового ограничения с состоянием и объектами среды.

В целом Caged CrafText показывает, что задачи с естественно-языковыми целями и ограничениями требуют от агента сразу нескольких способностей: понимать текст, помнить расположение объектов, исследовать среду, планировать на длинном горизонте и переводить текстовые правила в безопасное поведение.

Заключение

В диссертационной работе рассмотрены методы безопасного обучения с подкреплением для задач, где агенту необходимо не только достигать цели, но и ограничивать штрафы за небезопасные действия во время обучения и исполнения. Такой конфликт особенно заметен в робототехнических задачах: для нахождения успешного поведения агент должен исследовать среду, однако именно исследование часто приводит к столкновениям, попаданию в опасные области или другим нарушениям ограничений.

В работе последовательно рассмотрены три аспекта этой проблемы. Первый связан с использованием моделей мира для предварительной оценки последствий действий. Второй — с иерархической декомпозицией поведения, которая позволяет работать с задачами большого горизонта через промежуточные подцели. Третий — с переходом к постановке, где цель и ограничение безопасности задаются не только численно, но и на естественном языке.

Проведённый обзор показывает, что существующие методы решают эти задачи только частично. Одноуровневые безопасные стратегии могут снижать штрафы, но в задачах большого горизонта часто становятся слишком осторожными и перестают продвигаться к цели. Методы на основе моделей мира дают возможность оценивать риск до выполнения действия, однако их качество зависит от точности модели, горизонта предсказания и выбранного способа оценки штрафов. Подходы с априорной информацией о среде могут давать более жёсткий контроль безопасности, но обычно требуют известной модели объекта управления или явных функций ограничений.

В рамках направления безопасного обучения с подкреплением на основе модели мира предложена модификация подхода SPOWL [40], в котором модель мира используется для оценки награды, штрафов и долгосрочного риска кандидатных действий. Показано, что безопасное исследование должно учитывать не только мгновенный штраф, но и оценки будущих накопленных штрафов, позволяющие оценивать риск за пределами короткого горизонта планирования. Экспериментальный анализ показал, что способ агрегации ансамбля функций оценки будущих накопленных штрафов существенно влияет на баланс между безопасностью и эффективностью.

Для решения проблемы безопасного исследования в задачах с большим горизонтом разработан метод SG-Safe [38]. Метод использует стратегию генерации промежуточных подцелей, которая применяется на этапе обучения и направляет безопасную стратегию к более информативным областям пространства состояний. При этом на этапе исполнения используется только итоговая безопасная стратегия, поэтому метод не требует планирования и дополнительных вычислительных затрат. Эксперименты на Safety Gym и POLAMP показали, что SG-Safe повышает успешность решения навигационных задач при сохранении низкого уровня нарушений безопасности. В среднем на Safety Gym метод достигает доли успешных эпизодов 0.87 при частоте столкновений 0.03, а на POLAMP демонстрирует преимущество в задачах с длинными маршрутами и узкими коридорами.

Дальнейшее развитие иерархического подхода реализовано в методе ITES [28]. В отличие от SG-Safe, метод ITES вводит явный контроль безопасности как на уровне генерации подцелей, так и на уровне их достижения. Верхнеуровневая стратегия генерирует промежуточные подцели с учётом модели штрафов и верхнеуровневого критика штрафов, а низкоуровневая стратегия использует модель мира для проверки безопасности коротких воображаемых траекторий. Эксперименты на SafeAntMaze и SafePusher показали, что ITES превосходит неиерархические методы безопасного обучения с подкреплением в задачах с большим горизонтом, где многие методы сравнения либо нарушают ограничения, либо не достигают цели. В SafeAntMaze C-shape метод достигает доли успешных эпизодов 0.88 при штрафов 15.2, а в SafePusher — доли успешных эпизодов 0.42 при штрафов 12.8, сохраняя ограничения безопасности.

Отдельно в диссертации рассмотрена задача безопасного обучения с подкреплением с естественно-языковыми целями и ограничениями. Для этой постановки разработан бенчмарк Caged CrafText [39], расширяющий CrafText до задач, где агент получает не только инструкцию цели, но и текстовое ограничение. Бенчмарк включает бюджетные, последовательные, математические и отношенческие ограничения, проверяющие память, безопасное исследование, рассуждение, понимание того, как агент соотносит текст с объектами и состояниями среды, а также долгосрочное планирование. Эксперименты с PPO, PPO-LAG, PPO-Cost и агентом на основе большой языковой модели показали, что существующие подходы плохо решают задачи, где инструкция и ограничения заданы с помощью естественного языка. PPO учится решать задачу, но систематически нарушает ограничения; PPO-LAG снижает уровень эпизодических нарушений, но часто ста-

новится чрезмерно консервативным; агент на основе большой языковой модели лучше интерпретирует инструкции, но сохраняет высокий уровень нарушений из-за ошибок связывания текстового ограничения с состояниями среды.

При этом остаются направления для дальнейшего исследования. Для методов безопасного обучения с подкреплением с применением иерархии остаётся проблема обеспечения более строгих гарантий безопасности для каждого действия агента, например с помощью барьерных функций или безопасных слоёв. Для задач с естественно-языковыми ограничениями проблемой остаётся связывание языка и наблюдений: агент должен понимать текстовое ограничение и соотносить его с объектами среды.

По итогам, диссертационная работа развивает безопасное обучение с подкреплением в трёх направлениях: оценка долгосрочного риска с помощью моделей мира для обеспечения безопасного исследования, решение проблемы безопасного исследования в задачах с большим горизонтом с помощью иерархической структуры и разработка бенчмарка для обучения и оценки методов безопасного обучения с подкреплением с ограничениями и задачами, заданными на естественном языке.

Словарь терминов

CEM : Cross-Entropy Method, метод кросс-энтропии

CMDP : Constrained Markov Decision Process, марковский процесс принятия решений с ограничениями

CPO : Constrained Policy Optimization, оптимизация стратегии с ограничениями

CR : Collision Rate, частота столкновений

GCRL : Goal-Conditioned Reinforcement Learning, обучение с подкреплением, обусловленное целью

HER : Hindsight Experience Replay, переиспользование опыта с переобозначением цели

HRL : Hierarchical Reinforcement Learning, иерархическое обучение с подкреплением

ITES : Imagine To Ensure Safety, метод безопасного иерархического обучения с использованием модели мира

LLM : Large Language Model, большая языковая модель

MBRL : Model-Based Reinforcement Learning, обучение с подкреплением на основе модели мира

MCTS : Monte-Carlo Tree Search, поиск по дереву методом Монте-Карло

MDP : Markov Decision Process, марковский процесс принятия решений

MFRL : Model-Free Reinforcement Learning, обучение с подкреплением без модели мира

MPC : Model Predictive Control, управление с предсказанием модели

MTSC — Mean Total Safety Cost, средний накопленный штраф безопасности за эпизод

PPO : Proximal Policy Optimization, метод оптимизации стратегии с ограничением шага обновления

RQ : Research Question, исследовательский вопрос

SAC : Soft Actor-Critic, актор-критик метод с энтропийной регуляризацией

Safe RL : Safe Reinforcement Learning, безопасное обучение с подкреплением

SG-Safe : Subgoal-Guided Safe Reinforcement Learning, безопасное обучение с подкреплением с направлением через подцели

SPOWL : Safe Planning and Policy Optimization via World Model Learning, безопасное планирование и оптимизация стратегии с использованием модели мира

SR : Success Rate, доля успешных эпизодов

TD-MPC : Temporal Difference Learning for Model Predictive Control, обучение временных разностей для управления с предсказанием модели

TD3 : Twin Delayed Deep Deterministic Policy Gradient, метод детерминированного градиента стратегии с двумя критиками и задержанным обновлением

VLM : Vision-Language Model, визуально-языковая модель

Список литературы

1. Irl-vla: Training an vision-language-action policy via reward world model / A. Jiang, Y. Gao, Y. Wang, Z. Sun, S. Wang, Y. Heng, H. Sun, S. Tang, L. Zhu, J. Chai [и др.] // arXiv preprint arXiv:2508.06571. — 2025.
2. *Polydoros*, *A. S.* Survey of model-based reinforcement learning: Applications on robotics / A. S. Polydoros, L. Nalpantidis // Journal of Intelligent & Robotic Systems. — 2017. — Т. 86, № 2. — С. 153—173.
3. Model-based reinforcement learning: A survey / T. M. Moerland, J. Broekens, A. Plaat, C. M. Jonker [и др.] // Foundations and Trends® in Machine Learning. — 2023. — Т. 16, № 1. — С. 1—118.
4. *Altman*, *E.* Constrained Markov decision processes. Т. 7 / E. Altman. — CRC press, 1999.
5. A review of safe reinforcement learning: Methods, theory and applications / S. Gu, L. Yang, Y. Du, G. Chen, F. Walter, J. Wang, Y. Yang, A. Knoll // arXiv preprint arXiv:2205.10330. — 2022.
6. *Stooke*, *A.* Responsive Safety in Reinforcement Learning by PID Lagrangian Methods / A. Stooke, J. Achiam, P. Abbeel // Proceedings of the 37th International Conference on Machine Learning. Т. 119. — PMLR, 2020. — С. 9133—9143.
7. *Ray*, *A.* Benchmarking safe exploration in deep reinforcement learning / A. Ray, J. Achiam, D. Amodei // arXiv preprint arXiv:1910.01708. — 2019.
8. WCSAC: Worst-case soft actor critic for safety-constrained reinforcement learning / Q. Yang, T. D. Simão, S. H. Tindemans, M. T. Spaan // Proceedings of the AAAI Conference on Artificial Intelligence. Т. 35. Вып. 12. — 2021. — С. 10639—10646.
9. Safe exploration in continuous action spaces / G. Dalal, K. Dvijotham, M. Vecerik, T. Hester, C. Paduraru, Y. Tassa // arXiv preprint arXiv:1801.08757. — 2018.
10. Safe reinforcement learning using robust control barrier functions / Y. Emam, G. Notomista, P. Glotfelter, Z. Kira, M. Egerstedt // IEEE Robotics and Automation Letters. — 2022.

11. Learning-based model predictive control for safe exploration and reinforcement learning / T. Koller, F. Berkenkamp, M. Turchetta, A. Krause // Advances in Neural Information Processing Systems. T. 31. — 2018.

12. Verifiably safe exploration for end-to-end reinforcement learning / N. Hunt, N. Fulton, S. Magliacane, T. N. Hoang, S. Das, A. Solar-Lezama // Proceedings of the 24th International Conference on Hybrid Systems: Computation and Control. — 2021. — С. 1—11.

13. Safe Reinforcement Learning via Probabilistic Logic Shields / W.-C. Yang, G. Marra, G. Rens, L. De Raedt // Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence, IJCAI-23 / под ред. E. Elkind. — International Joint Conferences on Artificial Intelligence Organization, 08.2023. — С. 5739—5749. — Main Track.

14. *Wabersich*, *K. P.* Predictive safety filter for learning-based control / K. P. Wabersich, M. N. Zeilinger // IEEE Transactions on Automatic Control. — 2023. — Т. 68, № 5. — С. 2618—2633.

15. *Jayant*, *A. K.* Model-based safe deep reinforcement learning via a constrained proximal policy optimization algorithm / A. K. Jayant, S. Bhatnagar // Advances in Neural Information Processing Systems. — 2022. — Т. 35. — С. 24432—24445.

16. Constrained policy optimization via bayesian world models / Y. As, I. Usmanova, S. Curi, A. Krause. — 2022. — Preprint arXiv:2201.09802.

17. Safe reinforcement learning from pixels using a stochastic latent representation / Y. Hogewind, T. D. Simao, T. Kachman, N. Jansen // The Eleventh International Conference on Learning Representations. — 2022.

18. SafeDreamer: Safe Reinforcement Learning with World Models / W. Huang, J. Ji, B. Zhang, C. Xia, Y. Yang // The Twelfth International Conference on Learning Representations. — 2024.

19. Hierarchical Reinforcement Learning: A Survey / S. Pateria, B. Subagdja, A.-H. Tan, C. Quek // ACM Computing Surveys. — 2021. — Т. 54, № 5. — С. 1—35.

20. *Sutton*, *R. S.* Between MDPs and semi-MDPs: A framework for temporal abstraction in reinforcement learning / R. S. Sutton, D. Precup, S. Singh // Artificial Intelligence. — 1999. — Т. 112, № 1/2. — С. 181—211.

21. *Bacon*, *P.-L.* The Option-Critic Architecture / P.-L. Bacon, J. Harb, D. Precup // Proceedings of the AAAI Conference on Artificial Intelligence. T. 31. — 2017.

22. *Levy*, *A.* Hierarchical actor-critic / A. Levy, R. Platt, K. Saenko // arXiv preprint arXiv:1712.00948. — 2017. — T. 12. — C. 438.

23. Data-efficient hierarchical reinforcement learning / O. Nachum, S. S. Gu, H. Lee, S. Levine // Advances in neural information processing systems. — 2018. — T. 31.

24. Generating Adjacency-Constrained Subgoals in Hierarchical Reinforcement Learning / T. Zhang, S. Guo, T. Tan, X. Hu, F. Chen // Advances in Neural Information Processing Systems. T. 33. — 2020. — C. 21579—21590.

25. Safe Robot Navigation Using Constrained Hierarchical Reinforcement Learning / F. S. Roza, H. Rasheed, K. Roscher, X. Ning, S. Günnemann // 2022 21st IEEE International Conference on Machine Learning and Applications (ICMLA). — IEEE. 2022. — C. 737—742.

26. Model-free neural lyapunov control for safe robot navigation / Z. Xiong, J. Eapper, A. H. Qureshi, S. Jagannathan // 2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). — IEEE. 2022. — C. 5572—5579.

27. *Lee*, *S.-H.* Imagination-Augmented Hierarchical Reinforcement Learning for Safe and Interactive Autonomous Driving in Urban Environments / S.-H. Lee, Y. Jung, S.-W. Seo // IEEE Transactions on Intelligent Transportation Systems. — 2024.

28. *Gorbov*, *G.* Imagine To Ensure Safety in Hierarchical Reinforcement Learning / G. Gorbov, A. Latyshev, A. I. Panov. — 2026. — arXiv: 2606.22509. — URL: https://arxiv.org/abs/2606.22509.

29. *Andreas*, *J.* Alignment-based compositional semantics for instruction following / J. Andreas, D. Klein // Proceedings of the Conference on Empirical Methods in Natural Language Processing. — 2015. — C. 1165—1174.

30. Vision-and-language navigation: Interpreting visually-grounded navigation instructions in real environments / P. Anderson, Q. Wu, D. Teney, J. Bruce, M. Johnson, N. Sünderhauf, I. Reid, S. Gould, A. van den Hengel // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. — 2018. — C. 3674—3683.

31. Mapping instructions to actions in 3D environments with visual goal prediction / D. Misra, A. Bennett, V. Blukis, E. Niklasson, M. Shatkhin, Y. Artzi // Proceedings of the Conference on Empirical Methods in Natural Language Processing. — 2018. — С. 2667—2678.

32. Learning to follow directions in street view / K. M. Hermann, M. Malinowski, P. Mirowski, A. Banki-Horvath, K. Anderson, R. Hadsell // Proceedings of the AAAI Conference on Artificial Intelligence. Т. 34. — 2020. — С. 11773—11781.

33. Towards learning a generic agent for vision-and-language navigation via pre-training / W. Hao, C. Li, X. Li, L. Carin, J. Gao // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. — 2020. — С. 13137—13146.

34. TOUCHDOWN: Natural language navigation and spatial reasoning in visual street environments / H. Chen, A. Suhr, D. Misra, N. Snavely, Y. Artzi // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. — 2019. — С. 12538—12547.

35. Talk the walk: Navigating New York City through grounded dialogue / H. de Vries, K. Shuster, D. Batra, D. Parikh, J. Weston, D. Kiela // arXiv preprint arXiv:1807.03367. — 2018.

36. Safe reinforcement learning with natural language constraints / T.-Y. Yang, M. Y. Hu, Y. Chow, P. J. Ramadge, K. Narasimhan // Advances in Neural Information Processing Systems. — 2021. — Т. 34. — С. 13794—13808.

37. Guiding safe reinforcement learning policies using structured language constraints / B. Prakash, N. Waytowich, A. Ganesan, T. Oates, T. Mohsenin. — 2020. — UMBC Student Collection.

38. *Gorbov*, *G.* Enhancing Safe Exploration Through Subgoal Guidance / G. Gorbov, A. I. Panov // Technologies. — 2026. — Vol. 14, no. 3. — P. 146.

39. Caged CrafText: Language-Grounded Safety Constraints for Multimodal Reinforcement Learning in CrafText / G. Gorbov, D. Lukashevsky, A. Skrynnik, A. I. Panov // Optical Memory and Neural Networks. — 2026. — Vol. 35. — P. 18—30.

40. *Latyshev, A.* Safe Planning and Policy Optimization via World Model Learning / A. Latyshev, G. Gorbov, A. I. Panov // Frontiers in Artificial Intelligence and Applications: Proceedings of the 28th European Conference on Artificial Intelligence (ECAI 2025). Vol. 413. — IOS Press, 2025. — P. 1945—1952.

41. CrafText Benchmark: Advancing Instruction Following in Complex Multimodal Open-Ended World / Z. Volovikova, G. Gorbov, P. Kuderov, A. Panov, A. Skrynnik // Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). — 2025. — P. 26131—26151.

42. Constrained policy optimization / J. Achiam, D. Held, A. Tamar, P. Abbeel // International conference on machine learning. — PMLR. 2017. — C. 22—31.

43. Constrained update projection approach to safe policy optimization / L. Yang, J. Ji, J. Dai, L. Zhang, B. Zhou, P. Li, Y. Yang, G. Pan // Advances in Neural Information Processing Systems. T. 35. — 2022. — C. 9111—9124.

44. *Zhang, Y.* First order constrained optimization in policy space / Y. Zhang, Q. Vuong, K. Ross // Advances in Neural Information Processing Systems. T. 33. — 2020. — C. 15338—15349.

45. Sauté RL: Almost Surely Safe Reinforcement Learning Using State Augmentation / A. Sootla, A. I. Cowen-Rivers, T. Jafferjee, Z. Wang, D. H. Mguni, J. Wang, H. Ammar // International Conference on Machine Learning. — PMLR. 2022. — C. 20423—20443.

46. *He, T.* AutoCost: Evolving Intrinsic Cost for Zero-Violation Reinforcement Learning / T. He, W. Zhao, C. Liu // Proceedings of the AAAI Conference on Artificial Intelligence. T. 37. — 2023. — C. 14847—14855.

47. Safe reinforcement learning in black-box environments via adaptive shielding / D. Bethell, S. Gerasimou, R. Calinescu, C. Imrie // arXiv preprint arXiv:2405.18180. — 2024.

48. *Camacho, E. F.* Model Predictive Control / E. F. Camacho, C. Bordons. — Springer, 2007.

49. Constrained model-based reinforcement learning with robust cross-entropy method / Z. Liu, H. Zhou, B. Chen, S. Zhong, M. Hebert, D. Zhao. — 2020. — Preprint arXiv:2010.07968.

50. *Wen*, *M.* Constrained cross-entropy method for safe reinforcement learning / M. Wen, U. Topcu // Advances in Neural Information Processing Systems. — 2018. — T. 31.

51. Dream to Control: Learning Behaviors by Latent Imagination / D. Hafner, T. Lillicrap, J. Ba, M. Norouzi // International Conference on Learning Representations. — 2020.

52. *Thomas*, *G.* Safe Reinforcement Learning by Imagining the Near Future / G. Thomas, Y. Luo, T. Ma // Advances in Neural Information Processing Systems. T. 34. — 2021. — C. 24653—24665.

53. Mastering Diverse Domains through World Models / D. Hafner, J. Pasukonis, J. Ba, T. Lillicrap. — 2023. — Preprint arXiv:2301.04104.

54. *Hansen*, *N.* Temporal Difference Learning for Model Predictive Control / N. Hansen, X. Wang, H. Su // International Conference on Machine Learning. — PMLR. 2022. — C. 8387—8406.

55. *Hansen*, *N.* TD-MPC2: Scalable, Robust World Models for Continuous Control / N. Hansen, H. Su, X. Wang // International Conference on Learning Representations (ICLR). — 2024.

56. Safety Gymnasium: A Unified Safe Reinforcement Learning Benchmark / J. Ji, B. Zhang, J. Zhou, X. Pan, W. Huang, R. Sun, Y. Geng, Y. Zhong, J. Dai, Y. Yang // Thirty-seventh Conference on Neural Information Processing Systems Datasets and Benchmarks Track. — 2023.

57. *Sikchi*, *H.* Learning Off-Policy with Online Planning / H. Sikchi, W. Zhou, D. Held // Conference on Robot Learning. — PMLR. 2022. — C. 1622—1633.

58. Autonomous driving in urban environments: approaches, lessons and challenges / M. Campbell, M. Egerstedt, J. P. How, R. M. Murray // Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences. — 2010. — T. 368, № 1928. — C. 4649—4672.

59. A deep reinforcement learning network for traffic light cycle control / X. Liang, X. Du, G. Wang, Z. Han // IEEE Transactions on Vehicular Technology. — 2019. — T. 68, № 2. — C. 1243—1253.

60. *Wei*, *T.* Deep Reinforcement Learning for Building HVAC Control / T. Wei, Y. Wang, Q. Zhu // Proceedings of the 54th Annual Design Automation Conference. — ACM. 2017. — C. 1—6.

61. *Kayhan*, *B. M.* Reinforcement learning applications to machine scheduling problems: a comprehensive literature review / B. M. Kayhan, G. Yildiz // Journal of Intelligent Manufacturing. — 2023. — Т. 34, № 3. — С. 905—929.

62. AI Safety Gridworlds / J. Leike, M. Martic, V. Krakovna, P. A. Ortega, T. Everitt, L. Lefort, L. Orseau, S. Legg // arXiv preprint arXiv:1711.09883. — 2017.

63. Minigrid & Miniworld: Modular & Customizable Reinforcement Learning Environments for Goal-Oriented Tasks / M. Chevalier-Boisvert, B. Dai, M. Towers, R. Perez-Vicente, L. Willems, S. Lahlou, S. Pal, P. S. Castro, J. Terry // Advances in Neural Information Processing Systems. Т. 36. — 2023. — С. 73383—73394.

64. *Wachi*, *A.* Safe Policy Optimization with Local Generalized Linear Function Approximations / A. Wachi, Y. Wei, Y. Sui // Advances in Neural Information Processing Systems. Т. 34. — 2021. — С. 20759—20771.

65. Safe Exploration in Reinforcement Learning: A Generalized Formulation and Algorithms / A. Wachi, W. Hashimoto, X. Shen, K. Hashimoto // Advances in Neural Information Processing Systems. Т. 36. — 2023.

66. Safe-control-gym: A unified benchmark suite for safe learning-based control and reinforcement learning in robotics / Z. Yuan, A. W. Hall, S. Zhou, L. Brunke, M. Greeff, J. Panerati, A. P. Schoellig // IEEE Robotics and Automation Letters. — 2022. — Т. 7, № 4. — С. 11142—11149.

67. An empirical investigation of the challenges of real-world reinforcement learning / G. Dulac-Arnold, S. Levine, I. Mordatch, J. Li, P. Abbeel [и др.] // arXiv preprint arXiv:2003.11881. — 2020.

68. Safe Multi-Agent Reinforcement Learning for Multi-Robot Control / S. Gu, J. G. Kuba, Y. Chen, Y. Du, L. Yang, A. Knoll, Y. Yang // Artificial Intelligence. — 2023. — Т. 319. — С. 103905.

69. CARLA: An open urban driving simulator / A. Dosovitskiy, G. Ros, F. Codevilla, A. Lopez, V. Koltun // Conference on robot learning. — PMLR. 2017. — С. 1—16.

70. TORCS: The Open Racing Car Simulator / B. Wymann, E. Espié, C. Guionneau, C. Dimitrov, A. Sumner, B. Tóth, R. Menzel // Proceedings of the 4th International Conference on Methods and Techniques in Behavioral Research. Т. 4. — 2000. — С. 65—71.

71. MetaDrive: Composing Diverse Driving Scenarios for Generalizable Reinforcement Learning / Q. Li, Z. Peng, L. Feng, Q. Zhang, B. Zhou // IEEE Transactions on Pattern Analysis and Machine Intelligence. T. 45. — IEEE. 2023. — C. 3461—3475.

72. *Wang*, *S.* Deep reinforcement learning for autonomous driving / S. Wang, D. Jia, X. Weng // arXiv preprint arXiv:1811.11329. — 2018.

73. *Nehme*, *G.* Safe Navigation: Training Autonomous Vehicles using Deep Reinforcement Learning in CARLA / G. Nehme, T. Y. Deo // arXiv preprint arXiv:2311.10735. — 2023.

74. *Hossain*, *J.* Autonomous Driving with Deep Reinforcement Learning in CARLA Simulation / J. Hossain // arXiv preprint arXiv:2306.11217. — 2023.

75. *Tomilin*, *T.* HASARD: A Benchmark for Vision-Based Safe Reinforcement Learning in Embodied Agents / T. Tomilin, M. Fang, M. Pechenizkiy // arXiv preprint arXiv:2503.08241. — 2025.

76. ViZDoom: A Doom-based AI Research Platform for Visual Reinforcement Learning / M. Kempka, M. Wydmuch, G. Górcz, J. Jańskowski, M. Runc, P. Bojarski, A. Kaczmarczyk, M. Michalski, P. Kaczmarczyk, C. Bóhm [и др.] // IEEE Conference on Computational Intelligence and Games. — IEEE. 2016. — C. 1—8.

77. Sample Factory: Egocentric 3D Control from Pixels at 100000 FPS with Asynchronous Reinforcement Learning / A. Petrenko, Z. Huang, T. Kumar, M. Wawrzyniak, S. Sukhbataar, A. Szlam // International Conference on Machine Learning. — PMLR. 2020. — C. 7652—7662.

78. *Howard*, *T. M.* A natural language planner interface for mobile manipulators / T. M. Howard, S. Tellex, N. Roy // IEEE International Conference on Robotics and Automation. — IEEE. 2014. — C. 6652—6659.

79. Learning a natural-language to LTL executable semantic parser for grounded robotics / C. Wang, C. Ross, Y.-L. Kuo, B. Katz, A. Barbu // arXiv preprint arXiv:2008.03277. — 2020.

80. *MacMahon*, *M.* Walk the talk: Connecting language, knowledge, and action in route instructions / M. MacMahon, B. Stankiewicz, B. Kuipers // Proceedings of the AAAI Conference on Artificial Intelligence. T. 21. — 2006. — C. 1475—1482.

81. *Chen, D. L.* Learning to interpret natural language navigation instructions from observations / D. L. Chen, R. J. Mooney // Proceedings of the AAAI Conference on Artificial Intelligence. T. 25. — 2011. — C. 859—865.

82. *Artzi, Y.* Weakly supervised learning of semantic parsers for mapping instructions to actions / Y. Artzi, L. Zettlemoyer // Transactions of the Association for Computational Linguistics. — 2013. — T. 1. — C. 49—62.

83. *Misra, D.* Mapping instructions and visual observations to actions with reinforcement learning / D. Misra, J. Langford, Y. Artzi // Proceedings of the Conference on Empirical Methods in Natural Language Processing. — 2017. — C. 1004—1015.

84. Understanding natural language commands for robotic navigation and mobile manipulation / S. Tellex, T. Kollar, S. Dickerson, M. Walter, A. Banerjee, S. Teller, N. Roy // Proceedings of the AAAI Conference on Artificial Intelligence. T. 25. — 2011. — C. 1507—1514.

85. *Chevalier-Boisvert, M.* Minimalistic gridworld environment for gymnasium / M. Chevalier-Boisvert, L. Willems, S. Pal // Advances in Neural Information Processing Systems. — 2018. — C. 8024—8035.

86. *Angulo, B.* Policy Optimization to Learn Adaptive Motion Primitives in Path Planning with Dynamic Obstacles / B. Angulo, A. Panov, K. Yakovlev // IEEE Robotics and Automation Letters. — 2022.

87. Constrained variational policy optimization for safe reinforcement learning / Z. Liu, Z. Cen, V. Isenbaev, W. Liu, S. Wu, B. Li, D. Zhao // International Conference on Machine Learning. — PMLR. 2022. — C. 13644—13668.

88. *Chane-Sane, E.* Goal-conditioned reinforcement learning with imagined subgoals / E. Chane-Sane, C. Schmid, I. Laptev // International Conference on Machine Learning. — PMLR. 2021. — C. 1430—1440.

89. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor / T. Haarnoja, A. Zhou, P. Abbeel, S. Levine // International conference on machine learning. — PMLR. 2018. — C. 1861—1870.

90. Anytime motion planning using the RRT / S. Karaman, M. R. Walter, A. Perez, E. Frazzoli, S. Teller // 2011 IEEE international conference on robotics and automation. — IEEE. 2011. — C. 1478—1483.

91. Risk conditioned neural motion planning / X. Huang, M. Feng, A. Jasour, G. Rosman, B. Williams // 2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). — IEEE. 2021. — С. 9057—9063.

92. *Dubins*, *L. E.* On curves of minimal length with a constraint on average curvature, and with prescribed initial and terminal positions and tangents / L. E. Dubins // American Journal of mathematics. — 1957. — Т. 79, № 3. — С. 497—516.

93. Risk-constrained reinforcement learning with percentile risk criteria / Y. Chow, M. Ghavamzadeh, L. Janson, M. Pavone // The Journal of Machine Learning Research. — 2017. — Т. 18, № 1. — С. 6070—6120.

94. *Fujimoto*, *S.* Addressing function approximation error in actor-critic methods / S. Fujimoto, H. Hoof, D. Meger // International Conference on Machine Learning. — PMLR. 2018. — С. 1587—1596.

95. When to Trust Your Model: Model-Based Policy Optimization / M. Janner, J. Fu, M. Zhang, S. Levine // Advances in Neural Information Processing Systems. Т. 32. — Curran Associates, Inc., 2019.

96. CrafText Benchmark: Advancing Instruction Following in Complex Multimodal Open-Ended World / Z. Volovikova, G. Gorbov, P. Kuderov, A. Panov, A. Skrynnik // Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). — Association for Computational Linguistics, 2025. — С. 26131—26151.

Список рисунков

1.1 Среда SafeAntMaze. Сверху показана визуализация SafeAntMazeCshape, где робот Ant должен решить задачу с большим горизонтом и достичь заданной цели. Снизу приведены схемы C-образного лабиринта слева и W-образного лабиринта справа. Зелёная точка обозначает начальное положение Ant, жёлтая точка — целевое положение, светлая область — безопасную зону, розовая область — опасную зону, в которой агент получает штраф $+1$ за каждый шаг, а оранжевая область — статическое препятствие. Красная траектория соответствует алгоритму HRAC, не учитывающему безопасность, а синяя траектория соответствует алгоритму ITES. 35

1.2 Среда SafePusher. Слева показана визуализация MuJoCo: роботизированный манипулятор обозначен чёрным цветом, белый объект является перемещаемым объектом, а красный маркер указывает его целевое положение. Справа приведена схема среды сверху: красный круг обозначает объект для манипуляции, зелёный круг — положение конечной точки манипулятора, жёлтый круг — целевое положение объекта, а синяя зона — опасную область. Агент получает штраф $+1$ за каждый шаг, в течение которого объект находится внутри опасной зоны. 36

1.3 Примеры навигационных задач в бенчмарке POLAMP. Начальное положение и ориентация агента показаны зелёным прямоугольником, целевое положение — жёлтым кругом. Слева показан пример задачи Level 1, где требуется не более одного изменения направления движения. Справа показан пример задачи Level 2, где агенту необходимо выполнить два точных поворота в узких коридорах. 36

1.4 Примеры тел роботов в бенчмарке Safety Gym: Sweeps, Point, Car и Doggo. 37

1.5 Примеры задач PointGoal1 слева и CarGoal1 справа из бенчмарка Safety Gym. Синие круги обозначают опасные зоны, в которых агент получает штраф $+1$ при нахождении внутри них. Зелёный круг показывает целевую область, а синий прямоугольник обозначает перемещаемый объект среды, с которым агент может взаимодействовать без штрафа. 38

2.1 Схема неявной модели мира SPOWL. Состояние кодируется в латентное пространство (h), модель динамики (f) предсказывает следующее латентное состояние; предсказательные головы оценивают вознаграждение ($\hat{R}$), накопленное вознаграждение ($\hat{Q}_j$), мгновенный штраф ($\hat{C}_j$) и будущие накопленные штрафы ($\hat{Q}^c_j$). 43

2.2 Схема безопасного планирования в SPOWL. Планировщик оценивает кандидатные траектории по ожидаемому вознаграждению (J_M) и штрафов (J^c_M), после чего выбирает элитные траектории с учётом порогов (d_R) и (d_c). 46

2.3 Сравнение локальной и глобальной оценок штрафов траектории на средах PointGoal1 и PointGoal2. Сплошными линиями показана глобальная оценка с фиксированными порогами $d^c \in \{1, 3, 5, 10, 25\}$, пунктирными линиями — локальная оценка с порогами $d^c \in \{0{,}01, 0{,}1, 1\}$. Чёрной линией обозначена полная конфигурация SPOWL с адаптивным порогом d^c. Кривые усреднены по трём случайным инициализациям. 52

2.4 Сравнение способов агрегации ансамбля функций будущих накопленных штрафов. 54

2.5 Абляционное исследование размера ансамбля и подвыборки функций будущих накопленных штрафов. 55

3.1 Безопасное исследование с использованием подцелей. **Слева**: одноуровневая безопасная стратегия может не находить траекторию к удалённой цели. **Справа**: промежуточные подцели направляют исследование и упрощают достижение цели. 58

3.2 Схема метода SG-Safe. Метод включает сбор опыта безопасной стратегией с сохранением траекторий в HER и последующее улучшение безопасной стратегии с использованием промежуточных подцелей. 59

3.3 Обучение SAC, SAC-LAG, SG-NoSafe и SG-Safe в среде Safety Gym Point. Показаны доля успешных эпизодов (SR), MTSC ($C(\pi)$), частота столкновений (CR) и число взаимодействий со средой. Результаты усреднены по трём запускам. 66
3.4 Сравнение SG-Safe и Lyapunov RRT в Safety Gym Point при разном числе препятствий. **Слева** показана доля успешных эпизодов, **справа** — частота столкновений. Результаты усреднены по трём запускам. . . 68
3.5 Примеры траекторий SG-Safe и L-RRT в задачах POLAMP. 69
3.6 Влияние числа критиков штрафов ($Q_c^{\pi_\theta}$) на обучение SG-Safe в средах Safety Gym Point и Safety Gym Car. Показаны доля успешных эпизодов (SR), MTSC ($C(\pi)$), итоговая оценка критика штрафов и число взаимодействий со средой. Результаты усреднены по трём запускам. 74
3.7 Исследование гиперпараметров алгоритма SG-Safe: начального значения множителя Лагранжа λ_0, бюджета штрафов d и коэффициента α в среде Safety Gym Point. SR — доля успешных эпизодов, MTSC — Mean Total Safety Cost, средний накопленный штраф безопасности за эпизод ($C(\pi)$). Эксперименты проводились по трём случайным запускам. 75

4.1 Схема метода ITES. Верхний уровень выбирает промежуточные подцели с учётом штрафов, а нижний уровень проверяет безопасность движения к ним с помощью модели мира. 79
4.2 Схема обучения низкоуровневой и верхнеуровневой стратегий. **Слева**: модель штрафов C_M и модель мира M отвечают за обеспечение безопасности при обновлении низкоуровневой стратегии, тогда как функция $Q^l_{\theta_{ql}}$ используется для оптимизации награды. **Справа**: модель штрафов C_M используется для учёта безопасности при обновлении верхнеуровневой стратегии, а функция $Q^h_{\theta_{qh}}$ используется для оптимизации награды. 81

4.3 **Сравнение с базовыми методами на бенчмарках SafeAntMaze и SafePusher**. Сравнение предложенного метода ITES с безопасным иерархическим методом HRAC-LAG и небезопасным методом HRAC. **Первая строка**: среда SafeAntMazeCshape. **Вторая строка**: среда SafeAntMazeWshape. **Третья строка**: среда SafePusher. Каждый запуск проводился по 5 случайным инициализациям. Заштрихованная область соответствует стандартному отклонению. . . 89
4.4 **Сравнение с базовыми методами на Safety Gym**. **Первая строка**: PointGoal1. **Вторая строка**: CarGoal1. Результаты усреднены по 5 случайным запускам. 90
4.5 **Первая строка**: анализ безопасности на нижнем и верхнем уровнях. На рисунке показаны разные варианты ITES: ITES w/o LLS — ITES без безопасности на нижнем уровне, где безопасность реализуется только на верхнем уровне; ITES w/o HLS — ITES без безопасности на верхнем уровне, где безопасность реализуется только на нижнем уровне, на SafeAntMazeCshape. **Вторая строка**: сравнение ITES без верхнеуровневой стратегии и полного ITES на PointGoal1. **Третья строка**: сравнение ITES и ITES без верхнеуровневого критика штрафов Q_c^h на PointGoal1. Графики получены по 5 случайным запускам. 93

5.1 **Caged CrafText benchmark.** 96
5.2 **Сравнение базовых методов на основном наборе задач**. R — эпизодическое вознаграждение, C — эпизодический штраф. 104
5.3 **Сравнение базовых методов на бюджетных ограничениях**. R — эпизодическое вознаграждение, C — эпизодический штраф. 104
5.4 **Сравнение базовых методов на наборе Caged**. R — эпизодическое вознаграждение, C — эпизодический штраф. 104
5.5 **Слева**: сравнение базовых методов на отношенческом наборе задач. **Справа**: сравнение базовых методов на последовательном наборе задач. R — эпизодическое вознаграждение, C — эпизодический штраф. 105
5.6 **Сравнение базовых методов на математическом наборе задач**. R — эпизодическое вознаграждение, C — эпизодический штраф. 106

5.7 **Слева**: достижение «Eat Cow» при ограничении «20 budget, -10 for killing  ». **Справа**: достижение «Wake Up» при ограничении «Maintain $\geqslant 5$». 106

5.8 **Слева**: достижение «Wake Up» при ограничении «Don’t sleep nearby  ». **Справа**: достижение «Defeat Zombie» при ограничении «Don’t attack  w/o  ». 107

Список таблиц

1 Сравнение методов безопасного обучения с подкреплением. EC — не требуется явный вид функции штрафов; DC — не требуется дифференцируемость функции штрафов; RC — не требуется фильтрация действий на базе безопасности; NS — не требуются заранее заданные навыки; LH — способность решать задачи с большим горизонтом. 29

2 Сравнение SPOWL с базовыми методами на задачах Safety Gymnasium. TD-MPC2 не учитывает ограничения безопасности. Обозначения PPOLag(2), PPOLag(25), CPO(25), CVPO(25) указывают порог допустимого накопленного штрафа за эпизод. Метрика R обозначает среднее вознаграждение за эпизод, C — средний штраф за эпизод, ρ — средний штраф за шаг обучения. Все значения приведены после $5 \cdot 10^6$ шагов взаимодействия со средой. 50

3 Результаты базовых методов безопасного обучения с подкреплением на POLAMP Level 2. SR — доля успешных эпизодов, CR — частота столкновений, MTSC — средний накопленный штраф за эпизод. Результаты усреднены по 5 случайным запускам. 57

4 Результаты на Safety Gym Point и Car. Значения — среднее по трём случайным запускам. SR — доля успешных эпизодов, CR — частота столкновений, MTSC — Mean Total Safety Cost, средний накопленный штраф безопасности за эпизод ($C(\pi)$); меньше — лучше для CR и MTSC. Жирным выделены лучшие значения в каждой среде; красным — методы с полной наблюдаемостью. 70

5 Результаты на Safety Gym Doggo и Sweeps. Обозначения метрик — см. табл. 4. 71

6 Усреднённые результаты на Safety Gym (Avg.) по средам Point, Car, Doggo и Sweeps. Обозначения метрик — см. табл. 4. 71

7 Результаты на POLAMP Level 1 с указанием неопределённости. Каждая метрика — среднее ± стандартное отклонение; ниже указан 95%-ный бутстрэп-доверительный интервал (CI95). SR — доля успешных эпизодов, CR — частота столкновений, MTSC — Mean Total Safety Cost, средний накопленный штраф безопасности за эпизод. Красным выделены методы с привилегированной информацией и/или явными моделями. 72

8 Результаты на POLAMP Level 2 с указанием неопределённости. Обозначения метрик — см. табл. 7. 72

9 Усреднённые результаты на POLAMP (Avg.) по Level 1 и Level 2 с указанием неопределённости. Обозначения метрик — см. табл. 7. . . . 73

10 Результаты экспериментов на средах POLAMP метода SG-Safe и классическими планировщиками. TTR — время достижения цели в шагах среды, PT — время планирования в секундах, ET — время исполнения в секундах. Базовые методы, выделенные красным, используют полную информацию о состоянии, включая точные положения препятствий и геометрию робота. 73

11 **Итоговые результаты на SafeAntMaze и SafePusher.** SAM-C — SafeAntMaze C-shape, SAM-W — SafeAntMaze W-shape, SR — доля успешных эпизодов. Методы, удовлетворяющие условию безопасности (Final Cost $\leqslant d$), выделены **зелёным**, а методы, нарушающие ограничение, выделены **красным**. Результаты усреднены по 5 случайным запускам. 86

12 **Итоговые результаты на бенчмарке Safety Gym.** PG1 — PointGoal1, CG1 — CarGoal1, PGs — PointGoal1 sparse. Для каждой среды используется ограничение штрафов $d = 40$. Результаты усреднены по 5 случайным запускам. 91

13 Таксономия задач Caged CrafText и способностей агента, которые они проверяют. Иконки обозначают объекты и ресурсы, связанные с ограничениями: еду, воду, энергию, здоровье, деревянный меч, дерево, корову, зомби и скелета. Обозначения способностей: M — память, DE — глубокое исследование среды, SE — безопасное исследование, R — рассуждение, LU — понимание языка. 97

14 Сравнение базовых алгоритмов и LLM-агента на бенчмарке Caged CrafText. Лучшие результаты в каждом столбце выделены жирным. Результаты усреднены по 5 случайным запускам. 102