На правах рукописи

Горбов Григорий Владиславович

Методы и алгоритмы безопасного обучения с подкреплением в робототехнических задачах

Специальность: 1.2.1. Искусственный интеллект и машинное обучение

АВТОРЕФЕРАТ

диссертации на соискание ученой степени кандидата технических наук

Долгопрудный – 2026

Работа выполнена в федеральном государственном автономном образовательном учреждении высшего образования «Московский физико-технический институт (национальный исследовательский университет)»

Научный руководитель: **Панов Александр Игоревич – доктор физико-математических наук, профессор РАН**

Ведущая организация: Федеральное государственное бюджетное образовательное учреждение высшего образования «МИРЭА – Российский технологический университет» (РТУ МИРЭА)

Защита состоится **12 ноября 2026 в 15 часов 30 минут** на заседании диссертационного совета **ФПМИ.1.2.1.028**, созданного на базе федерального государственного автономного образовательного учреждения высшего образования «Московский физико-технический институт (национальный исследовательский университет)» (МФТИ, Физтех)

по адресу: 141701, Московская область, г. Долгопрудный, Институтский переулок, д. 9

С диссертацией можно ознакомиться в библиотеке МФТИ, Физтех и на сайте организации https://mipt.ru

Автореферат разослан «____» _____ 2026 г.

Ученый секретарь
диссертационного совета **Войтиков Константин Юрьевич**

Общая характеристика работы

Актуальность темы.

Искусственный интеллект (ИИ) всё шире применяется в робототехнических задачах, где роботу необходимо принимать решения в процессе взаимодействия со средой. Обычно обучение таких систем проводится на заранее собранных данных или в симуляторах. Однако при переносе обученной стратегии (policy) в реальные условия робот может столкнуться с ситуациями, которые не были учтены заранее, либо с проблемой переноса из симуляции в реальность (sim-to-real). Решением обеих проблем является дообучение робота непосредственно в реальных условиях.

Методы обучения с подкреплением (Reinforcement Learning, RL) являются одним из перспективных подходов к такому дообучению. В этих методах агент (робот) обучается методом проб и ошибок: он получает вознаграждение за действия, которые приближают его к желаемому поведению. Важной частью обучения является исследование среды, в ходе которого агенту необходимо обнаружить оптимальную последовательность действий, а затем использовать её для решения поставленной задачи. Однако в реальных условиях исследование не может быть произвольным: действия робота могут нанести вред людям, окружающей среде или самой робототехнической системе. Поэтому агент должен не только исследовать среду в поиске полезных действий, но и делать это безопасно. Эту задачу рассматривает область безопасного обучения с подкреплением (Safe Reinforcement Learning, Safe RL).

В безопасном обучении с подкреплением, помимо вознаграждения, вводится штраф, который численно описывает нарушения ограничений безопасности. В результате агент должен решать двойственную задачу: достигать цели и одновременно соблюдать ограничения. Например, робот должен не только прийти в заданную точку, но и не сталкиваться с препятствиями, не превышать скорость или снижать её рядом с людьми.

Существующие подходы решают эту проблему по-разному. Методы на основе функции лагранжиана применимы к широкому классу сред, но обычно не обеспечивают строгих гарантий безопасности. Методы на основе барьерных функций и других механизмов фильтрации действий могут давать более строгий контроль поведения, однако часто требуют знания модели объекта управления, явного вида функции штрафов и её дифференцируемости. Эти требования ограничивают их применение в сложных робототехнических задачах, где полная информация о среде и точная модель динамики часто недоступны.

Одним из способов уменьшить число небезопасных взаимодействий является использование моделей мира. В таких подходах, помимо стратегии агента, обучается модель, предсказывающая будущие состояния среды при выполнении заданных действий, что позволяет генерировать дополнительный синтетический

опыт, а также осуществлять планирование в рамках модели мира. Однако безопасное исследование в таких методах зависит от того, насколько корректно модель мира оценивает безопасность состояний.

Дополнительные трудности возникают в задачах с большим горизонтом, которые характеризуются разреженным вознаграждением, высокой размерностью пространства состояний и действий, а также большим количеством шагов. Соответственно, агенту необходимо выполнять длинную последовательность действий, чтобы получить полезный сигнал для обучения. Одним из способов справиться с этой проблемой является иерархическое обучение с подкреплением. В таких методах верхнеуровневая стратегия выбирает промежуточные подцели или навыки, а низкоуровневая стратегия отвечает за их достижение. Это позволяет разбить исходную задачу на более короткие подзадачи и направить исследование агента к достижению конечной цели.

Объединение моделей мира и иерархического обучения с подкреплением позволяет использовать оба преимущества одновременно: декомпозицию поведения на промежуточные подцели и предварительную оценку риска их достижения. Такой подход особенно важен в навигационных и робототехнических задачах, где одноуровневые безопасные стратегии часто становятся чрезмерно консервативными или не достигают цели.

При переходе от симуляционных задач к взаимодействию с человеком возникает ещё одна проблема: цели и правила поведения часто задаются не в виде явной функции штрафа, а на естественном языке. В этом случае агенту необходимо связать текстовое ограничение с объектами, состояниями среды и допустимыми последовательностями действий. Поэтому методы, ориентированные только на заранее заданные численные штрафы, не покрывают весь класс задач, возникающих при использовании автономных агентов в человеко-ориентированных средах. Для проверки таких методов требуются среды, где языковая инструкция влияет не только на цель, но и на допустимость поведения агента.

Таким образом, актуальность данной работы определяется тремя связанными проблемами. Во-первых, в задачах безопасного обучения важно заранее оценивать долгосрочные последствия действий: короткий горизонт планирования может не выявлять будущие нарушения безопасности, а ошибки в оценке нарушений приводят либо к небезопасным траекториям, либо к чрезмерно осторожному поведению. Во-вторых, безопасная стратегия должна сохранять способность к исследованию среды в постановках с большим горизонтом, а не сводить поведение к избеганию любых потенциально рискованных действий. В-третьих, для более реалистичных постановок необходимо учитывать ограничения, заданные не только численно, но и на естественном языке.

Цель работы.

Целью данной работы является исследование и разработка методов безопасного обучения с подкреплением, которые используют модели мира и иерархическую структуру поведения для повышения эффективности исследования среды при соблюдении ограничений безопасности в робототехнических задачах.

Задачи исследования.

Для достижения поставленной цели необходимо было решить следующие **задачи**:

1. Провести анализ существующих методов безопасного обучения с подкреплением и сред, используемых для их экспериментальной оценки.
2. Разработать подход для учёта долгосрочного риска в методах безопасного обучения с подкреплением на основе модели мира.
3. Разработать метод иерархического обучения с подкреплением, направленный на уменьшение консервативности безопасной стратегии и повышение её способности к исследованию среды.
4. Разработать метод генерации безопасных подцелей с использованием модели мира для обеспечения безопасности как у верхнеуровневой стратегии, так и у низкоуровневой для решения робототехнических задач с большим горизонтом.
5. Разработать бенчмарк для обучения методов безопасного обучения с подкреплением и для оценки их способностей к пониманию задачи и ограничений, заданных при помощи естественного языка.

Научная новизна.

1. В рамках метода SPOWL (Safe Planning and Policy Optimization via World Model Learning, безопасное планирование и оптимизация стратегии с использованием модели мира) предложена функция оценки будущих накопленных штрафов в рамках модели мира для улучшения скрытых представлений, а также для более точной оценки безопасности траекторий при планировании. Эксперименты на средах Safety Gym показали лучшую производительность и безопасность по сравнению с предыдущими методами безопасного обучения с подкреплением.
2. Разработан метод SG-Safe (Enhancing Safe Exploration Through Subgoal Guidance) для улучшения исследовательских способностей безопасных стратегий за счёт направления исследования через промежуточные подцели. На этапе исполнения используется только безопасная стратегия. Метод показывает лучшее качество в среде POLAMP в сравнении с методами безопасного обучения с подкреплением и методами на основе классического планирования.
3. Разработан метод ITES (Imagine to Ensure Safety in Hierarchical Reinforcement Learning) для генерации безопасных подцелей в задачах с большим горизонтом, использующий модель мира для обеспечения безопасного достижения этих подцелей. Метод достигает лучшего качества в задачах навигации и манипуляции с большим горизонтом в

сравнении с методами на основе моделей мира в безопасном обучении с подкреплением.

4. Разработан бенчмарк Caged CrafText (Caged CrafText: Language-Grounded Safety Constraints for Multimodal Reinforcement Learning in CrafText) для оценки способностей к пониманию языка, связывания языка с объектами из среды, памяти, безопасного исследования. Предложенный бенчмарк позволяет как обучать, так и оценивать методы безопасного обучения с подкреплением в сложной динамической среде.

Теоретическая значимость. В работе показано, что в задачах с большим горизонтом у нынешних методов безопасного обучения с подкреплением ухудшается способность к исследованию, и что такая проблема решается с помощью иерархического обучения с подкреплением в методах SG-Safe и ITES.

Показано, что безопасное исследование в методах обучения с подкреплением на основе модели мира зависит от корректной оценки моделью мира нарушений на сгенерированных траекториях. Недооценка будущих штрафов приводит к небезопасному исследованию, а переоценка — к чрезмерно консервативному поведению агента.

Caged CrafText позволяет обучать и оценивать методы безопасного обучения с подкреплением в задачах, где цель и ограничения заданы на естественном языке. Разделение задач на бюджетные, последовательные, математические и отношенческие ограничения позволяет оценивать разные аспекты поведения агента: понимание инструкции, связывание текста с объектами и состояниями среды, память, долгосрочное планирование и безопасное исследование.

Практическая значимость заключается в возможности применения разработанных методов для робототехнических платформ, где требуется заданный уровень безопасности и производительности, особенно для задач, требующих большого количества действий от робота, в том числе для адаптивного обучения робота в реальных условиях.

Компоненты метода SPOWL, отвечающие за оценку будущих накопленных штрафов действий, могут быть применены в робототехнических задачах безопасного исследования, где агент должен заранее оценивать риск кандидатных действий до их выполнения в реальной среде. Это позволяет уменьшить число небезопасных действий при обучении и одновременно избежать чрезмерно консервативного поведения агента.

Разработанные методы SG-Safe и ITES, направленные на улучшение исследовательских способностей безопасной стратегии при помощи иерархического обучения, могут быть применены для адаптации мобильных роботов к новым

условиям эксплуатации, например в задачах автономной инспекции промышленных объектов, патрулирования охраняемых территорий, обследования аварийных зон, навигации в шахтах и других труднодоступных пространствах, где требуется исследовать среду при ограничении числа небезопасных действий.

Методология и методы исследования. Для оптимизации стратегий использовались методы актор-критик, включая метод оптимизации ближайшей стратегии (Proximal Policy Optimization, PPO) и метод мягкого актор-критика (Soft Actor-Critic, SAC), а также методы на основе функции лагранжиана для учёта ограничений безопасности. Для формализации задач применялись марковские процессы принятия решений с ограничениями (CMDP). В качестве одного из базовых методов сравнения рассматривался SafeDreamer, основанный на архитектуре DreamerV3 и использующий модель мира для планирования с учётом ограничений безопасности. Для оценки предложенных методов проводились численные эксперименты в симуляционных средах безопасного обучения с подкреплением. Основными метриками выступали эпизодическое вознаграждение (Reward), эпизодические штрафы (Cost), успешность выполнения задачи (Success Rate). Программная реализация выполнялась на языке Python 3 с использованием JAX и PyTorch. В качестве основного программного интерфейса для симуляционных сред использовались Gymnasium и Safety Gymnasium, а также собственные реализации сред для отдельных экспериментов. Эксперименты проводились на графических ускорителях NVIDIA RTX-серии и NVIDIA H100. Логирование результатов экспериментов выполнялось с использованием Comet ML, а визуализация и анализ результатов — с использованием Matplotlib и стандартных инструментов обработки численных данных. Репозитории с открытым кодом: SPOWL[1], SG-Safe[2], ITES[3], CrafText[4], Caged CrafText[5].

Основные положения, выносимые на защиту.

1. Способ построения и агрегации функций оценки будущих накопленных штрафов в модели мира для безопасного исследования в рамках модели SPOWL. Показано, что устойчивое безопасное исследование в обучении с подкреплением на основе модели мира требует оценки не только мгновенных штрафов, но и оценки будущих накопленных штрафов.
2. Метод SG-Safe для безопасного иерархического обучения с подкреплением, использующий генерацию промежуточных подцелей для улучшения исследовательских способностей безопасной стратегии. Метод позволяет повысить успешность решения навигационных задач с большим горизонтом при сохранении контролируемого уровня нарушений безопасности.

[1] https://github.com/AIRI-Institute/SPOWL
[2] https://github.com/Gricha1/SPEIS
[3] https://github.com/Gricha1/ITES_alg
[4] https://github.com/AIRI-Institute/CrafText
[5] https://github.com/Gricha1/CAGED-CrafText

3. Метод ITES для безопасного исследования с использованием иерархической структуры и модели мира, в котором верхнеуровневая стратегия генерирует безопасные подцели, а низкоуровневая стратегия использует модель мира и модель штрафов для безопасного достижения этих подцелей. Метод позволяет контролировать безопасность как на уровне выбора подцелей, так и на уровне исполнения действий.
4. Бенчмарк Caged CrafText для оценки и обучения методов безопасного обучения с подкреплением с естественно-языковыми целями и ограничениями, позволяющий анализировать способность агентов понимать задачи и ограничения, заданные на естественном языке, и соблюдать их в сложной динамической среде.

Достоверность результатов.

Достоверность результатов обеспечивается многократным проведением экспериментов, использованием общепринятых симуляционных сред и сравнением с современными базовыми методами. Достоверность подтверждается также абляционными исследованиями, апробацией результатов на научных семинарах и конференциях, а также публикациями в рецензируемых научных изданиях.

Апробация работы. Основные результаты диссертационной работы докладывались и обсуждались на:

- семинарах Центра когнитивного моделирования МФТИ (2023, 2024, 2025);
- международной конференции European Conference on Artificial Intelligence, ECAI 2025;
- конференции Fall into ML 2025;
- междисциплинарной конференции по искусственному интеллекту «ИИ-АЗАМАН 2025».

Полученные результаты и знания использовались в преподавании курсов по искусственному интеллекту:

- курс «Продвинутые методы машинного обучения с подкреплением» (МФТИ, 2026): разработка и проведение практических занятий;
- курс «Обучение с подкреплением» (Центр «ПУСК», 2025): разработка и проведение практических и лекционных занятий;
- курс «Обучение с подкреплением (углубленный курс)» (ФКН ВШЭ, 2026): проведение лекции и семинара по безопасному обучению с подкреплением.

Публикации. Основные результаты по теме диссертации изложены в 5 публикациях: 3 — в журналах категории К1 собственного перечня журналов МФТИ, 2 — в сборниках трудов конференций уровня A и A*.

Личный вклад. В работе по SPOWL автор предложил функцию оценки будущих накопленных штрафов в рамках модели мира для улучшения скрытых

представлений и более точной оценки безопасности траекторий при планировании, а также способ агрегации её в ансамбле. В частности, автор провёл экспериментальный анализ способов агрегации ансамбля функций оценки будущих накопленных штрафов и влияния размера ансамбля на баланс между эффективностью и безопасностью агента. Показано, что корректная ансамблевая оценка будущих накопленных штрафов является необходимым условием безопасного исследования: недооценка риска приводит к нарушениям ограничений, а переоценка риска — к консервативному поведению и снижению целевой эффективности.

В работе по SG-Safe автор разработал метод безопасного иерархического обучения с подкреплением, направленный на улучшение исследовательских способностей безопасной стратегии за счёт генерации промежуточных подцелей, а также провёл экспериментальную проверку метода на навигационных задачах с большим горизонтом.

В работе по ITES автор разработал метод, использующий модель мира и модель штрафов для генерации безопасных подцелей и безопасного достижения этих подцелей низкоуровневой стратегией.

В работе по CrafText Benchmark автор участвовал в разработке задач для оценки способности агента следовать естественно-языковым инструкциям в сложной динамической среде. В частности, были сформированы навигационные и пространственные задачи, связанные с локализацией объектов, выбором направления движения и размещением объектов относительно элементов карты.

В работе разработан и протестирован бенчмарк Caged CrafText для оценки агентов безопасного обучения с подкреплением в задачах с естественно-языковыми целями и ограничениями. Сформированы типы ограничений, наборы задач для обучения и тестирования, а также протокол оценки агентов. Проведено экспериментальное сравнение базовых алгоритмов и проанализированы их ограничения при одновременном выполнении языковой инструкции и соблюдении текстового ограничения безопасности в динамической среде.

Во всех указанных работах автор участвовал в обсуждении экспериментальных результатов, их интерпретации и формулировке выводов.

Содержание диссертации соответствует паспорту научной специальности 1.2.1. Искусственный интеллект и машинное обучение, в частности, пунктам:

- **п. 5** — Методы и технологии поиска, приобретения и использования знаний и закономерностей, в том числе — эмпирических, в системах искусственного интеллекта. Исследования в области совместного применения методов машинного обучения и классического математического моделирования. Методы и средства использования экспертных знаний.
- **п. 6** — Формализация и постановка задач управления и (поддержки) принятия решений на основе систем искусственного интеллекта и машинного обучения. Разработка систем управления с использованием

систем искусственного интеллекта и методов машинного обучения в том числе — управления роботами, автомобилями, БПЛА и т.п.

– **п. 7** — Разработка специализированного математического, алгоритмического и программного обеспечения систем искусственного интеллекта и машинного обучения. Методы и средства взаимодействия систем искусственного интеллекта с другими системами и человеком-оператором.
– **п. 12** — Исследования в области «доверенных» систем класса ИИ, включая проблемы формирования тестовых выборок прецедентов, надёжности, устойчивости, переобучения и т.д.

Объём и структура работы. Диссертация состоит из введения, пяти глав и заключения. Полный объём диссертации составляет 132 страницы.

Содержание работы

Во **введении** диссертации раскрывается актуальность работы на основе краткого обзора научной литературы в области безопасного обучения с подкреплением. Обозначаются основные проблемы и возможные пути их решения. Формулируется цель и ставятся задачи работы. Излагается научная новизна, а также практическая и теоретическая значимость представляемой работы. Представляется методология, используемая в рамках данной диссертации. Перечисляются основные положения, выносимые на защиту. Приводится информация об апробации, публикациях и личном вкладе автора в каждом из опубликованных исследований. Глава завершается кратким описанием структуры диссертации.

В **первой главе** рассматриваются основные методы безопасного обучения с подкреплением и среды, используемые для их оценки. В качестве базовой формальной модели вводится марковский процесс принятия решений с ограничениями (Constrained Markov Decision Process, CMDP). В этой постановке агент максимизирует ожидаемое вознаграждение, но при этом должен удерживать накопленные штрафы ниже заданного порога. Такая модель позволяет описывать задачи, в которых агенту необходимо не только достигать цели, но и соблюдать ограничения: избегать столкновений, опасных областей или превышения допустимого уровня риска.

Далее анализируются методы оптимизации стратегии с ограничениями. К ним относятся CPO, методы на основе функции лагранжиана и их модификации, где ограничение на штраф включается непосредственно в задачу обучения стратегии. Эти методы удобны тем, что применимы к широкому классу сред и не требуют заранее известной модели динамики. Вместе с тем безопасность в них обычно контролируется через ожидаемые накопленные штрафы. Поэтому такие методы не исключают небезопасные действия напрямую и на практике

могут приводить как к превышению ограничений, так и к чрезмерно осторожному поведению агента.

Отдельно рассматриваются методы, которые ограничивают небезопасные действия уже на этапе управления агентом: слои безопасности, экранирование, методы на основе барьерных функций и подходы на основе функций Ляпунова. Их преимущество состоит в более прямом контроле поведения: действие стратегии может быть проверено, скорректировано или заменено до выполнения в среде. Однако такая проверка часто требует дополнительных предположений — полной наблюдаемости, достаточно точной модели динамики, дифференцируемой функции штрафов, формального описания ограничений или решения вспомогательной задачи оптимизации на каждом шаге управления. Это ограничивает применение таких подходов в сложных и частично наблюдаемых средах.

Затем обсуждаются методы безопасного обучения с подкреплением на основе моделей мира. В этих подходах модель среды используется для построения воображаемых траекторий, предварительной оценки последствий действий и уменьшения числа небезопасных взаимодействий с реальной средой. Основная трудность состоит в том, что безопасное поведение агента сильно зависит от качества оценки будущих накопленных штрафов. Если модель недооценивает риск, агент может выбирать небезопасные траектории; если переоценивает его, поведение становится чрезмерно консервативным. Поэтому для безопасного обучения на основе модели мира важна не только оценка мгновенного штрафа, но и оценка будущих накопленных штрафов.

Для задач с большим горизонтом в главе рассматривается иерархическое обучение с подкреплением. Использование подцелей или навыков позволяет разбить исходную задачу на более короткие подзадачи и тем самым облегчить исследование среды. Однако в безопасной постановке одной достижимости подцели недостаточно: путь к ней может проходить через опасную область или приводить к накоплению большого штрафа. Поэтому в безопасном иерархическом обучении необходимо учитывать не только достижимость подцелей, но и штрафы за их достижение. В этой связи сравниваются существующие методы безопасного иерархического обучения, включая SafetyLayer + HiRO, LyapunovRRT и IAHRL, а также обсуждаются их ограничения: требования к информации о среде, ручное задание навыков или необходимость дополнительного контроля действий на этапе исполнения.

Отдельная проблема возникает при переходе от фиксированных численных функций штрафов к ограничениям, заданным на естественном языке. В реальных сценариях человек задаёт ограничения и задачи при помощи естественного языка. Ограничение может зависеть от объектов сцены, порядка действий, контекста или отношений между объектами. Поэтому для оценки безопасных агентов требуются среды, в которых проверяется не только способность достигать цели, но и способность связывать текстовое ограничение с динамикой среды. Сначала анализируются бенчмарки безопасного обучения с

подкреплением: дискретные среды, среды непрерывного управления, робототехнические симуляторы, задачи автономного вождения и визуальные трёхмерные среды. Несмотря на различия, большинство таких бенчмарков задаёт безопасность через фиксированную численную функцию штрафов. Это удобно для классической постановки безопасного обучения с подкреплением, но плохо отражает сценарии, где пользователь задаёт правила поведения в текстовой форме. Затем рассматриваются бенчмарки и подходы с естественно-языковыми ограничениями, включая HAZARDWORLD. Отмечается, что остаётся открытой задача оценки агентов, которые должны одновременно понимать цель, учитывать текстовое ограничение и обучаться поведению, разделяющему вознаграждение и безопасность.

Во **второй главе** рассматривается использование модели мира для оценки будущих накопленных штрафов. Основное внимание уделяется компонентам метода SPOWL, связанным с предсказанием штрафов, оценкой долгосрочного риска, а также сравнением локальной и глобальной оценок безопасности траекторий. В безопасном обучении с подкреплением на основе модели мира агент может оценивать последствия кандидатных действий до их выполнения в среде. Поэтому качество безопасного исследования определяется не только тем, насколько точно модель предсказывает будущие состояния и вознаграждение, но и тем, насколько устойчиво она оценивает возможные нарушения безопасности.

В методе SPOWL модель мира используется при планировании кандидатных траекторий. Для каждой такой траектории оценивается не только ожидаемое вознаграждение, но и штрафы безопасности. При этом существенную роль играет функция будущих накопленных штрафов. Короткий горизонт планирования может не захватывать отложенный риск: траектория может выглядеть безопасной на ближайших шагах, но приводить к нарушению ограничений позже. Поэтому в SPOWL к сумме предсказанных мгновенных штрафов добавляется терминальная оценка будущих накопленных штрафов.

Далее проводится сравнение полной конфигурации SPOWL с базовыми методами. Для компактного представления в (см. Таблица 1) приведены результаты только для SafeDreamer и PPO-LAG. SafeDreamer выбран как базовый метод на основе модели мира, а PPO-LAG — как представитель методов на основе функции лагранжиана без модели мира. В таблицу включены только две метрики: Reward и Cost.

Из (см. Таблица 1) видно, что SPOWL сохраняет более высокий уровень целевой эффективности при небольшом уровне штрафов. SafeDreamer во многих задачах удерживает штрафы на низком уровне, но часто делает это за счёт почти нулевого вознаграждения. PPO-LAG, напротив, в отдельных задачах получает ненулевое вознаграждение, но при этом накапливает существенно большие штрафы. Это показывает, что учёт будущих накопленных штрафов в модели мира позволяет получить более устойчивый баланс между достижением цели и безопасностью.

Таблица 1 — Сравнение SPOWL с базовыми методами на задачах Safety Gymnasium. Reward — эпизодическое вознаграждение, Cost — накопленные штрафы безопасности за эпизод.

	SPOWL		**SafeDreamer**		**PPO-LAG**	
Задача	Reward↑	Cost↓	Reward↑	Cost↓	Reward↑	Cost↓
PointButton1	10.0	5.4	0.1	0.3	3.7	33.6
CarGoal1	31.3	1.0	6.6	0.0	18.4	30.5
DoggoGoal1	19.0	0.3	1.1	0.0	0.0	21.8
AntGoal1	38.9	2.0	0.2	0.0	5.1	23.6

Следующий эксперимент проверяет влияние локальной и глобальной оценки штрафов траектории. В локальной оценке учитываются только мгновенные штрафы внутри горизонта планирования, а в глобальной к ним добавляется терминальная оценка будущих накопленных штрафов. Результаты показывают, что локальная оценка часто оказывается слишком оптимистичной и требует более жёстких порогов безопасности, тогда как глобальная позволяет учитывать отложенный риск и получать более устойчивый баланс между достижением цели и соблюдением ограничений.

Сравнение локальной и глобальной оценок штрафов приведено на (см. Рисунок 1).

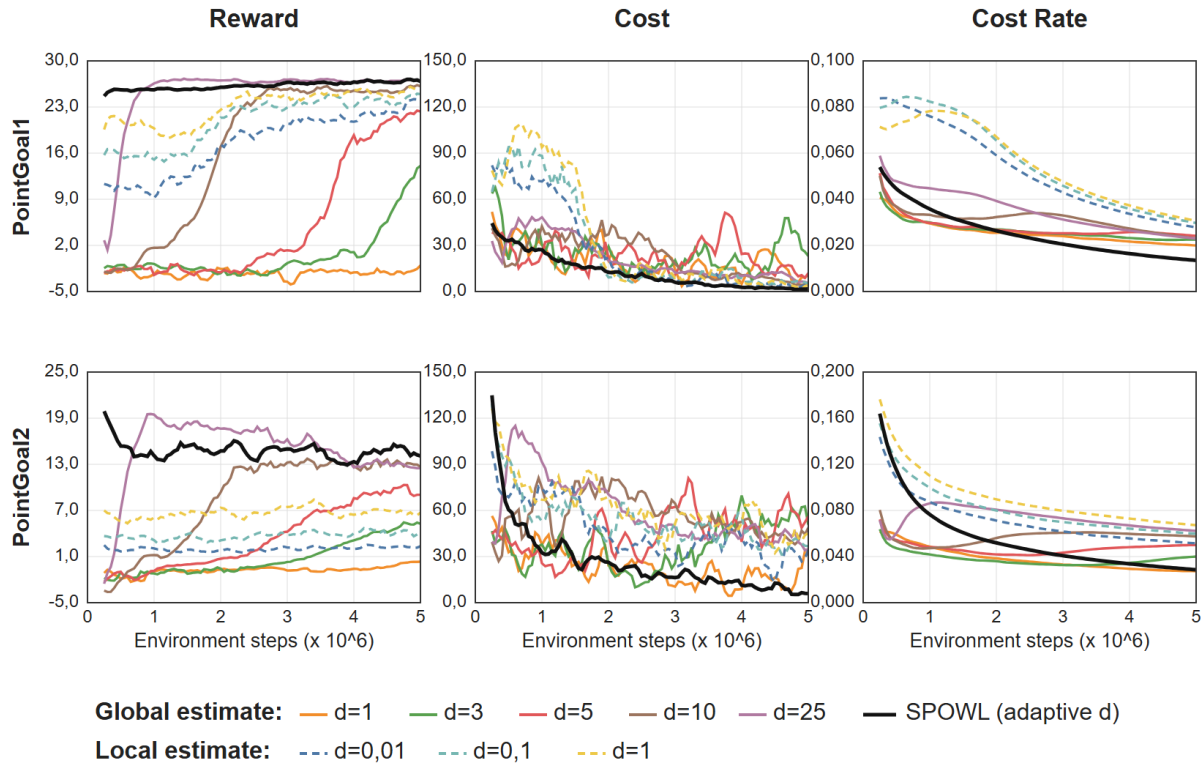


Рисунок 1 — Сравнение локальной и глобальной оценок штрафов траектории.

Таким образом, результаты второй главы показывают, что для безопасного обучения с подкреплением на основе модели мира недостаточно предсказывать только мгновенные штрафы. Корректная оценка будущих накопленных штрафов позволяет безопаснее исследовать среду.

В **третьей главе** представлен метод SG-Safe, предназначенный для улучшения безопасного исследования в задачах с большим горизонтом. Основная проблема, рассматриваемая в главе, связана с тем, что неиерархические безопасные стратегии часто становятся слишком консервативными. Они уменьшают число нарушений безопасности, но вместе с этим хуже исследуют среду и могут не находить траектории к целевому состоянию. В SG-Safe эта проблема решается за счёт промежуточных подцелей, которые используются как дополнительный обучающий сигнал для безопасной стратегии.

Метод состоит из двух связанных компонент: безопасной стратегии и стратегии генерации подцелей. Безопасная стратегия обучается на основе SAC-Lagrangian: она максимизирует ожидаемое вознаграждение и одновременно учитывает штраф за нарушение ограничений безопасности. Стратегия генерации подцелей используется только на этапе обучения. Её задача — разбить исходную задачу на более короткие переходы и направить безопасную стратегию к более информативным областям пространства состояний. При этом подцели не являются жёстким планом исполнения; они задают дополнительное направление для обучения, но не требуют от агента точного следования каждой подцели.

Для работы с разреженным вознаграждением в SG-Safe используется буфер с переиспользованием опыта и подстановкой достигнутых целей (Hindsight Experience Replay, HER). Опыт собирается безопасной стратегией и сохраняется в HER, после чего часть целей в переходах заменяется на фактически достигнутые состояния. Благодаря этому обучающий сигнал можно получать не только из успешных, но и из неуспешных эпизодов. Затем данные из буфера используются для обновления критика вознаграждения, критика штрафов, безопасной стратегии и стратегии генерации подцелей. После завершения обучения стратегия подцелей больше не используется: на этапе исполнения действие выбирается только итоговой безопасной стратегией.

Экспериментальная проверка SG-Safe проводилась в средах POLAMP и Safety Gym. На POLAMP преимущество иерархического обучения проявляется сильнее: среда содержит длинные маршруты, узкие коридоры и частичную наблюдаемость, поэтому безопасным стратегиям сложнее найти путь к цели. В таких условиях штрафы ограничивают исследование, но сами по себе не подсказывают агенту последовательность промежуточных состояний. Подцели в SG-Safe дают дополнительный ориентир и помогают безопасной стратегии продолжать поиск траектории к цели.

В среднем по двум уровням POLAMP метод SG-Safe достигает доли успешных эпизодов 0.897 при частоте столкновений 0.028. SAC-LAG достигает $\mathrm{SR} = 0.364$, SAC — $\mathrm{SR} = 0.305$, а L-RRT — $\mathrm{SR} = 0.338$ при существенно большей

частоте столкновений. Наиболее показателен результат на Level 2, где требуется проходить длинные маршруты с препятствиями: SG-Safe достигает SR $= 0.875$ при CR $= 0.031$, тогда как SAC-LAG и SAC фактически не решают задачу, а L-RRT достигает только SR $= 0.125$ при CR $= 0.664$. Усреднённые результаты приведены в (см. Таблица 2).

Таблица 2 — Сравнение SG-Safe с базовыми методами на POLAMP. SR — доля успешных эпизодов, CR — частота столкновений, MTSC — средний накопленный штраф безопасности за эпизод. Значения усреднены по Level 1 и Level 2.

Метод	SR↑	CR↓	MTSC↓
SG-Safe	0.897	0.028	3.335
SAC-LAG	0.364	0.017	4.042
SAC	0.305	0.017	8.153
SAC-NCMP	0.214	0.787	1.119
SAC-RCBF	0.176	0.145	6.541
ADVICE	0.000	0.021	0.021
L-RRT	0.338	0.507	10.245

В Safety Gym метод сравнивался с SAC, SAC-Lagrangian, CPO, L-RRT и вариантом SG-NoSafe, где подцели используются без безопасной оптимизации. Результаты показывают, что SG-Safe повышает успешность выполнения задачи по сравнению с безопасными методами и при этом сохраняет низкую частоту столкновений. В среднем по средам Point, Car, Doggo и Sweeps метод достигает доли успешных эпизодов 0.87 при частоте столкновений 0.03. Для сравнения, SAC-LAG достигает доли успешных эпизодов 0.40 при частоте столкновений 0.05, а SAC — 0.39 при частоте столкновений 0.28. Численные результаты приведены в (см. Таблица 3).

Таблица 3 — Результаты на Safety Gym. SR — доля успешных эпизодов, CR — частота столкновений, MTSC — средний накопленный штраф безопасности за эпизод. Значения усреднены по средам Point, Car, Doggo и Sweeps.

Метод	SR↑	CR↓	MTSC↓
SG-Safe	0.87	0.03	13.7
SG-NoSafe	0.85	0.14	29.9
L-RRT	0.97	0.03	26.5
SAC-LAG	0.40	0.05	12.8
SAC	0.39	0.28	23.3
CPO	0.51	0.44	117.1

Полученные результаты показывают, что SG-Safe улучшает безопасное исследование именно в тех условиях, где безопасные стратегии оказываются

слишком осторожными и не находят путь к цели. При этом метод не требует отдельного планировщика во время исполнения. Это отличает SG-Safe от подходов, которые используют полную карту среды, точную модель динамики или дополнительный контроль действий на этапе применения.

Таким образом, результаты третьей главы показывают, что иерархическая структура может использоваться не как внешний планировщик, а как механизм обучения безопасной стратегии. SG-Safe повышает успешность решения задач с большим горизонтом при сохранении низкого уровня столкновений. При этом безопасность подцелей не задаётся отдельным формальным условием, а формируется в процессе обучения через согласование с безопасной стратегией. Поэтому следующий шаг состоит в контроле безопасности непосредственно на уровне выбора подцелей и на уровне исполнения действий, что рассматривается в следующей главе.

В **четвёртой главе** представлен метод ITES (Imagine To Ensure Safety in Hierarchical Reinforcement Learning), развивающий безопасное иерархическое обучение с подкреплением за счёт использования модели мира. В отличие от SG-Safe, где подцели используются прежде всего как дополнительный сигнал для улучшения исследования, ITES вводит явный контроль безопасности на двух уровнях: при выборе промежуточных подцелей и при их достижении низкоуровневой стратегией.

Метод строится на иерархической архитектуре. Верхнеуровневая стратегия выбирает промежуточные подцели, а низкоуровневая стратегия управляет агентом при достижении текущей подцели. В качестве базовой структуры используется HRAC, где пространство подцелей ограничивается состояниями, достижимыми за конечное число шагов. Однако в безопасной постановке одной достижимости недостаточно: подцель может быть достижимой, но путь к ней может проходить через опасные состояния или приводить к накоплению большого штрафа. Поэтому в ITES дополнительно учитываются штрафы как самой подцели, так и траектории её достижения.

На верхнем уровне безопасность подцелей оценивается с помощью модели штрафов и верхнеуровневого критика штрафов. Эти компоненты помогают выбирать такие подцели, которые не только приближают агента к конечной цели, но и не приводят к превышению допустимого уровня накопленного штрафа. На нижнем уровне используется модель мира: для действия, выбранного низкоуровневой стратегией, строится короткая воображаемая траектория, после чего модель штрафов оценивает её безопасность. Такая проверка снижает вероятность небезопасных действий ещё до их выполнения в среде.

Экспериментальная проверка ITES проводилась на задачах с большим горизонтом SafeAntMaze и SafePusher. В этих средах метод сравнивался с безопасными одноуровневыми алгоритмами, включая SafeDreamer, CUP, FOCOPS, TD3-LAG и PPO-LAG, а также с иерархическими базовыми методами HRAC и HRAC-LAG.

Результаты на задачах с большим горизонтом показывают ограничение одноуровневых безопасных методов. Низкие штрафы в этих методах часто связаны не с успешным безопасным решением задачи, а с тем, что агент почти не продвигается к цели. Например, в SafeAntMaze C-shape методы SafeDreamer, CUP и FOCOPS имеют нулевую долю успешных эпизодов. ITES в той же среде достигает SR $= 0.88$ при Cost $= 15.2$. В SafeAntMaze W-shape метод достигает SR $= 0.35$, тогда как большинство одноуровневых методов также не решает задачу. В SafePusher ITES достигает SR $= 0.42$ при Cost $= 12.8$, в то время как SafeDreamer и другие одноуровневые методы практически не находят успешные траектории. Для компактного представления в (см. Таблица 4) приведено сравнение ITES с SafeDreamer и PPO-LAG.

Таблица 4 — Итоговые результаты на задачах с большим горизонтом. SAM-C — SafeAntMaze C-shape, SAM-W — SafeAntMaze W-shape. SR — доля успешных эпизодов, Cost — накопленные штрафы за эпизод.

	ITES		**SafeDreamer**		**PPO-LAG**	
Среда	SR↑	Cost↓	SR↑	Cost↓	SR↑	Cost↓
SAM-C	0.88	15.2	0.00	13.0	0.20	41.2
SAM-W	0.35	183.0	0.00	216.3	0.00	105.0
SafePusher	0.42	12.8	0.00	6.7	0.00	51.25

Отдельно ITES сравнивался с HRAC и HRAC-LAG. Это сравнение позволяет отделить эффект самой иерархической структуры от вклада механизмов безопасности. В SafeAntMaze C-shape иерархические методы достигают сопоставимой успешности, однако ITES снижает штрафы за счёт совместного использования модели штрафов и модели мира. В SafePusher преимущество ITES выражено сильнее: проверка безопасности низкоуровневых действий через модель мира оказывается особенно полезной в задаче с более сложной динамикой.

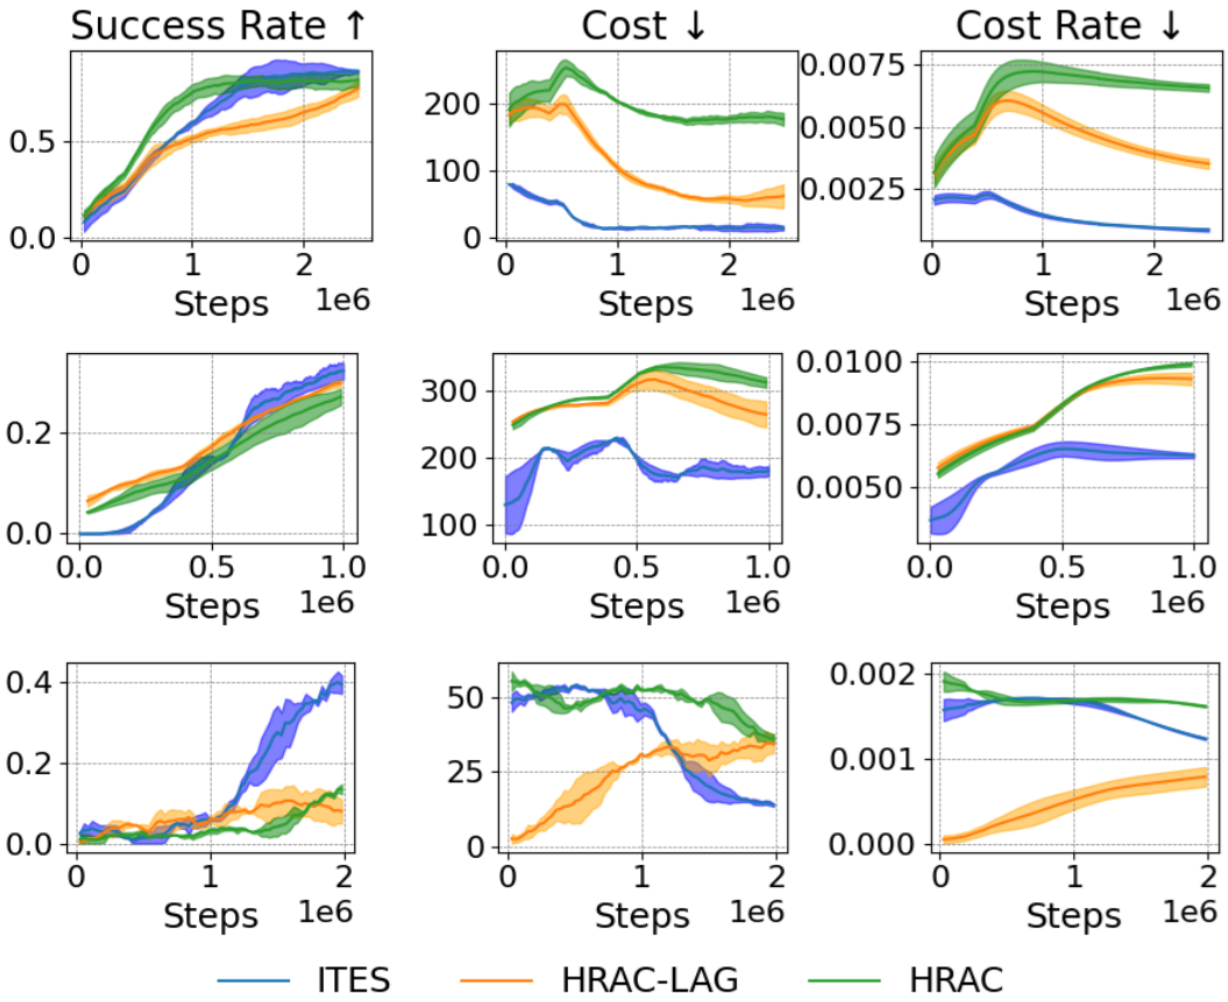


Рисунок 2 — Сравнение ITES с HRAC и HRAC-LAG на задачах SafeAntMaze и SafePusher.

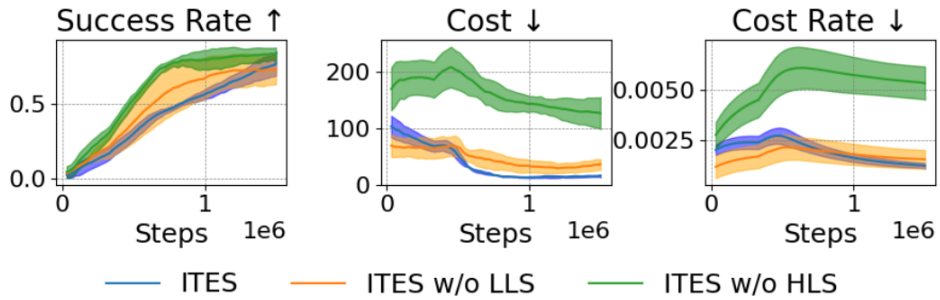


Рисунок 3 — Абляция компонентов безопасности ITES на SafeAntMaze C-shape. Отсутствие безопасности в подцелях приводит к сопоставимой доле успешных эпизодов, но к существенно большим штрафам.

В главе показано, что для задач с большим горизонтом необходим контроль безопасности как при выборе подцелей, так и при их достижении низкоуровневой стратегией.

Таким образом, результаты четвёртой главы показывают, что в задачах с большим горизонтом важно контролировать не только отдельные действия агента, но и промежуточные цели, через которые строится решение. Иерархическая

структура помогает разбить задачу на более короткие подзадачи, модель штрафов направляет выбор подцелей в безопасные области, а модель мира снижает риск небезопасных действий при достижении этих подцелей. В этом смысле ITES является развитием SG-Safe: SG-Safe улучшает исследование через подцели, а ITES дополнительно вводит контроль безопасности как на уровне выбора подцелей, так и на уровне исполнения действий.

Пятая глава рассматривает переход от классической постановки безопасного обучения с подкреплением к задачам с естественно-языковыми целями и ограничениями. Для этого предложен бенчмарк Caged CrafText, расширяющий среду CrafText задачами с текстовыми ограничениями. В такой постановке агент должен не только выполнить целевую инструкцию, но и соблюдать дополнительное правило безопасности, сформулированное в виде отдельной текстовой инструкции.

Бенчмарк включает четыре типа ограничений: бюджетные, последовательные, математические и отношенческие. Бюджетные ограничения требуют поддерживать некоторый ресурс выше заданного уровня. Последовательные ограничения задают зависимость допустимости действия от предыдущих действий агента. Математические ограничения вводят численный бюджет штрафа, который уменьшается при выполнении определённых действий. Отношенческие ограничения требуют учитывать пространственные или причинные связи между объектами среды. За счёт такой структуры Caged CrafText проверяет не только способность агента достигать цели, но и память, безопасное исследование, рассуждение, долгосрочное планирование и понимание естественного языка. Основные типы задач приведены в (см. Таблица 5).

Экспериментальная проверка проводилась на обучаемых агентов с подкреплением и агенте на основе большой языковой модели. В качестве базовых методов использовались PPO, PPO-LAG и PPO-Cost. В обучаемых методах текст цели и текст ограничения кодировались при помощи BERT, после чего передавались стратегии агента. Отдельно рассматривался LLM-агент, использующий языковую модель для выбора действий в режиме zero-shot. Сравнение методов приведено в (см. Таблица 6).

Стандартный PPO получает высокое эпизодическое вознаграждение почти во всех задачах, но делает это без учёта штрафов. Поэтому высокое вознаграждение сопровождается частыми нарушениями ограничений.

PPO-Cost за счёт фиксированного штрафного коэффициента в среднем лучше контролирует штрафы, чем PPO-LAG. Однако это не решает основную проблему: агент находит безопасный режим поведения, но затем не возвращается к активному выполнению целевой инструкции. Эти результаты показывают, что для Caged CrafText недостаточно просто добавить штраф за нарушение ограничения. Агент должен уметь исследовать среду безопасно, но при этом не застревать в первом найденном безопасном поведении. После стабилизации штрафов ему всё равно нужно продолжать движение к основной цели.

Таблица 5 — Таксономия задач Caged CrafText и проверяемых способностей агента. В ограничениях используются пиктограммы: (еда), (вода), (энергия), (здоровье), (деревянный меч), (дерево), (корова), (зомби), (скелет). M — memory, память; DE — deep exploration, глубокое исследование; SE — safe exploration, безопасное исследование; R — reasoning, рассуждение; LU — language understanding, понимание языка.

Сценарий	**Ограничение**	**M**	**DE**	**SE**	**R**	**LU**
Budgetary	Maintain ≥ 5	✓	✓	✓		
	Maintain ≥ 5	✓	✓	✓		
	Maintain ≥ 5			✓		
	Maintain ≥ 5	✓	✓	✓	✓	
Sequential	Don't attack w/o		✓	✓	✓	
	Don't sleep nearby			✓	✓	
	When ≤ 4, avoid			✓	✓	
Mathematical	20 budget, -10 for killing	✓		✓	✓	
	50 budget, -10 for chopping	✓		✓	✓	
Relational	Avoid within 3 cells	✓		✓	✓	
	Find source of	✓	✓	✓		
	Find source of	✓	✓	✓		
Budgetary All		✓	✓	✓	✓	
Sequential All			✓	✓	✓	
Mathematical All		✓		✓	✓	
Relational All		✓	✓	✓	✓	
Caged: all constraints and their reformulations		✓	✓	✓	✓	✓

Оценка LLM-агента в режиме без обучения показывает, что он имеет эпизодическое вознаграждение как у PPO. Однако штрафы существенно различаются между типами ограничений. Математические ограничения оказываются проще, поскольку штраф начисляется за отдельные действия, например рубку деревьев или убийство коров, и агенты просто перестают рубить деревья или убивать коров.

Эксперименты на Caged CrafText показывают разные слабые места у обучаемых агентов с подкреплением и LLM-агента. PPO-LAG и PPO-Cost умеют снижать штрафы, но часто делают это за счёт остановки исследования и перехода к локально безопасному поведению. LLM-агент, наоборот, лучше сохраняет выполнение целевой инструкции, но из-за плохого умения связывать текст с объектами в среде нарушает ограничения.

Таблица 6 — Сравнение базовых алгоритмов и LLM-агента на Caged CrafText. R — вознаграждение, C — штраф за нарушение ограничений.

	PPO		**PPO-LAG**		**PPO-Cost**		**LLM**	
Набор задач	R↑	C↓	R↑	C↓	R↑	C↓	R↑	C↓
Budgetary All	0.23	11.38	0.05	0.36	0.11	0.12	0.19	40.1
Sequential All	0.24	7.65	0.05	1.02	0.08	0.82	0.19	22.7
Mathematical All	0.23	110.42	0.24	0.10	0.18	0.05	0.19	16.9
Relational All	0.22	31.36	0.11	11.69	0.04	8.18	0.18	15.2
Caged	0.22	103.66	0.03	0.17	0.14	0.13	0.20	43.4

Заключение

В диссертационной работе рассмотрены методы безопасного обучения с подкреплением для задач, где агенту необходимо не только достигать цели, но и ограничивать штрафы за небезопасные действия во время обучения и исполнения. Такой конфликт особенно заметен в робототехнических задачах: для нахождения успешного поведения агент должен исследовать среду, однако именно исследование часто приводит к столкновениям, попаданию в опасные области или другим нарушениям ограничений.

В работе последовательно рассмотрены три аспекта этой проблемы. Первый связан с использованием моделей мира для предварительной оценки последствий действий. Второй — с иерархической декомпозицией поведения, которая позволяет работать с задачами большого горизонта через промежуточные подцели. Третий — с переходом к постановке, где цель и ограничение безопасности задаются не только численно, но и на естественном языке.

Проведённый обзор показывает, что существующие методы решают эти задачи только частично. Одноуровневые безопасные стратегии могут снижать штрафы, но в задачах большого горизонта часто становятся слишком осторожными и перестают продвигаться к цели. Методы на основе моделей мира дают возможность оценивать риск до выполнения действия, однако их качество зависит от точности модели, горизонта предсказания и выбранного способа оценки штрафов. Подходы с априорной информацией о среде могут давать более жёсткий контроль безопасности, но обычно требуют известной модели объекта управления или явных функций ограничений.

В рамках направления безопасного обучения с подкреплением на основе модели мира предложена модификация подхода SPOWL, в котором модель мира используется для оценки вознаграждения, штрафов и долгосрочного риска кандидатных действий. Показано, что безопасное исследование должно учитывать не только мгновенный штраф, но и оценки будущих накопленных штрафов, позволяющие оценивать риск за пределами короткого горизонта планирования. Экспериментальный анализ показал, что способ агрегации ансамбля функций

оценки будущих накопленных штрафов существенно влияет на баланс между безопасностью и эффективностью.

Для решения проблемы безопасного исследования в задачах с большим горизонтом разработан метод SG-Safe. Метод использует стратегию генерации промежуточных подцелей, которая применяется на этапе обучения и направляет безопасную стратегию к более информативным областям пространства состояний. При этом на этапе исполнения используется только итоговая безопасная стратегия, поэтому метод не требует планирования и дополнительных вычислительных затрат. Эксперименты на Safety Gym и POLAMP показали, что SG-Safe повышает успешность решения навигационных задач при сохранении низкого уровня нарушений безопасности. В среднем на Safety Gym метод достигает доли успешных эпизодов 0.87 при частоте столкновений 0.03, а на POLAMP демонстрирует преимущество в задачах с длинными маршрутами и узкими коридорами.

Дальнейшее развитие иерархического подхода реализовано в методе ITES. В отличие от SG-Safe, метод ITES вводит явный контроль безопасности как на уровне генерации подцелей, так и на уровне их достижения. Верхнеуровневая стратегия генерирует промежуточные подцели с учётом модели штрафов и верхнеуровневого критика штрафов, а низкоуровневая стратегия использует модель мира для проверки безопасности коротких воображаемых траекторий. Эксперименты на SafeAntMaze и SafePusher показали, что ITES превосходит неиерархические методы безопасного обучения с подкреплением в задачах с большим горизонтом, где многие методы сравнения либо нарушают ограничения, либо не достигают цели. В SafeAntMaze C-shape метод достигает доли успешных эпизодов 0.88 при штрафах 15.2, а в SafePusher — доли успешных эпизодов 0.42 при штрафах 12.8, сохраняя ограничения безопасности.

Отдельно в диссертации рассмотрена задача безопасного обучения с подкреплением с естественно-языковыми целями и ограничениями. Для этой постановки разработан бенчмарк Caged CrafText, расширяющий CrafText до задач, где агент получает не только инструкцию цели, но и текстовое ограничение. Бенчмарк включает бюджетные, последовательные, математические и отношенческие ограничения, проверяющие память, безопасное исследование, рассуждение, понимание того, как агент соотносит текст с объектами и состояниями среды, а также долгосрочное планирование. Эксперименты с PPO, PPO-LAG, PPO-Cost и агентом на основе большой языковой модели показали, что существующие подходы плохо решают задачи, где инструкция и ограничения заданы с помощью естественного языка. PPO учится решать задачу, но систематически нарушает ограничения; PPO-LAG снижает уровень эпизодических нарушений, но часто становится чрезмерно консервативным; агент на основе большой языковой модели лучше интерпретирует инструкции, но сохраняет высокий уровень нарушений из-за ошибок связывания текстового ограничения с состояниями среды.

При этом остаются направления для дальнейшего исследования. Для методов безопасного обучения с подкреплением с применением иерархии остаётся проблема обеспечения более строгих гарантий безопасности для каждого действия агента, например с помощью барьерных функций или безопасных слоёв. Для задач с естественно-языковыми ограничениями проблемой остаётся связывание языка и наблюдений: агент должен понимать текстовое ограничение и соотносить его с объектами среды.

По итогам, диссертационная работа развивает безопасное обучение с подкреплением в трёх направлениях: оценка долгосрочного риска с помощью моделей мира для обеспечения безопасного исследования, решение проблемы безопасного исследования в задачах с большим горизонтом с помощью иерархической структуры и разработка бенчмарка для обучения и оценки методов безопасного обучения с подкреплением с ограничениями и задачами, заданными на естественном языке.

Основные результаты работы:

1. проведён анализ методов безопасного обучения с подкреплением и выявлены ограничения одноуровневых стратегий, безопасного обучения с подкреплением на основе модели мира и существующих методов безопасного иерархического обучения с подкреплением;
2. исследована роль модели мира в оценке вознаграждения, штрафов и долгосрочного риска при безопасном планировании;
3. разработан метод SG-Safe для безопасного исследования в задачах с большим горизонтом за счёт генерации промежуточных подцелей;
4. разработан метод ITES, объединяющий иерархическую декомпозицию, модель мира и модель штрафов для контроля безопасности на уровне подцелей и действий;
5. разработан бенчмарк Caged CrafText для задач с естественно-языковыми целями и ограничениями и проведена экспериментальная оценка базовых методов в этой постановке.

Публикации автора по теме диссертации

1. Gorbov G., Panov A. I. Enhancing Safe Exploration Through Subgoal Guidance // Technologies. – 2026. – Vol. 14, no. 3. – Art. 146.
2. Latyshev A., Gorbov G., Panov A. I. Safe Planning and Policy Optimization via World Model Learning // Frontiers in Artificial Intelligence and Applications: Proceedings of the 28th European Conference on Artificial Intelligence (ECAI 2025). – IOS Press, 2025. – Vol. 413. – P. 1945–1952.
3. Gorbov G., Lukashevsky D., Skrynnik A., Panov A. I. Caged CrafText: Language-Grounded Safety Constraints for Multimodal Reinforcement

Learning in CrafText // Optical Memory and Neural Networks. – 2026. – Vol. 35. – P. 18–30.
4. Volovikova Z., Gorbov G., Kuderov P., Panov A., Skrynnik A. CrafText Benchmark: Advancing Instruction Following in Complex Multimodal Open-Ended World // Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). – 2025. – P. 26131–26151.
5. Gorbov G., Latyshev A., Panov A. I. Imagine to Ensure Safety in Hierarchical Reinforcement Learning // Machine Learning and Knowledge Extraction. – 2026. – Vol. 8, no. 8. – Art. 243.

Горбов Григорий Владиславович

Методы и алгоритмы безопасного обучения с подкреплением в робототехнических задачах

Автореф. дис. на соискание ученой степени канд. техн. наук

Подписано в печать ___.___._____. Заказ № _____
Формат А4. Усл. печ. л. 1. Тираж 100 экз.
Типография _____